

Estatística + R

Ana Paula Fernandes (DESCO/ICS/UFTM)

Atualizado em: 04/09/2026

Contents

1	Bem-vindos!	9
2	Introdução	11
2.1	Desconstruindo mitos	11
2.2	Aplicações práticas da estatística	11
2.3	Um desafio para você	12
2.4	Tipos de análise estatística	13
2.5	Atividade 1: a estatística na pesquisa científica	13
3	Conceitos Fundamentais	15
3.1	Estatística descritiva	15
3.2	Estatística inferencial	16
3.3	A conexão com a probabilidade	16
3.4	População e amostra	17
4	Tamanho da Amostra	19
4.1	Por que calcular o tamanho da amostra	19
4.2	O cálculo muda conforme o objetivo	19
4.3	Cálculo para estimar uma proporção	20
4.4	E se a pesquisa tiver vários objetivos?	21
4.5	Ferramentas para o cálculo	21
4.6	Atividade 2: análise crítica do artigo	23
4.7	Exercício: a Calculadora USP Bauru	23
5	Técnicas de Amostragem	27
5.1	O que é viés de amostragem	27
5.2	Amostragem aleatória simples	27
5.3	Amostragem estratificada	28
5.4	Amostragem sistemática	28
5.5	Amostragem por conglomerados	29
5.6	Amostragem por conveniência	29
5.7	Combinando técnicas	30
5.8	Comparando as técnicas	31
5.9	Um guia rápido contra o viés	31
5.10	Para levar daqui	32
6	Ambiente Computacional	33
6.1	Softwares pagos	33
6.2	Softwares livres	33
6.3	Linguagens computacionais	33
6.4	Preparando o Ambiente Computacional	33
6.5	Plano A: Instalação do R e RStudio	33
6.6	Plano B: R e RStudio na Nuvem	34
7	Trabalhando no RStudio	37

8	Primeiros exercícios no R	41
8.1	Exemplo 1	41
8.2	Exemplo 2	41
8.3	Exemplo 3	42
9	Tipos de Variáveis	45
9.1	Variáveis Quantitativas	45
9.2	Variáveis Qualitativas	45
9.3	Aplicação das Variáveis em Estatística	46
9.4	Atividade 3	46
10	Estatística Descritiva	47
10.1	Medidas de Tendência Central (ou Posição)	47
10.2	Medidas de Dispersão (ou Variabilidade)	48
10.3	Medida Relativa de Variabilidade	49
10.4	Apresentação dos Resultados	49
10.5	Funções no R	50
10.6	Atividade 4	50
11	Importando banco de dados	53
11.1	Antes de tudo: onde o arquivo mora	53
11.2	Forma 1: pelo botão Import Dataset	54
11.3	Forma 2: sem baixar nada	56
11.4	Forma 3: escolhendo o arquivo na tela	57
11.5	Forma 4: escrevendo o caminho	57
11.6	Importando um banco xls	57
11.7	Exemplo 1	57
11.8	Exemplo 2	59
11.9	Exemplo 3	59
11.10	Exemplo 4: um banco da sua área	59
12	Instalando pacotes	63
12.1	Exemplo 1	64
12.2	Exemplo 2	64
12.3	Exemplo 3	64
12.4	Exemplo 4	64
12.5	Atividade 5	65
13	Gráficos	67
13.1	Histograma	68
13.2	Boxplot	70
13.3	Atividade 6	72
14	Pacote ggplot	73
14.1	Principais Vantagens	73
14.2	Exemplos de Gráficos Simples e Bonitos com ggplot2	73
14.3	Exemplos de Bancos de Dados do R	77
15	Distribuição de Probabilidade	79
15.1	Distribuição Normal	79
15.2	Gráfico QQ	83
15.3	Atividade 7	87
16	Exemplos de distribuições	89
16.1	Distribuições Discretas	89
16.2	Distribuições Contínuas	91

17 Normal ou Não?	99
17.1 Dados que seguem distribuição normal	99
17.2 Dados que geram dúvida	101
17.3 Dados que não seguem distribuição normal	103
17.4 Dados com forte concentração de repetição de valor (não seguem distribuição normal)	105
18 Estatística Inferencial	109
18.1 Etapas de um Teste Estatístico	109
18.2 Erros Tipo I e Tipo II	110
18.3 Poder do Teste Estatístico	110
18.4 Tabela: Erros, Decisões e Poder do Teste	110
18.5 Tamanho do Efeito	111
18.6 Medidas Comuns de Tamanho do Efeito	111
18.7 Por que o Tamanho do Efeito é Importante?	112
18.8 Testes	112
19 Testes de Comparação entre Grupos	113
19.1 Comparações Pareadas (Dependentes)	113
19.2 Comparações Não-Pareadas (Independentes)	113
19.3 Número de Grupos na Comparação	113
19.4 Testes Paramétricos e Não Paramétricos	114
20 Comparação entre dois grupos	115
20.1 Teste t pareado	115
20.2 Wilcoxon pareado	116
20.3 Teste t não pareado	117
20.4 Wilcoxon não pareado	119
20.5 Teste bilateral vs. teste unilateral	120
20.6 Exercício 1	121
20.7 Exercício 2	122
20.8 Exercício 3	123
20.9 Exercício 4	124
21 Cálculo amostral no R	127
21.1 Principais Pacotes para Cálculo Amostral	127
21.2 Exemplo de cálculo amostral para teste t	127
21.3 O que é o d de Cohen?	128
21.4 Exemplos práticos	130
21.5 Como calcular o poder do teste quando você já tem o tamanho da amostra	132
21.6 Cálculo do Tamanho da Amostra para Testes t Pareado e Wilcoxon	133
22 Memes de Estatística: p-valor	135
22.1 Quando você encontra um p-valor baixo e sabe que deve rejeitar H_0	135
22.2 Homem-Aranha apontando	136
22.3 Namorado distraído	137
22.4 Willy Wonka e o p-valor menor que 0,05	137
22.5 Cantada Nerd	138
22.6 P-valor não é tudo	138
22.7 Coitado do tamanho do efeito	141
22.8 Senhora estatística	143
22.9 Pobre do gatinho	143
23 Pacotes pwr, rstatix e effsize	145
23.1 Cálculos de tamanho de amostra, poder e efeito com o pacote pwr	145
23.2 Tamanho do efeito em testes de Wilcoxon	149
24 Teste de Normalidade	155
24.1 Hipóteses nos Testes de Normalidade	155

24.2	Principais Testes de Normalidade	155
24.3	Assimetria e Curtose: O que são e por que são importantes?	158
25	Comparação de mais de dois grupos	159
25.1	Revisando as hipóteses da comparação entre dois grupos	159
25.2	Hipóteses para a comparação entre mais de dois grupos	159
25.3	Testes Paramétricos	160
25.4	Testes Não Paramétricos	160
25.5	ANOVA de uma via no R	160
25.6	Kruskal-Wallis no R	163
25.7	Por que não é indicado comparar os grupos dois a dois diretamente?	164
25.8	ANOVA para Dados Repetidos no R	164
25.9	Teste de Friedman	170
26	Correlação entre variáveis	173
26.1	Tipos de Variáveis	173
26.2	Diagrama de Dispersão	173
26.3	Coefficientes de Correlação	174
26.4	Testes de Correlação	176
26.5	Tamanho do Efeito (Effect Size)	178
26.6	Cálculo do Tamanho da Amostra e Poder Estatístico	178
26.7	Outros recursos	179
27	Regressão	185
27.1	Regressão Linear Simples	186
27.2	Regressão Linear Múltipla	190
27.3	No R é fácil	192
27.4	Exercício	195
28	Associação entre variáveis	197
28.1	Tipos de Variáveis Envolvidas	197
28.2	Tabela de Contingência	197
28.3	Principais Testes de Associação	198
28.4	Tamanho do Efeito: Medidas de Associação	202
28.5	Cálculo do Poder Estatístico	205
29	Ciência Aberta	207
29.1	O que é ciência aberta	207
29.2	Por que isso importa para o seu trabalho	207
29.3	Onde encontrar dados abertos	208
29.4	Onde encontrar artigos abertos	209
29.5	Registro de estudos	209
29.6	Como tornar a sua pesquisa aberta	209
30	Dados do DATASUS	211
30.1	Os principais sistemas	211
30.2	O pacote microdatasus	211
30.3	Duas armadilhas que valem ouro	212
30.4	O banco de nascimentos deste livro	212
30.5	Um exemplo do começo ao fim	213
30.6	Cuidados ao usar dados do DATASUS	218
30.7	Ideias para começar	218
	Livros e textos gerais	219
	Tamanho do efeito	219
	Cálculo amostral e poder em testes não paramétricos	219
	Testes de normalidade, assimetria e curtose	219
	Comparação entre grupos e ANOVA	220

Gráficos e instrumentos	220
Ciência aberta e dados abertos	220
Software	220

Chapter 1

Bem-vindos!

Esse livro *online* tem como propósito principal ser um guia para as aulas de estatística, referente as disciplinas de **Bioestatística** para os cursos de Medicina e Educação Física e **Estatística Aplicada** para o curso de Psicologia da Universidade Federal do Triângulo Mineiro - UFTM. E como objetivo secundário, ser uma referência de consulta para todos os discentes que passaram por essas disciplinas, bem como, para todos que estão interessados em realizar análises de dados por meio da linguagem R e o ambiente de desenvolvimento RStudio.

Sugestões, correções ou qualquer outra forma de interação são sempre bem-vindas! Então, por favor, não hesite em me escrever (anapaula.fernandes@uftm.edu.br).

Para mais informações sobre minha trajetória acadêmica e profissional, acesse meu Currículo Lattes.

Esta obra, registrada sob o **ISBN 978-65-01-56980-2**, traz conteúdos atualizados e essenciais para estudantes e profissionais interessados no tema.

Chapter 2

Introdução

Ao longo de algum tempo ministrando aulas de estatística, concluí que estudar estatística com auxílio de recursos computacionais é bem mais eficaz. Quero dizer, é mais fácil entender os conceitos teóricos, lidar com recursos visuais (gráficos) e, de fato, transformar o conteúdo estudado na disciplina em uma ferramenta para pesquisas científicas, quando se trata de analisar dados.

2.1 Desconstruindo mitos

Ministrando aulas para os cursos da área de **saúde, esporte e psicologia**, sempre ouvi dos discentes que “estatística é matemática”, e sempre digo que **estatística é estatística!**

É normal alguns discentes não assimilarem, em princípio, a importância da disciplina na grade do seu curso. Alguns acham até que é um assunto que deveria ficar restrito aos cursos das exatas. Assim, a primeira tarefa é sempre desconstruir essa ideia.

2.1.1 A estatística é multidisciplinar

A estatística está em tudo, na verdade. E para dizer uma coisa “bem chique”: a estatística é a base da Inteligência Artificial. Adivinha quem está por trás dos famosos algoritmos das redes sociais, das sugestões de filmes e músicas que aparecem no seu *streaming* favorito, do ranqueamento de busca do *Google* e dos agentes de IA?

2.2 Aplicações práticas da estatística

E sendo um pouco mais “acadêmica”, dentro do nosso propósito, veja como ela aparece em cada uma das nossas áreas.

2.2.1 No esporte

Qualquer competição ou treinamento esportivo está recheado de estatística. Como medir o desempenho de um time ou atleta?

Uso de suplementos alimentares e acompanhamento nutricional por frequentadores de academias

<https://www.rbne.com.br/index.php/rbne/article/view/2440>

2.2.2 Na medicina

Estudos epidemiológicos e, claro, da medicina baseada em evidências têm o suporte da estatística.

Síndrome Coronariana Aguda no Brasil: Registro dos Fatores Predisponentes e Perfil Populacional em um Instituto Cardiológico Público de Referência Nacional

<https://www.scielo.br/j/abc/a/gPrBrwLpGxWgzjFCgLkJJLN/?format=html&lang=pt>

2.2.3 Na psicologia

Na psicologia, a estatística é a ferramenta utilizada na psicometria.

Avaliação do sofrimento psíquico em estudantes do internato médico

<https://acervomais.com.br/index.php/cientifico/article/view/21295>

2.3 Um desafio para você

Faça uma busca com os termos “estatística” mais um campo do seu curso que te interessa, e você vai encontrar um artigo científico. E se não encontrar, comece a escrever sobre o tema!

2.3.1 Periódicos por área

Para facilitar sua busca, separei alguns periódicos por área de conhecimento.

Ciência dos esportes

Periódico	Link
RBFF - Revista Brasileira de Futsal e Futebol	http://www.rbff.com.br
RBME - Revista Brasileira de Medicina do Esporte	https://www.scielo.br/j/rbme
RBPE - Revista Brasileira de Psicologia do Esporte	http://pepsic.bvsalud.org

Medicina e saúde

Periódico	Link
RBC - Revista Brasileira de Cancerologia	https://rbc.inca.gov.br/index.php/revista
RBCMS - Revista Brasileira de Ciências Médicas e da Saúde	http://www.rbcms.com.br
ABRASCO - Revista da Associação Brasileira de Saúde Coletiva	https://cienciaesaudecoletiva.com.br

Psicologia

Periódico	Link
Psicologia Argumento	https://periodicos.pucpr.br/psicologiaargumento
Estudos de Psicologia (Campinas)	https://www.scielo.br/j/estpsi/
Psicologia em Foco	https://revistas.fw.uri.br/index.php/psicologiaemfoco

2.3.2 Onde mais procurar

Além dos periódicos, vale conhecer as bases de dados: o Mendeley, que é gerenciador de referências e buscador ao mesmo tempo; a SciELO, com foco na produção da América Latina; o Google Scholar, que é o mais abrangente; e o PubMed, especializado em ciências biomédicas e da saúde.

Dica de busca: use aspas para termos exatos ("análise estatística"), combine assuntos com o operador AND (estatística AND psicologia) e filtre por período nas opções de busca. Isso reduz muito o número de resultados irrelevantes.

2.4 Tipos de análise estatística

Quando olhamos os artigos acima, podemos ver que todos eles têm resultados **descritivos** e **inferenciais**. A estatística descritiva descreve os dados amostrados para uma dada análise; a inferencial infere, isto é, tira conclusões a partir desses dados. Discutiremos sobre ambas ao longo do curso.

A estatística não é apenas matemática abstrata: é a ferramenta que transforma dados em conhecimento, seja qual for a sua área.

2.5 Atividade 1: a estatística na pesquisa científica

A metodologia científica é composta por etapas que guiam o processo de investigação, e a estatística está presente em várias delas, desde o planejamento da coleta até a interpretação dos resultados. Nesta atividade você vai identificar como isso acontece em um estudo real da sua área.

Busque um artigo científico do campo do seu interesse que utilize estatística e percorra o roteiro abaixo.

2.5.1 1. Problema de pesquisa

Toda pesquisa começa com uma pergunta. Qual é a questão central que o artigo busca responder? Os autores apresentam os objetivos com clareza? O que se espera alcançar com os resultados? Há hipóteses formuladas e, se há, quais são?

2.5.2 2. Metodologia

A metodologia descreve o caminho percorrido pelo pesquisador, e é aqui que a estatística começa a aparecer no planejamento. Observe cada um destes aspectos:

Aspecto	O que observar no artigo
Tipo de pesquisa	É qualitativa, quantitativa ou mista?
População e amostra	Qual é a população-alvo? Quantos participantes compõem a amostra?
Cálculo amostral	Os autores justificam o tamanho da amostra? Foi feito o cálculo?
Técnica de amostragem	Como os participantes foram selecionados? Aleatória, por conveniência, estratificada?
Instrumentos de coleta	Questionários, testes, medições, observações?
Análise estatística	Quais técnicas foram aplicadas aos dados?
Software	Qual programa foi usado? SPSS, R, Python, Excel?

Depois de preencher a tabela, pergunte-se por que essas escolhas metodológicas importam para a validade da pesquisa.

2.5.3 3. Resultados

A estatística descritiva organiza e resume os dados coletados, e é isso que aparece nas tabelas e nos gráficos. Quais informações estão representadas visualmente? Que tipos de gráfico foram usados (barras, dispersão, boxplot, histograma, pizza)? Eles são claros e bem organizados? Os dados apresentados respondem aos objetivos da pesquisa? E como os autores interpretam esses resultados?

Dica: preste atenção nas legendas, nos títulos e nas notas de rodapé das tabelas e dos gráficos. É ali que costumam estar as informações que explicam o que você está vendo.

2.5.4 4. Glossário estatístico

Familiarizar-se com a terminologia é essencial para compreender e depois aplicar essas técnicas nas suas próprias pesquisas. Faça uma lista dos termos estatísticos que aparecem no artigo. Estes são alguns dos que você pode encontrar:

Categoria	Exemplos de termos
Medidas descritivas	Média, mediana, moda, desvio padrão, variância, percentis
Tipos de variáveis	Variável dependente, independente, qualitativa, quantitativa
Testes de hipótese	Teste t, ANOVA, qui-quadrado, Mann-Whitney, Kruskal-Wallis
Análises de relação	Correlação de Pearson, Spearman, regressão linear, regressão logística
Conceitos inferenciais	Intervalo de confiança, nível de significância, p-valor, poder do teste, tamanho do efeito
Outros	Normalidade, homocedasticidade, distribuição, outliers

Para cada termo, anote a página onde aparece, tente defini-lo com suas palavras e pesquise o significado dos que você não conhece.

2.5.5 Para fechar

Ao terminar a análise, você deve conseguir reconhecer como a estatística se integra às etapas da metodologia científica, identificar as principais técnicas usadas na sua área, entender por que o planejamento estatístico afeta a qualidade da pesquisa e olhar com mais critério para a forma como os dados são apresentados.

E uma última pergunta, para pensar: com base no artigo que você analisou, que decisões metodológicas você tomaria de outro jeito se fosse conduzir uma pesquisa semelhante?

Chapter 3

Conceitos Fundamentais

Antes de mergulharmos nas análises, precisamos de dois conceitos que sustentam qualquer estudo quantitativo: a **estatística descritiva** e a **estatística inferencial**. Pense assim: a descritiva organiza e resume os dados que você coletou; a inferencial tira conclusões sobre uma população maior a partir dessa amostra. Vamos ver cada uma com exemplos.

3.1 Estatística descritiva

A estatística descritiva organiza, resume e apresenta os dados de forma compreensível, usando tabelas, gráficos e medidas numéricas.

3.1.1 Exemplo 1: saúde mental dos estudantes

Imagine que você quer avaliar a saúde mental dos estudantes da UFTM, coletando informações sobre níveis de estresse e de ansiedade, presença de depressão e bem-estar geral.

Como esses dados são coletados? Por meio de **instrumentos psicométricos**, que são questionários e escalas padronizadas para medir características psicológicas de forma objetiva. Esses instrumentos passam por processos rigorosos de validação estatística, justamente para garantir que medem o que se propõem a medir.

Aspecto avaliado	Instrumento	O que avalia
Estresse	PSS-10 (Escala de Estresse Percebido)	O quanto as situações da vida são percebidas como estressantes
Ansiedade	BAI (Inventário de Ansiedade de Beck) ou GAD-7	Sintomas de ansiedade em diferentes intensidades
Depressão	BDI-II (Inventário de Depressão de Beck) ou PHQ-9	Presença e gravidade de sintomas depressivos
Bem-estar	Escala de Bem-Estar Subjetivo ou WHO-5	Qualidade de vida e satisfação geral

Atenção: muitos desses instrumentos podem ser aplicados por pesquisadores de diferentes áreas, e não só por psicólogos. Mas a interpretação clínica e o diagnóstico são atribuição exclusiva de profissionais habilitados em psicologia ou psiquiatria.

Com esses dados em mãos, a estatística descritiva organiza as respostas em tabelas (por curso, por período, por faixa etária), calcula médias que resumem o conjunto em um número (média de estresse de 6,5 numa escala de 0 a 10), monta gráficos que facilitam a leitura (a porcentagem de alunos com ansiedade baixa, média

e alta), mede a variabilidade — um desvio padrão alto avisa que os alunos são muito diferentes entre si — e ajuda a enxergar padrões, como a relação entre horas de sono e nível de estresse.

O resultado é um panorama claro da saúde mental dos estudantes, e é sobre esse panorama que a instituição consegue montar programas de apoio psicológico, formular políticas de bem-estar e identificar os grupos que precisam de mais atenção.

3.1.2 Exemplo 2: prática de atividades físicas

Agora suponha que você queira entender como os estudantes se exercitam. Você pode levantar a frequência semanal e descobrir que 45% praticam atividade mais de três vezes por semana. Pode levantar os tipos de atividade e montar um gráfico com a distribuição: corrida 30%, musculação 25%, futebol 20%, dança 15% e yoga 10%. E pode classificar a intensidade em leve, moderada e intensa, para comparar os grupos.

Com essas informações, a universidade consegue criar campanhas direcionadas, oferecer novas modalidades e ajustar a infraestrutura ao que os alunos de fato procuram.

3.2 Estatística inferencial

A estatística inferencial usa os dados de uma **amostra** para tirar conclusões sobre a **população inteira**, com uma margem de confiança conhecida.

3.2.1 Exemplo 1: saúde mental dos estudantes

Você pesquisou 200 estudantes e quer falar sobre todos os 6.900 da UFTM.

A primeira coisa que a inferência permite é **estimar a média da população**. Se a média de ansiedade na amostra foi 7,0 numa escala de 0 a 10, você pode afirmar, com 95% de confiança, que a ansiedade média de todos os estudantes está entre 6,5 e 7,5.

A segunda é **comparar grupos**. Estudantes de Medicina têm mais ansiedade que os de Engenharia? Com média de 7,8 contra 6,2, uma diferença de 1,6 ponto, o teste estatístico indicou que essa diferença é significativa ($p < 0,05$). A conclusão é que sim, os estudantes de Medicina apresentam níveis maiores de ansiedade.

A vantagem é evidente: você não precisou pesquisar os 6.900 alunos. Com uma amostra bem planejada, dá para fazer afirmações confiáveis sobre a universidade inteira.

3.2.2 Exemplo 2: prática de atividades físicas

Agora você pesquisou 300 estudantes de diferentes cursos, e a inferência responde a duas perguntas.

Qual é a proporção real de estudantes ativos? Na amostra, 60% praticam exercícios regularmente; para toda a UFTM, a estimativa fica entre 55% e 65%, com 95% de confiança.

E quem se exercita mais, Educação Física ou Medicina? Com 85% de ativos contra 42%, o teste apontou diferença significativa: os estudantes de Educação Física são mais ativos fisicamente.

3.3 A conexão com a probabilidade

A teoria de probabilidade é a ponte entre a descritiva e a inferencial. É ela que permite sair dos dados que você tem em mãos e chegar a afirmações sobre quem você não mediu.

A partir dos dados descritivos, podemos calcular a probabilidade de um estudante desenvolver sintomas de estresse durante o semestre, de um aluno que dorme menos de seis horas ter ansiedade alta, ou de quem pratica exercícios apresentar melhor bem-estar mental. Isso nos permite prever e prevenir, e não apenas descrever.

3.4 População e amostra

Entender essa diferença é fundamental para qualquer pesquisa.

A **população** é o conjunto completo de todos os indivíduos que você quer estudar. No nosso exemplo, são os 6.900 estudantes da UFTM (dado do DRCA de dezembro/2024, incluindo graduação, cursos técnicos e pós-graduação).

A **amostra** é um grupo menor e representativo, selecionado dessa população. No nosso caso, 364 estudantes sorteados aleatoriamente, que representam toda a população com 95% de confiança e erro máximo de 5%.

3.4.1 Um exemplo completo

Vamos juntar tudo. O objetivo é avaliar o bem-estar emocional dos estudantes da UFTM.

Na **coleta**, partimos de uma população de 6.900 estudantes, sorteamos 364 e aplicamos um questionário padronizado em escala de 0 a 10.

Na **análise descritiva**, a amostra deu média de bem-estar 6,8, desvio padrão 1,5, com mínimo de 2,0 e máximo de 10,0.

Na **inferência**, generalizamos para a UFTM inteira. A média estimada é 6,8, e o intervalo de confiança de 95% vai de 6,65 a 6,95, calculado como $6,8 \pm 1,96 \cdot 1,5/364$, ou seja, $6,8 \pm 0,15$. A leitura é esta: temos 95% de confiança de que o bem-estar emocional médio de todos os estudantes da UFTM está entre 6,65 e 6,95.

Atenção a uma confusão comum: a margem de erro de 5% usada no cálculo do tamanho da amostra é dada em pontos percentuais de uma *proporção* — ela não é um percentual da média. O intervalo de confiança de uma *média* depende do desvio padrão da amostra, como na conta acima. São duas coisas diferentes.

E o que significa exatamente esse IC95%? Se você repetisse a pesquisa 100 vezes, com amostras aleatórias diferentes de 364 estudantes, e construísse um intervalo a cada vez, cerca de 95 desses intervalos conteriam a verdadeira média de todos os estudantes, e cerca de 5 não conteriam.

Repare na direção da afirmação: o que varia de amostra para amostra é o **intervalo**, não a média populacional. A média de todos os estudantes é um número fixo e desconhecido, e ou ela está dentro deste intervalo específico, ou não está. Os 95% são a confiança no *procedimento* que gerou o intervalo, não a probabilidade de a média cair nele.

O caminho completo, então, é este: da população sorteamos uma amostra; sobre a amostra fazemos a estatística descritiva, organizando, calculando e visualizando; sobre esses resultados fazemos a inferência, estimando, comparando e concluindo; e chegamos a conclusões sobre a população inteira, com margem de erro conhecida.

Agora reflita: em uma pesquisa sobre hábitos alimentares dos estudantes, como você aplicaria esses conceitos?

Chapter 4

Tamanho da Amostra

4.1 Por que calcular o tamanho da amostra

Calcular o tamanho da amostra é etapa obrigatória no planejamento de qualquer pesquisa. É esse cálculo que determina quantos participantes o estudo precisa para que os resultados representem a população, sejam estatisticamente confiáveis, tenham precisão suficiente para responder à pergunta e ainda caibam no tempo e nos recursos que você tem.

4.1.1 Errar o tamanho da amostra

Uma amostra pequena demais não tem poder para detectar o efeito que você procura: o estudo termina sem conclusão, ou com uma conclusão equivocada, e às vezes é invalidado por isso. Uma amostra grande demais desperdiça tempo e dinheiro e, na pesquisa com pessoas, levanta uma questão ética — você expôs mais gente do que precisava para responder à mesma pergunta.

Calcular direito, portanto, não é só uma exigência técnica: é o que torna a pesquisa cientificamente válida e eticamente responsável.

4.2 O cálculo muda conforme o objetivo

Não existe uma fórmula única. O método varia conforme o que você quer estimar ou testar, e cada análise exige informações diferentes:

Objetivo da pesquisa	Exemplo	O que você precisa saber antes
Estimar uma proporção	Percentual de alunos com ansiedade	Margem de erro, nível de confiança, proporção estimada
Estimar uma média	Média de horas de estudo por dia	Desvio padrão, margem de erro, nível de confiança
Comparar dois grupos	Estresse entre dois cursos	Tamanho do efeito, poder estatístico, nível de significância
Testar correlação	Relação entre sono e desempenho	Tamanho do efeito esperado, poder estatístico
Estudos experimentais	Efeito de uma intervenção	Grupos controle e experimental, poder, efeito esperado

Vamos detalhar o primeiro caso, que é o mais comum nos trabalhos de graduação.

4.3 Cálculo para estimar uma proporção

Quando o objetivo é estimar uma proporção — “qual percentual de estudantes tem ansiedade?” —, precisamos de quatro informações:

Parâmetro	O que é	No exemplo da UFTM
Tamanho da população (N)	Total de indivíduos que você quer estudar	6.900 estudantes
Margem de erro (E)	Quanto você aceita errar na estimativa	5% (0,05)
Nível de confiança	Quão confiante você quer estar	95% (o padrão)
Proporção estimada (p)	Estimativa inicial do fenômeno	50% (0,5), o pior cenário

4.3.1 A fórmula

Para população infinita ou muito grande:

$$n = \frac{Z^2 p (1 - p)}{E^2}$$

Onde n é o tamanho da amostra necessário; Z é o valor da distribuição normal padrão, que vale 1,96 para 95% de confiança e 2,58 para 99%; p é a proporção estimada, e usamos 0,5 quando não temos ideia; e E é a margem de erro em decimal, de modo que 5% vira 0,05.

Queremos estimar a proporção de estudantes da UFTM com sintomas de ansiedade. A população é de 6.900 estudantes, aceitamos uma margem de erro de 5%, queremos 95% de confiança e, como não fazemos ideia da proporção, usamos 50%. Substituindo:

$$n = \frac{1,96^2 \cdot 0,5 \cdot (1 - 0,5)}{0,05^2} = \frac{3,8416 \cdot 0,5 \cdot 0,5}{0,0025} = \frac{0,9604}{0,0025} = 384,16$$

Precisamos de 384 estudantes.

4.3.2 Ajuste para população finita

Quando a população é “pequena” — na prática, quando N é menor que 10.000 —, aplicamos uma correção que aproveita o fato de estarmos pegando uma fração relevante do total:

$$n_{ajustado} = \frac{n}{1 + \frac{n-1}{N}}$$

No nosso caso:

$$n_{ajustado} = \frac{384}{1 + \frac{384-1}{6900}} = \frac{384}{1 + 0,0555} = \frac{384}{1,0555} = 364$$

Com a correção, precisamos de 364 estudantes, e não mais 384.

O que isso significa na prática? Que com 364 estudantes temos 95% de confiança nos resultados, com margem de erro de 5%, e que esses resultados representam bem os 6.900 alunos. Se 60% da amostra relatar ansiedade, podemos afirmar que entre 55% e 65% de todos os estudantes da UFTM têm ansiedade, com 95% de confiança.

4.4 E se a pesquisa tiver vários objetivos?

A regra é simples: calcule cada objetivo separadamente e use a maior amostra.

Imagine uma pesquisa com quatro objetivos. Estimar o percentual com ansiedade pede 364 alunos; calcular a média de bem-estar pede 280; comparar três cursos pede 120; e testar a correlação entre sono e estresse pede 85. A decisão é usar 364, porque essa amostra é suficiente para todos os objetivos ao mesmo tempo.

4.4.1 Ajuste para perdas

Nem todo mundo convidado vai participar ou responder, então acrescente uma margem de segurança:

$$\text{amostra final} = \frac{\text{amostra calculada}}{1 - \text{perda esperada}}$$

Prevendo 20% de perdas, $364 \div 0,80 = 455$. Ou seja, você precisa alcançar 455 pessoas para terminar com as 364 respostas válidas de que precisa.

4.5 Ferramentas para o cálculo

Nosso foco aqui não é fazer contas na mão, e sim compreender os conceitos e saber onde buscar ajuda. Existem hoje várias ferramentas gratuitas que fazem todo o trabalho.

Entre as calculadoras online, a Calculadora USP Bauru é a mais simples para proporções e médias: é rápida, está em português e não exige instalação. O OpenEpi é voltado para estudos em saúde e epidemiologia, e cobre desenhos como caso-controle e coorte. Já o G*Power é o mais completo e virou padrão em pesquisa: ele calcula amostra e poder estatístico para comparações e testes mais complexos, mas precisa ser instalado.

4.5.1 No R

A ideia é a mesma das calculadoras: em vez de aplicar a fórmula na mão, usamos uma função pronta. O pacote `samplingbook` faz o cálculo para proporção.

```
# Instalar o pacote (se ainda não tiver)
# install.packages("samplingbook")

# Carregar
library(samplingbook)

# Calcular amostra para proporção (considerando a população infinita)
sample.size.prop(
  e = 0.05,          # Margem de erro (5%)
  P = 0.5,          # Proporção estimada (50%)
  N = Inf,          # Tamanho da população: infinita
  level = 0.95      # Nível de confiança (95%)
)

##
## sample.size.prop object: Sample size for proportion estimate
## Without finite population correction: N=Inf, precision e=0.05 and expected proportion P=0.5
##
## Sample size needed: 385

# Calcular amostra para proporção (considerando a população finita)
sample.size.prop(
  e = 0.05,
  P = 0.5,
  N = 6900,          # Tamanho da população: finita
```

```
level = 0.95
)
```

```
##
## sample.size.prop object: Sample size for proportion estimate
## With finite population correction: N=6900, precision e=0.05 and expected proportion P=0.5
##
## Sample size needed: 364
```

E chegamos aos mesmos 364 estudantes.

Na saída, *sample size needed* quer dizer “tamanho de amostra necessário”.

Se preferir, dá para escrever a fórmula diretamente:

```
# Cálculo direto
N <- 6900
Z <- 1.96
p <- 0.5
E <- 0.05

n <- (Z^2 * p * (1-p)) / E^2
n_final <- ceiling(n / (1 + (n-1) / N))
n_final
```

```
## [1] 364
```

A vantagem de fazer no R é que o cálculo fica rápido, sem erro de conta, reproduzível por qualquer pessoa e fácil de repetir com outros cenários — basta trocar um número e rodar de novo.

4.5.2 E a inteligência artificial?

Você também pode pedir ajuda ao ChatGPT, ao Copilot ou a outra IA. Um exemplo de pergunta:

"Preciso calcular o tamanho da amostra para uma pesquisa com estudantes universitários (população de 6.900). Quero estimar a proporção de alunos com ansiedade, com 95% de confiança e margem de erro de 5%. Como faço e qual o resultado?"

Atenção: sempre valide o resultado da IA em uma das calculadoras acima. Ela erra, e erra com confiança.

4.5.3 Qual ferramenta escolher

Se você está começando, use a Calculadora USP Bauru. Se a pesquisa é da área da saúde, o OpenEpi cobre mais desenhos de estudo. Se precisa comparar grupos ou testar correlações, vá de G*Power. Se já usa R nas análises, os pacotes `samplingbook` e `pwr` resolvem. E se quer só entender o conceito rapidamente, pergunte a uma IA — mas confira o resultado em uma calculadora.

Seja qual for a escolha, documente-a no projeto. Um exemplo de como citar:

“O tamanho amostral foi calculado utilizando a Calculadora Amostral da USP Bauru (<http://estatistica.bauru.usp.br/calculoamostral/>), considerando população de 6.900 estudantes, margem de erro de 5% e nível de confiança de 95%.”

A boa notícia é que você não precisa ser expert em matemática para fazer isso direito. Com as ferramentas certas, o cálculo sai em minutos, e sobra tempo para o que realmente importa: planejar e executar uma pesquisa de qualidade.

4.6 Atividade 2: análise crítica do artigo

Volte ao artigo que você buscou na Atividade 1 e responda ao que segue.

4.6.1 Análise metodológica

1. Os autores discutem o cálculo do tamanho da amostra? Procure se há explicação sobre como o tamanho foi determinado, se mencionam a fórmula, o software ou a ferramenta usada, e se apresentam os parâmetros (margem de erro e nível de confiança). Se essa informação não aparece, pergunte-se: isso é uma limitação do estudo?

2. A população da pesquisa foi claramente definida? Verifique quem compõe a população-alvo, se há critérios de inclusão e exclusão, e se o contexto está delimitado quanto a local e período. Uma população mal definida compromete a validade dos resultados.

3. O tamanho da amostra foi adequado? Avalie criticamente se a amostra parece grande o suficiente, se é representativa da população e se os próprios autores discutem as limitações relacionadas ao tamanho dela.

4.6.2 Refaça o cálculo

Use uma das ferramentas indicadas e preencha:

Item	Informação do artigo	Seu cálculo
Tamanho da população (N)		
Margem de erro		
Nível de confiança		
Tipo de cálculo necessário		
Tamanho no artigo		
Seu resultado		
Coincidem?		Sim Não

Se os números não coincidirem, quais podem ser as razões?

4.6.3 Aspectos éticos

4. A pesquisa foi aprovada pelo Comitê de Ética? Procure no artigo a menção à aprovação do CEP, o número do parecer e a referência ao TCLE, o Termo de Consentimento Livre e Esclarecido.

5. Por que submeter ao Comitê de Ética importa? A submissão protege os participantes, garantindo que seus direitos sejam respeitados; assegura o consentimento informado, isto é, uma participação voluntária e esclarecida; resguarda a confidencialidade dos dados pessoais; obriga a avaliar a relação entre riscos e benefícios; e sustenta a credibilidade da pesquisa.

Não submeter tem consequências concretas: além da violação dos direitos dos participantes, há infração às Resoluções CNS 466/2012 e 510/2016, o artigo pode ser rejeitado ou retratado depois de publicado, e o pesquisador está sujeito a sanções.

Conheça o Comitê de Ética em Pesquisa (CEP) da UFTM em <https://www.uftm.edu.br/comite-secomissoes/cep>. Lá você encontra como submeter projetos, os documentos necessários, os prazos de tramitação e as regulamentações vigentes.

Para fechar: se você fosse revisor deste artigo, aprovaria a metodologia amostral? Justifique.

4.7 Exercício: a Calculadora USP Bauru

Você é pesquisador(a) e quer investigar a adesão ao uso de equipamentos de proteção individual (EPIs) entre os profissionais de enfermagem de um hospital universitário.

O hospital tem 450 profissionais de enfermagem, entre enfermeiros, técnicos e auxiliares. Estudos semelhantes mostram que cerca de 70% deles usam EPIs corretamente, e você quer trabalhar com 95% de confiança e margem de erro de 5%. Quantos profissionais precisa incluir na amostra?

4.7.1 Passo a passo na calculadora

Acesse <http://estatistica.bauru.usp.br/calculoamostral/>, clique em **Cálculos** no menu e selecione **1 - Intervalo de Confiança de uma Proporção**. Preencha os campos conforme a imagem:

Figure 4.1: Calculadora USP Bauru

Campo	O que colocar	Valor
Nível de Confiança	Deixe marcado 95%	95%
Erro (%)	Margem de erro desejada	5
Proporção Estimada na População (%)	Uso correto de EPIs	70
População finita	Marque a caixa e informe o total	450

Depois, clique em **Calcular**.

4.7.2 Anote seus resultados

a) Quantos profissionais você precisa pesquisar?

_____ profissionais

b) Qual é a diferença no tamanho da amostra ao considerar população finita e infinita?

Sem considerar população finita (infinita): _____ profissionais

Considerando população finita (450): _____ profissionais

Diferença: _____ profissionais

c) Volte às configurações originais e aumente o nível de confiança para 99%. O que acontece?

Com 99% de confiança: _____ profissionais

d) Retorne para 95% de confiança e diminua a margem de erro para 3%. Qual o impacto?

Com erro de 3%: _____ profissionais

e) Volte às configurações originais (95% de confiança, erro de 5%, proporção de 70%). Agora use o campo “Perda de elementos (%)” e considere 20% de perdas, por férias, licença ou recusa. Quantas pessoas você precisaria alcançar?

Ajustado para perdas: _____ profissionais

4.7.3 Questões para reflexão

1. Considerando que você precisa pesquisar _____ profissionais de um total de 450, isso representa cerca de _____% da população. É viável? Por quê?
2. Por que o tamanho da amostra é menor quando consideramos a população finita (450) em vez de infinita?
3. Se tivesse que escolher entre erro de 5% com 95% de confiança e erro de 3% com 95% de confiança, qual escolheria, considerando tempo e recursos limitados? Justifique.

4.7.4 Desafio extra

Agora mude o cenário: suponha que você não faça ideia da proporção de profissionais que usam EPIs corretamente. Quando não temos estimativa prévia, usamos 50%, que é o pior cenário e gera a maior amostra.

Volte à calculadora, confira que os parâmetros estão nas configurações originais (95% de confiança, erro de 5%, população finita de 450) e mude apenas a proporção estimada para 50%. Recalcule.

Qual é o novo tamanho da amostra? _____ profissionais. E por que ele mudou?

4.7.5 Gabarito

Clique para ver as respostas

Considerando população finita de 450 profissionais e proporção de 70%:

a) **Amostra necessária (erro de 5%, confiança de 95%):** 189 profissionais.

b) **Comparação:** sem considerar a população finita, seriam 323 profissionais; com a correção para os 450, caem para 189. A diferença é de 134 pessoas, ou seja, a correção reduz bastante.

c) **Com 99% de confiança:** 250 profissionais na população finita, contra 560 na infinita. Repare que 560 não faz sentido algum, por ser maior que a própria população do hospital.

d) **Com erro de 3%:** 300 profissionais na população finita, contra 897 na infinita — outro número sem sentido.

e) **Ajustado para 20% de perdas:** 237 profissionais, porque $189 \times 0,80 = 236,25$, e arredondamos para cima.

Desafio extra, com proporção de 50%: 208 profissionais, contra os 189 obtidos com 70%. A amostra aumentou porque 50% é o cenário mais conservador, o que gera a maior variabilidade possível.

E por que 50% gera a maior variabilidade? Porque a fórmula do cálculo para proporção inclui o produto $p(1-p)$, e esse produto é máximo justamente quando p vale 0,5:

Proporção (p)	$p \text{ e } (1 - p)$	Variabilidade
10% (0,10)	$0,10 \text{ e } 0,90 = 0,09$	Baixa
30% (0,30)	$0,30 \text{ e } 0,70 = 0,21$	Média
50% (0,50)	$0,50 \text{ e } 0,50 = 0,25$	Máxima
70% (0,70)	$0,70 \text{ e } 0,30 = 0,21$	Média
90% (0,90)	$0,90 \text{ e } 0,10 = 0,09$	Baixa

É por isso que, sem nenhuma estimativa prévia, usamos 50%: é a escolha que nos protege do pior caso.

Reflexão 1: 189 de 450 é 42% da população. É uma amostra grande em termos proporcionais, mas perfeitamente viável dentro de um hospital.

Reflexão 2: a correção para população finita leva em conta que estamos pegando uma fração significativa do total — 42%, neste caso. Quanto maior essa fração, menos pessoas são necessárias para atingir a mesma precisão.

Ao final deste exercício você deve saber usar a Calculadora USP Bauru passo a passo, entender por que a correção para população finita importa, perceber como o nível de confiança e a margem de erro puxam o tamanho da amostra para cima ou para baixo, saber por que usamos 50% quando não temos estimativa e como ajustar o número para as perdas esperadas. O próximo passo é aplicar isso à sua própria pesquisa.

Chapter 5

Técnicas de Amostragem

Depois de calcular quantas pessoas a pesquisa precisa, falta responder à outra metade da pergunta: **como** escolher essas pessoas. É disso que trata a técnica de amostragem, e o objetivo dela é garantir que a amostra represente bem a população, evitando viés.

5.1 O que é viés de amostragem

O viés aparece quando certos grupos têm mais chance de ser selecionados do que outros, o que distorce os resultados.

Imagine que a UFTM tenha 60% de mulheres e 40% de homens. Se a sua amostra terminar com 80% de homens e 20% de mulheres, ela não representa a população — e qualquer conclusão que você tirar dela vai carregar essa distorção. Toda a discussão a seguir é sobre técnicas que minimizam esse risco.

As técnicas se dividem em dois grupos. Nas **probabilísticas**, há sorteio, e todos têm uma chance conhecida e diferente de zero de ser selecionados. Nas **não probabilísticas**, não há sorteio: a seleção se dá por conveniência, julgamento ou cotas.

5.2 Amostragem aleatória simples

Todos têm a mesma chance de ser escolhidos, como num sorteio de loteria.

Para fazer, você obtém uma lista completa da população, numera cada pessoa de 1 até N, sorteia aleatoriamente a quantidade calculada e monta a amostra com quem foi sorteado. O sorteio pode ser feito no R com a função `sample()`, no Excel com `=ALEATÓRIOENTRE(1;N)`, em sites como o Random.org ou em qualquer aplicativo de sorteio.

Um exemplo na UFTM: para avaliar a saúde mental dos estudantes, você solicitaria à secretaria a lista de todos os alunos matriculados, sortearia 364 deles com uma ferramenta digital e convidaria os sorteados por e-mail institucional.

A vantagem é ser simples de entender e aplicar, dar chance igual a todo mundo, minimizar o viés de seleção e servir de base para as análises inferenciais. A desvantagem é depender de uma lista completa e atualizada, o que nem sempre existe, e ficar difícil em populações muito grandes. Há ainda o risco de grupos pequenos ficarem sub-representados por puro acaso.

Para evitar viés: garanta que a lista esteja completa e atualizada, use geradores aleatórios confiáveis em vez de escolher “de cabeça”, e nunca substitua um sorteado por outra pessoa mais acessível.

5.3 Amostragem estratificada

Aqui dividimos a população em grupos homogêneos, chamados estratos, e sorteamos dentro de cada grupo proporcionalmente. Use quando a população tem subgrupos importantes que precisam estar representados.

Vejamos como ficaria na UFTM, com uma amostra de 364 estudantes de graduação.

Nos exemplos de amostragem a seguir trabalhamos apenas com a graduação, cerca de 6.750 alunos. O N de 6.900 usado no cálculo amostral incluía também a pós-graduação e os cursos técnicos. Como os dois números são próximos, a amostra de 364 continua adequada — mas, na sua pesquisa, defina uma população só e use a mesma em todas as etapas.

O primeiro passo é definir os estratos, que aqui serão os cursos:

Curso	Estimativa de alunos*	%	Amostra por curso
Medicina	660	10%	36
Enfermagem	400	6%	22
Fisioterapia	330	5%	18
Terapia Ocupacional	200	3%	11
Nutrição	330	5%	18
Educação Física	530	8%	29
Psicologia	400	6%	22
Serviço Social	330	5%	18
Engenharia Ambiental	330	5%	18
Engenharia de Produção	330	5%	18
Engenharia de Alimentos	260	4%	15
Engenharia Elétrica	330	5%	18
Engenharia Mecânica	330	5%	18
Letras	260	4%	15
História	200	3%	11
Geografia	200	3%	11
Ciências Biológicas	400	6%	22
Química	200	3%	11
Matemática	200	3%	11
Biomedicina	330	5%	18
Total	~6.750	100%	364

*Valores aproximados, para efeito didático.

O segundo passo é sortear aleatoriamente, dentro de cada curso, a quantidade calculada para aquele estrato.

Essa técnica dá maior representatividade, garante que os cursos menores entrem na amostra, permite comparações entre eles e reduz a variabilidade do conjunto. Em compensação, exige conhecer a composição da população por curso e ter acesso a listas separadas por estrato, além de dar mais trabalho que a aleatória simples.

Para evitar viés: os estratos precisam ser relevantes para a pesquisa e mutuamente exclusivos, isto é, cada aluno em um estrato só. E use alocação proporcional, para que a amostra reflita a distribuição real da população.

Os cursos não são a única forma de estratificar na UFTM: dá para usar o período (calouros, intermediários, formandos), o campus (Uberaba e Iturama), o turno (matutino, vespertino, noturno, integral) ou a grande área (Saúde, Exatas, Humanas).

5.4 Amostragem sistemática

A ideia é escolher um ponto de partida aleatório e depois selecionar a cada k elementos da lista.

Com 6.750 alunos e uma amostra de 364, começamos calculando o intervalo:

$k = \text{População} / \text{Amostra}$

$k = 6.750 / 364 = 18,5$ arredonde PARA BAIXO: $k = 18$

Atenção ao arredondamento: aqui o k deve ser arredondado para baixo. Se usássemos $k = 19$, percorrendo a lista de 19 em 19 sairiam apenas 6.750 e $19 = 355$ pessoas, menos do que os 364 necessários. Com $k = 18$ saem 375, que cobre a amostra com folga.

Em seguida sortearmos o primeiro elemento, um número entre 1 e 18. Digamos que saiu o 7. A partir dele, selecionamos de 18 em 18: 7, 25, 43, 61, 79, 97, 115, 133, e assim por diante até percorrer a lista inteira. No R, a função `seq()` monta essa sequência; no Excel, uma fórmula de sequência aritmética resolve; e no papel, basta uma calculadora e a lista numerada.

Um exemplo fora da universidade: você está numa UBS pesquisando satisfação na fila de vacinação. Decide entrevistar uma a cada dez pessoas, sorteia o início e cai na terceira; daí em diante entrevista a 13ª, a 23ª, a 33ª, e por aí vai.

É uma técnica muito fácil de aplicar em campo, distribui a amostra uniformemente ao longo da lista e dispensa múltiplos sorteios. O problema aparece quando a lista tem algum padrão periódico, porque aí o salto fixo pode cair sempre no mesmo tipo de pessoa. E, por isso mesmo, ela é um pouco menos aleatória que a amostragem simples.

Para evitar viés: certifique-se de que a lista não tem uma ordem sistemática e, se tiver (por curso, por exemplo), embaralhe antes. E garanta que o primeiro elemento seja sorteado de verdade.

5.5 Amostragem por conglomerados

Aqui dividimos a população em grupos, os conglomerados, e sortearmos grupos inteiros.

Suponha que você queira pesquisar hábitos de estudo na UFTM. Uma opção é tomar as turmas como conglomerados: liste todas as turmas por curso e período, sorteie algumas e pesquise todos os alunos delas. Outra é tomar os cursos: liste os 20, sorteie 5 e pesquise todos os alunos (ou uma amostra) desses cursos. Uma terceira é tomar os campi: sorteie entre Uberaba e Iturama e pesquise uma amostra dos alunos do campus sorteado.

A vantagem fica evidente em escala nacional. Numa pesquisa sobre educação no Brasil é impossível listar todos os estudantes do país; então sortearmos 50 cidades, dentro delas sortearmos 5 escolas cada, e pesquisamos os alunos dessas escolas.

É a técnica mais prática para populações grandes e dispersas, economiza tempo e custo porque concentra a coleta, e dispensa a lista completa de indivíduos. O preço é ser menos precisa que as outras: conglomerados podem ser muito diferentes entre si, e isso aumenta o erro amostral.

Para evitar viés: os conglomerados devem ser internamente diversos e parecidos entre si — o oposto do que se espera dos estratos. E sorteie um número suficiente deles.

Essa é justamente a diferença que costuma confundir:

Aspecto	Estratificada	Conglomerados
Divisão	Grupos homogêneos	Grupos heterogêneos
Seleção	Amostra de cada grupo	Alguns grupos inteiros
Objetivo	Representar subgrupos	Facilitar a coleta
Na UFTM	Sortear alunos de cada curso	Sortear turmas inteiras

5.6 Amostragem por conveniência

Aqui selecionamos quem está mais acessível ao pesquisador. É uma técnica não probabilística, sem sorteio, com alto risco de viés — e, ao mesmo tempo, rápida, prática e barata. É a mais usada nos trabalhos de graduação, e por isso merece atenção redobrada.

Os exemplos mais comuns são o formulário online, em que o pesquisador compartilha um link e responde quem quiser; a abordagem em locais específicos, como entrevistar alunos na biblioteca, no restaurante universitário ou na entrada do campus; e a divulgação em redes sociais, por post no Instagram, grupo de WhatsApp do curso ou e-mail para colegas conhecidos.

Os formulários online, em especial, concentram quatro tipos de viés:

Tipo de viés	O que é	Exemplo
De acesso	Só quem tem internet responde	Exclui quem não tem smartphone ou dados móveis
De autosseleção	Só os interessados respondem	Quem gosta do tema participa mais
De distribuição	Enviado só a certos grupos	Só o grupo de WhatsApp do seu curso
De plataforma	Cada rede tem seu perfil	O público do Instagram não é o do e-mail institucional

O viés de distribuição é o mais fácil de cometer: se o formulário circular só no grupo da Medicina, a amostra terá um curso onde a população tem vinte.

A conveniência é aceitável em estudos exploratórios de fase inicial, em pré-testes de questionário, em pesquisas qualitativas, quando os recursos são muito limitados e em TCCs com prazo curto. Não é aceitável quando a pesquisa precisa generalizar para a população, em estudos quantitativos rigorosos, em dissertações e teses, e em publicações de alto impacto.

Se você precisa usá-la, dá para reduzir bastante o estrago. **Diversifique os canais:** não envie só em um grupo, mas também por e-mail institucional para todos os cursos, em redes sociais variadas, em murais físicos espalhados pelo campus, em avisos de sala de aula de cursos diferentes e na rádio universitária. **Descreva as limitações honestamente** no texto do trabalho. **Compare a amostra com os dados populacionais** e relate as diferenças: se 80% da amostra é de Exatas e a UFTM tem 40% de cursos dessa área, isso precisa aparecer. E, se possível, **combine com outra técnica**, somando o formulário online a uma coleta presencial estratificada.

Um exemplo de como relatar isso com honestidade em um artigo:

“Utilizou-se amostragem por conveniência através de formulário online (Google Forms), divulgado por e-mail institucional, redes sociais e grupos de WhatsApp. Obtivemos 412 respostas de estudantes da UFTM. Reconhecemos que esta técnica apresenta limitações quanto à representatividade, especialmente viés de autosseleção e acesso digital. A amostra apresentou maior proporção de estudantes da área da Saúde (65%) comparado à distribuição real dos cursos da UFTM (aproximadamente 40%), o que deve ser considerado na interpretação dos resultados.”

5.7 Combinando técnicas

Na vida real, os pesquisadores frequentemente combinam técnicas para melhorar a representatividade dentro do que é viável.

Dá para juntar estratificada com aleatória simples, dividindo os alunos por área e sorteando dentro de cada uma. Ou conglomerados com sistemática, sorteando 8 cursos e, dentro deles, selecionando a cada quinto aluno. Ou ainda estratificada com cotas, definindo quantas respostas se quer por curso e divulgando o formulário até preencher cada cota.

Veja um caso concreto: pesquisar o bem-estar dos estudantes, com recursos limitados e dois meses de prazo. Na primeira etapa, estratifique por área — Saúde 40%, Exatas 35%, Humanas 25% — e calcule a amostra proporcional. Na segunda, faça a coleta mista, visitando turmas sorteadas para obter 60% da amostra e complementando os 40% restantes com formulário online. Na terceira, monitore as proporções durante a coleta e reforce a divulgação nos grupos que ficarem sub-representados. O resultado é uma amostra mais representativa do que a puramente online e mais viável do que a puramente presencial.

5.8 Comparando as técnicas

Técnica	Tipo	Complexidade	Representatividade	Custo	Quando usar
Aleatória simples	Probabilística	Baixa	Alta	Médio	Lista completa disponível
Estratificada	Probabilística	Média	Muito alta	Médio-alto	Subgrupos importantes
Sistemática	Probabilística	Baixa	Alta*	Baixo	Lista sem padrões
Conglomerados	Probabilística	Média	Média	Baixo	População dispersa
Conveniência	Não probabilística	Muito baixa	Baixa	Muito baixo	Estudos exploratórios

*Desde que não haja padrão periódico na lista.

Para escolher, comece perguntando se você tem a lista completa da população. Se tem, veja se existem subgrupos importantes: havendo, use estratificada; não havendo, aleatória simples resolve. Se não tem a lista, pergunte se a população está dispersa geograficamente: se estiver, vá de conglomerados. Se não estiver e os recursos forem muito limitados, resta a conveniência, com todo o cuidado que ela exige — caso contrário, vale o esforço de conseguir a lista e usar a estratificada.

Antes de fechar a decisão, confira se você:

- ☐ definiu claramente a população-alvo
- ☐ calculou o tamanho da amostra necessária
- ☐ verificou se tem a lista completa da população
- ☐ identificou os subgrupos relevantes (cursos, períodos, áreas)
- ☐ avaliou os recursos disponíveis (tempo, dinheiro, equipe)
- ☐ escolheu a técnica adequada aos objetivos
- ☐ planejou como minimizar o viés
- ☐ vai documentar todo o processo para relatar no artigo

5.9 Um guia rápido contra o viés

Cinco fontes de viés aparecem com mais frequência, e cada uma tem um antídoto:

Tipo de viés	O que é	Como evitar
Seleção	Alguns grupos têm mais chance	Usar sorteio verdadeiramente aleatório
Autosseleção	Só os motivados participam	Incentivar e facilitar a participação de todos
Não resposta	Quem não responde é diferente de quem responde	Fazer follow-up, oferecer incentivos
Acesso	Parte da população não é alcançável	Combinar canais, online e presencial
Temporal	Coletar só em um certo período	Distribuir a coleta em momentos diferentes

E, ao final da coleta, verifique se você usou de fato um método de sorteio em vez de escolher pessoas conhecidas; se todos os subgrupos relevantes tinham chance de ser selecionados; se o cadastro estava atualizado; se você resistiu à tentação de substituir sorteados por quem estava mais à mão; se documentou quem recusou ou não respondeu; se comparou as características da amostra com as da população; e se relatou as limitações honestamente.

5.10 Para levar daqui

Documente tudo: como sorteu e com qual ferramenta, quantas pessoas foram convidadas, quantas aceitaram e quantas recusaram, e em que data a coleta aconteceu. Seja transparente sobre as limitações da técnica escolhida, sobre os vieses possíveis e sobre o motivo da escolha. Planeje para as perdas, acrescentando 20% a 30% ao tamanho calculado e tendo uma estratégia pronta para baixa adesão. E teste antes: um piloto com 10 a 20 pessoas revela problemas no questionário que você não veria de outro jeito.

Um exemplo de redação completa para a seção de método:

“Utilizou-se amostragem estratificada proporcional, com estratos definidos por curso de graduação. A partir do cadastro institucional de 6.750 estudantes da UFTM, distribuídos em 20 cursos, calculou-se amostra de 364 alunos (margem de erro de 5%, nível de confiança de 95%). A distribuição amostral por curso respeitou a proporção de cada curso na população. Dentro de cada estrato, realizou-se sorteio aleatório simples utilizando gerador de números aleatórios (Random.org). Foram convidados 486 estudantes para compensar possíveis perdas estimadas em 25% ($364 \times 0,75$). A taxa de resposta foi de 77% ($n = 374$), superando o mínimo necessário. A amostra final apresentou distribuição por área (Saúde 38%, Exatas 36%, Humanas 26%) compatível com a população da instituição.”

Em uma frase cada: a aleatória simples sorteia direto da lista completa; a estratificada divide em grupos e sorteia de cada um; a sistemática escolhe a cada k elementos; a de conglomerados sorteia grupos inteiros; e a de conveniência pega quem está acessível.

Sempre que possível, use técnicas probabilísticas: são elas que permitem generalizar os resultados e são mais aceitas cientificamente. E se você precisar recorrer à conveniência, seja honesto sobre as limitações.

Chapter 6

Ambiente Computacional

Existem diversos softwares dedicados à análise estatística, que vão desde planilhas eletrônicas, como o Excel, até programas mais robustos, como o SPSS. Abaixo, listamos algumas das principais ferramentas utilizadas:

6.1 Softwares pagos

- SPSS (IBM)
- Stata
- SAS
- JMP
- Prism
- Minitab
- Microsoft Excel

6.2 Softwares livres

- Jamovi
- OpenStat

6.3 Linguagens computacionais

- R
- Python

Neste curso, utilizaremos a linguagem **R**, desenvolvida especialmente para análise estatística. Quer entender por que essa escolha e ir além do que vemos aqui? Recomendamos: R para Ciência de Dados (livro completo e gratuito, em português) e o material aberto da Curso-R.

6.4 Preparando o Ambiente Computacional

Vamos preparar o ambiente computacional para realizar nossas análises com R.

Para esclarecer: - **R** é uma linguagem de programação (mas não se preocupe, não vamos programar profundamente). - **RStudio** é o software onde os códigos R serão executados. É o que chamamos de IDE – *Integrated Development Environment* (Ambiente de Desenvolvimento Integrado).

6.5 Plano A: Instalação do R e RStudio

Nos laboratórios da UFTM, o R e o RStudio já estão instalados. No entanto, sugerimos que você também os instale em seu computador pessoal, pois nem sempre conseguiremos realizar todas as atividades em sala.

Siga estes passos:

1. Instale o R: <https://cran.rstudio.com>
2. Instale o RStudio Desktop: <https://posit.co/download/rstudio-desktop>

Certifique-se de baixar versões compatíveis com o sistema operacional do seu computador.

Se tudo estiver correto, ao abrir o RStudio, você verá uma tela semelhante a esta:




Figure 6.1: Figura: Tela inicial do RStudio

Caso enfrente dificuldades, siga para o Plano B.

6.6 Plano B: R e RStudio na Nuvem

O Plano B é utilizar o RStudio diretamente na nuvem, sem precisar instalar nada. Essa alternativa é excelente, mas requer uma boa conexão com a internet.

Siga os passos:

1. Acesse: <https://posit.cloud>
2. Faça login (você pode usar sua conta do Google, por exemplo)
3. Após o login, você verá esta tela:
4. Crie um novo projeto clicando em *New Project* e, depois, *New RStudio Project*:
5. Pronto! A interface do RStudio será carregada na nuvem:

Vantagem: seus arquivos e análises ficam salvos na nuvem, em um local seguro e acessível de qualquer lugar.

Com o ambiente configurado, estaremos prontos para explorar o mundo da estatística com R!




Figure 6.2: Figura: Tela inicial na nuvem da Posit




Figure 6.3: Figura: Botão de criação de um novo projeto




Figure 6.4: Figura: Tela do RStudio online na Posit Cloud

Chapter 7

Trabalhando no RStudio

Seja na versão instalada no seu computador (plano A) ou na nuvem (plano B), conheça melhor as áreas do RStudio:

1. **Console:** local onde serão apresentadas as respostas para códigos executados;
2. **Ambiente de memória (Environment):** é o cérebro do R, onde ficam registrados os objetos que ele reconhece.
3. A área de **Arquivos (Files)**, **Gráficos (Plots)**, **Pacotes (Packages)**, **Ajuda (Help)**, **Visualização (Viewer)** e **Apresentação (Presentation)**: mostram, respectivamente, os arquivos do diretório onde estão seus arquivos no computador, os gráficos, os pacotes, a ajuda, a janela de visualização e a apresentação.

A figura abaixo identifica cada uma dessas áreas:

Digitaremos os códigos da linguagem R, em um arquivo que chamamos de **script**. Para abrir um arquivo do tipo script R, faça:

1. Acesse a opção **File** no menu principal do RStudio;
2. Escolha a opção **New File**;
3. E depois a opção **R Script**.

Assim, na tela da IDE RStudio aparecerá uma nova área, que é a área do arquivo script, como mostra a figura.

Observe que o arquivo está sem um nome (**Untitled1**, sem título). Salve o arquivo atribuindo-lhe um nome adequado. Para isso, no menu principal, escolha *File*, depois *Save*.

Dica: O ideal seria criar um **Projeto**. Veja a opção *File > New Project*.




Figure 7.1: Figura: Identificação das áreas do RStudio




Figure 7.2: Figura: Como abrir um novo arquivo de script R




Figure 7.3: Figura: A área de script na tela do RStudio

Chapter 8

Primeiros exercícios no R

Nos capítulos 6 e 7 vimos sobre o ambiente computacional (computador ou nuvem) e identificamos as 4 áreas da tela da interface do RStudio: **console**, **ambiente de memória**, **arquivos**, **gráficos**, **etc.** e **script**, assim estamos prontos para escrever alguns códigos e executá-los a partir da área de script.

Atenção: TODOS os códigos serão digitados no arquivo de script, seguindo uma sequência lógica de passos, ou seja, escreveremos um roteiro (*script*), como se fosse uma receita de bolo, isso é o que o pessoal da computação chama de algoritmo.

8.1 Exemplo 1

- Observe o código escrito na linha 1 do arquivo de script e o botão **Run** (primeira seta verde):




Figure 8.1: Figura: Primeiro exemplo de código R

- A sequência de caracteres `<-` é o símbolo de atribuição no R.
Pressionando as teclas ALT e - (menos) simultaneamente cria no script o sinal de atribuição.
- O código significa que criamos um objeto chamado **x** e atribuímos a esse objeto o valor 2.
- No entanto, o R ainda não sabe que o valor de **x** é igual a 2!
- Para registrar essa informação na memória do R, devemos executar essa linha.
Para executar uma linha posicione o cursor na linha, e clique no botão **Run**
Observe sempre o ambiente de memória (bem como o console) quando executar uma linha.

8.2 Exemplo 2

Execute o seguinte código no R.

```
idades <- c( 23, 18, 17, 25, 21, 19, 22, 24, 19, 19 )
```

- Esse código significa que foi criado um objeto chamado **idades** que armazena 10 valores: 23, 18, 17, 25, 21, 19, 22, 24, 19, 19, diferentemente do exemplo 1 em que **x** armazenava somente o valor 2.




Figure 8.2: Figura: O objeto x é registrado na memória do R, armazenando o valor igual a 2

- Isso foi possível pois usamos a função `c( )`.
- observe que os valores foram colocados dentro dos parênteses da função `c( )`

Com função `c( )` podemos **combinar** vários valores em um objeto, esse objeto recebe o nome de vetor ou lista.

8.3 Exemplo 3

Observe nesse código as funções:

- `max( )`
- `min( )`
- `range( )`
- `mean( )`
- `sd( )`

```
# criando o vetor idades
idades <- c( 23, 18, 17, 25, 21, 19, 22, 24, 19, 19 )
```

```
# maior valor
# função max( )
max(idades)
```

```
## [1] 25
```

```
# menor valor
# função min( )
min(idades)
```

```
## [1] 17
```

```
# faixa de valores
# função range( )
range(idades)
```

```
## [1] 17 25
```

```
# média (mean)
# função mean( )
mean(idades)
```


```
## [1] 20.7
```

```
# desvio padrão (standard deviation)
# função sd()
sd(idades)
```

```
## [1] 2.710064
```

Copie o código e cole no seu arquivo script, selecione todo conteúdo (CTRL+A) e execute todo o código de uma única vez.

- Observe que as respostas apareceram no **console**, conforme mostrado na figura abaixo:



The screenshot shows an R console window with the following content:

```
R 4.3.0 · /cloud/project/
> # criando o vetor idades
> idades <- c( 23, 18, 17, 25, 21, 19, 22, 24, 19, 19 )
>
> # maior valor
> # função max( )
> max(idades)
[1] 25
>
> # menor valor
> # função min( )
> min(idades)
[1] 17
>
> # faixa de valores
> # função range( )
> range(idades)
[1] 17 25
>
> # média (mean)
> # função mean( )
> mean(idades)
[1] 20.7
>
> # desvio padrão (standard deviation)
> # função sd()
> sd(idades)
[1] 2.710064
>
```

Figure 8.3: Figura: As respostas do código aparecem no console

O símbolo # é o símbolo de comentário, isso significa que podemos escrever qualquer texto diferente do que o R sabe interpretar, e mesmo executando o código nenhum erro acontece!

IMPORTANTE: é uma boa prática comentar os trechos de códigos para deixar documentado qual é o objetivo do código.

Chapter 9

Tipos de Variáveis

As variáveis podem ser classificadas de acordo com sua natureza:

9.1 Variáveis Quantitativas

Expressam **quantidade** e podem ser divididas em:

- **Discreta:** Assume valores inteiros (contagem).
 - *Exemplo:* O número de filhos de uma pessoa. Você pode contar 0, 1, 2, 3 filhos, mas não pode ter 2,5 filhos.
- **Contínua:** Assume qualquer valor dentro de um intervalo específico (mensuração).
 - *Exemplo:* A altura de uma pessoa, que pode ser 1,70 m, 1,71 m, 1,711 m, e assim por diante, com infinitas possibilidades entre os valores.

9.2 Variáveis Qualitativas

Expressam **qualidade** e são representadas por **categorias** ou **rótulos**. São subdivididas em:

- **Nominal:** Categorias que não podem ser ordenadas.
 - *Exemplo:* O tipo de fruta que você prefere, como maçã, banana, laranja. Não faz sentido ordenar essas categorias de maneira que uma seja “maior” que a outra.
- **Ordinal:** Categorias que podem ser ordenadas, com uma graduação entre elas.
 - *Exemplo:* Níveis de satisfação de um serviço, como “satisfeito”, “neutro” e “insatisfeito”. Aqui, existe uma ordem em que “satisfeito” é maior que “neutro”, e “neutro” é maior que “insatisfeito”.

Uma aplicação comum das variáveis ordinais é a **Escala Likert**, que é amplamente utilizada em pesquisas de opinião para medir atitudes ou percepções. A escala Likert geralmente apresenta uma série de afirmativas, e o participante deve indicar seu nível de concordância com cada uma delas, com respostas em uma sequência ordenada.

Exemplo: Em uma pesquisa de satisfação de clientes, a pergunta poderia ser: “Concordo que a alimentação oferecida pelo hospital foi satisfatória.” As opções de resposta poderiam ser:

1. **Discordo totalmente**
2. **Discordo parcialmente**
3. **Neutro**
4. **Concordo parcialmente**
5. **Concordo totalmente**

Essas respostas formam uma escala ordinal, pois a ordem das categorias reflete um aumento no nível de concordância, mas as diferenças entre elas não são necessariamente iguais.

Dica: Veja o vídeo do Prof. Heitor no **Canal Pesquise**: Assista aqui.

9.3 Aplicação das Variáveis em Estatística

A natureza da variável influencia o tipo de procedimento estatístico que será utilizado. Exemplos:

9.3.1 Estatística Descritiva:

- **Variáveis Qualitativas:** São representadas por sua **frequência absoluta** ou **percentual**.
 - *Exemplo:* Em uma pesquisa de preferência de frutas, pode-se dizer que 40% das pessoas escolheram maçã, 35% escolheram banana, e 25% escolheram laranja.
- **Variáveis Quantitativas:** São representadas por **medidas resumo**, como **média** e **desvio padrão**.
 - *Exemplo:* Se você calcular a média de altura de um grupo de pessoas, e o desvio padrão indicar que a altura das pessoas varia em torno de 5 cm da média.

9.3.2 Estatística Inferencial:

- **Teste Qui-Quadrado:** Usado para verificar se há associação entre as categorias de duas variáveis qualitativas.
 - *Exemplo:* Um teste Qui-Quadrado poderia ser utilizado para verificar se a escolha de fruta (maçã, banana, laranja) tem relação com o sexo (masculino, feminino) dos participantes.
- **Teste de Correlação de Pearson:** Mede a força da correlação linear entre duas variáveis quantitativas.
 - *Exemplo:* O teste de Pearson poderia ser utilizado para verificar se existe uma relação entre a altura e o peso das pessoas. Quanto maior a altura, maior o peso? Esse teste nos diria a força dessa relação.

9.4 Atividade 3

Leia o artigo *Estado nutricional, tempo de internação e mortalidade em pacientes submetidos à cirurgia cardíaca em um hospital na cidade de Maceió*

Disponível em: RASBRAN, Revista da Associação Brasileira de Nutrição, 2023

Acesse também o portal: RASBRAN - Revista da Associação Brasileira de Nutrição.

9.4.1 Análise das Tabelas

- **Tabela 1 - Características clínicas dos pacientes submetidos à cirurgia cardíaca:** Esta tabela apresenta as características da amostra analisada na pesquisa.
 - **Tarefa:** Classifique as variáveis (características) em **qualitativas** e **quantitativas**.
 - **Observação:** Verifique como as variáveis foram resumidas. Elas foram apresentadas em **porcentagens**? Ou foram calculadas medidas de **média** e **desvio padrão**?
- **Tabela 2 - Associação entre estado nutricional, sexo, idade e tempo de internação hospitalar entre os pacientes submetidos à cirurgia cardíaca**
- **Tabela 3 - Associação entre evolução clínica, sexo, idade, tempo de internação hospitalar e estado nutricional entre os pacientes submetidos à cirurgia cardíaca:** Estas tabelas mostram os resultados de um **teste de hipótese** (parte da estatística inferencial).
 - **Tarefa:** Identifique qual **teste estatístico** foi aplicado.
 - **Objetivo:** Qual é o objetivo deste teste?

Chapter 10

Estatística Descritiva

A estatística descritiva permite **resumir, organizar e interpretar** dados de forma clara e objetiva. Para isso, utilizamos **medidas de tendência central, medidas de dispersão e medidas relativas de variabilidade**.

Todos os exemplos de redação (“Como reportar”) deste capítulo foram calculados a partir do vetor `Batimentos` da Atividade 4, no final do capítulo. Assim você pode refazer cada conta no R e conferir os valores.

10.1 Medidas de Tendência Central (ou Posição)

10.1.1 Média

- **Definição:** Soma de todos os valores dividida pelo número de observações.
- **Interpretação:** Representa o valor médio ou típico do conjunto de dados.
- **Como reportar:**

A média dos batimentos cardíacos foi de 58,5 bpm, indicando o valor médio da amostra analisada.

10.1.2 Mediana

- **Definição:** Valor central de um conjunto ordenado de dados.
- **Interpretação:** Divide o conjunto de dados ao meio, sendo útil quando há valores extremos (outliers).
- **Como reportar:**

A mediana dos batimentos foi de 60,5 bpm, indicando que 50% dos indivíduos apresentaram valores abaixo ou iguais a esse valor.

10.1.3 Quartis

- **Definição:** Q1 (primeiro quartil) e Q3 (terceiro quartil) representam os valores que dividem os 25% e os 75% inferiores dos dados, respectivamente.
- **Interpretação:** Ajudam a entender a distribuição dos dados e identificar a dispersão em torno da mediana.
- **Como reportar:**

O primeiro e o terceiro quartis foram 54,0 bpm e 64,8 bpm, respectivamente, revelando que 50% dos batimentos ficaram entre esses dois valores.

10.1.4 Moda

- **Definição:** Valor mais frequente do conjunto de dados.
- **Interpretação:** Indica o valor mais comum, embora possa não existir ou haver mais de uma moda.
- **Como reportar:**

A amostra é multimodal: os valores 39, 54, 62 e 75 bpm ocorreram duas vezes cada, e nenhum outro se repetiu.

Observação: este é justamente um caso em que a moda ajuda pouco a resumir os dados — situação comum em amostras pequenas de variáveis contínuas.

Observação importante:

- **Média e desvio padrão** são medidas que devem ser usadas juntas, especialmente para dados simétricos (distribuição simétrica) e sem valores extremos. - **Mediana e quartis** formam outro conjunto de medidas, mais apropriado quando há assimetria ou presença de outliers.

Sugestão de vídeo: Canal Pesquise - Tendência Central

10.2 Medidas de Dispersão (ou Variabilidade)

10.2.1 Amplitude

- **Definição:** Diferença entre o maior e o menor valor.
- **Interpretação:** Indica o intervalo total em que os dados variam.
- **Como reportar:**

A amplitude foi de 36 bpm, com valores variando de 39 a 75 bpm.

10.2.2 Variância

- **Definição:** Média dos quadrados das diferenças entre os valores e a média.
- **Interpretação:** Mede a dispersão, mas sua unidade é o quadrado da unidade original.
- **Como reportar:**

A variância foi de 120,4 bpm², indicando a variabilidade dos batimentos em relação à média.

Observação:

A unidade da variância é expressa ao quadrado da unidade original dos dados (por exemplo, bpm² no caso de batimentos por minuto), o que pode dificultar sua interpretação direta.

Por isso, costuma-se utilizar o **desvio padrão**, que tem a **mesma unidade dos dados originais** e fornece uma noção mais intuitiva da dispersão dos valores em torno da média.

10.2.3 Desvio padrão (DP)

- **Definição:** Raiz quadrada da variância.
- **Interpretação:** Expressa, em média, o quanto os dados se afastam da média.
- **Como reportar:**

O desvio padrão foi de 11,0 bpm, o que indica que, em média, os batimentos cardíacos dos indivíduos da amostra se afastam cerca de 11,0 bpm da média.

10.2.4 Amplitude interquartil (IQR)

- **Definição:** Diferença entre o terceiro e o primeiro quartis ($Q3 - Q1$).
- **Interpretação:** Indica a dispersão dos 50% centrais dos dados.
- **Como reportar:**

A amplitude interquartil foi de 10,8 bpm, mostrando a dispersão dos 50% centrais dos dados.

Sugestão de vídeo: Canal Pesquise - Variabilidade

10.3 Medida Relativa de Variabilidade

10.3.1 Coeficiente de Variação (CV)

- **Definição:** Quociente entre o desvio padrão e a média, multiplicado por 100.
- **Interpretação:** Expressa a variabilidade dos dados em relação à média, permitindo comparar conjuntos com unidades diferentes.
- **Como reportar:**

O coeficiente de variação foi de 18,8%, indicando que os dados são relativamente homogêneos.

Observação:

Um CV inferior a 25% geralmente indica homogeneidade; valores muito altos indicam alta variabilidade.

10.4 Apresentação dos Resultados

Uma maneira eficiente de apresentar estatísticas descritivas é organizar as variáveis em linhas, facilitando a visualização dos principais parâmetros de cada variável estudada. Veja abaixo uma sugestão de tabela para esse formato:

Variável	n	Média $\pm$ DP	Mediana (Q1; Q3)	Mínimo	Máximo
Idade (anos)	98	24,5 $\pm$ 4,2	24,0 (21,0; 28,0)	18	35
IMC (kg/m ²)	98	22,3 $\pm$ 3,1	21,9 (20,3; 23,7)	17,0	31,5
Pressão Sistólica	98	118,5 $\pm$ 13,0	120 (110; 128)	90	145
Pressão Diastólica	98	76,2 $\pm$ 9,1	76 (70; 82)	60	98

Reportar uma medida de tendência central (como média ou mediana) junto com uma medida de dispersão (como desvio padrão, intervalo interquartil ou amplitude) é fundamental porque, isoladamente, a tendência central não fornece informações suficientes sobre o conjunto de dados.

Para variáveis qualitativas, a tabela pode ser organizada assim:

Variável	Categoria	n	%
Sexo	Masculino	52	53,1%
	Feminino	46	46,9%
Tabagismo	Sim	18	18,4%
	Não	80	81,6%

Essas tabelas permitem uma apresentação clara e objetiva das principais características da amostra analisada.

10.5 Funções no R

Com um vetor `x` contendo os dados, utilize:

Medida	Código R
Média	<code>mean(x)</code>
Mediana	<code>median(x)</code>
Primeiro quartil (Q1)	<code>quantile(x, 0.25)</code>
Terceiro quartil (Q3)	<code>quantile(x, 0.75)</code>
Moda	<code>sort(table(x), decreasing = TRUE)</code>
Menor valor	<code>min(x)</code>
Maior valor	<code>max(x)</code>
Resumo geral	<code>summary(x)</code>
Amplitude	<code>range(x)</code>
Variância	<code>var(x)</code>
Desvio padrão	<code>sd(x)</code>
Amplitude interquartil	<code>IQR(x)</code>
Coefficiente de variação	<code>sd(x)/mean(x)*100</code>

Sobre a moda: o R não tem uma função pronta para ela. O comando acima devolve a tabela de frequências ordenada da maior para a menor — a moda é o valor (ou os valores) no topo dessa tabela. Lembre-se de que um conjunto pode não ter moda, ou ter mais de uma.

Calcular é importante, mas interpretar corretamente é essencial. Ao elaborar suas interpretações, descreva o que os números revelam sobre o fenômeno analisado.

10.6 Atividade 4

Considere o objeto **Batimentos**, que é uma amostra de batimentos cardíacos de 20 homens.

```
Batimentos <- c(62, 55, 56, 46, 75, 67, 62, 75, 60, 54, 69, 63, 39, 57, 40, 39, 64, 71, 61, 54)
```

- Obtenha as seguintes medidas:
 - Menor valor:
 - Maior valor:
 - Média:
 - Mediana:
 - Primeiro quartil:
 - Terceiro quartil:
 - Variância:
 - Desvio padrão:
 - Amplitude interquartil:
 - Coeficiente de variação:
- Escreva sobre o conjunto media e desvio padrão:

A média dos dados foi de X (unidade), com um desvio padrão de Y (unidade), indicando que os valores estão, em geral, relativamente próximos/espalhados em torno da média. O desvio padrão reflete a quantidade de variabilidade ou dispersão dos dados em relação à média, e neste caso, a dispersão é baixa/média/alta, dependendo do valor de Y.

- Escreva sobre conjunto mediana e quartis:

A mediana foi Z (unidade), e o intervalo interquartil (IQR), que representa a diferença entre o terceiro quartil (Q3) e o primeiro quartil (Q1), foi Q3 - Q1 (unidade). Isso indica que 50% dos dados estão concentrados nesse intervalo.

- Escreva sobre o coeficiente de variação:

O coeficiente de variação (CV) foi calculado como $X\%$, o que reflete a dispersão relativa dos dados em relação à média. Valores mais baixos de CV indicam que os dados estão mais concentrados em torno da média, enquanto valores mais altos indicam uma maior dispersão.

- Acrescente mais uma amostra com valor de batimento igual a 120, recalcule as medidas acima. Qual conjunto você consideraria mais adequado para resumir sua amostra, na presença desse valor discrepante (*outlier*)? A média (DP) ou mediana (1o.Q ; 3o.Q)? Explique.

Chapter 11

Importando banco de dados

Até aqui, todos os dados que usamos foram digitados por nós mesmos, direto no script, como no vetor `idades` ou no `Batimentos`. Isso funciona para dez ou vinte valores. Na prática, os dados de uma pesquisa vêm em um **arquivo**, com centenas ou milhares de linhas, e o nosso trabalho passa a ser **trazer esse arquivo para dentro do R**. É disso que trata este capítulo.

Os dois tipos de arquivo mais comuns são:

- Arquivo do tipo Excel (xls ou xlsx)
- Arquivo de texto separado por vírgulas (csv, de *comma-separated values*)

Muitos dados de pesquisa são hoje publicados livremente, para que qualquer pessoa possa conferir os resultados de um estudo ou fazer perguntas novas com o mesmo material. Esse movimento se chama **ciência aberta**, e é graças a ele que você consegue fazer um bom trabalho sem precisar coletar dados próprios. Algumas fontes para começar:

- DataSus: <https://datasus.saude.gov.br/transferencia-de-arquivos>
- OMS: <https://www.who.int/data/collections>
- Kaggle: <https://www.kaggle.com/datasets>

O assunto é grande e rende bons trabalhos, então tem dois capítulos só para ele no fim do livro: um sobre **ciência aberta** e onde encontrar dados e artigos abertos, e outro sobre os **dados do DATASUS**, que é a principal fonte brasileira para quem é da área da saúde.

Os bancos usados neste livro ficam reunidos em <https://ana-mat-br.github.io/dados/>. Cada capítulo apresenta o endereço do arquivo que vai usar, para você baixar ou ler direto pelo R.

11.1 Antes de tudo: onde o arquivo mora

Esta seção parece boba, mas é onde quase todo mundo trava na primeira vez. Leia com calma.

Quando você baixa um arquivo da internet, ele **não fica solto no computador**: ele é guardado dentro de uma **pasta**. Na maioria dos computadores, essa pasta se chama **Downloads**, e é para lá que tudo vai por padrão, sem perguntar nada.

O R, por sua vez, não adivinha onde as coisas estão. Suponha que você baixou o arquivo `mcdonald.csv` e escreveu apenas isto:

```
mcdonald <- read_csv("mcdonald.csv")
```

O R vai procurar esse arquivo em **um único lugar**: a pasta que ele considera a sua, naquele momento. Se o arquivo estiver na Downloads e essa não for a pasta em que o R está, ele não encontra e devolve um erro — mesmo que o arquivo esteja ali, a dois cliques de distância.

Você precisa dizer onde o arquivo está, e é só isso que aquelas linhas de código cheias de barras e aspas estão fazendo: soletrando o endereço da pasta para o R.

11.1.1 Como é um caminho por extenso

Vale ver um de verdade, escrito inteiro. Em um Mac, o `mcdonald.csv` recém-baixado costuma estar aqui:

```
/Users/anafernandes/Downloads/mcdonald.csv
```

E no Windows, assim:

```
C:/Users/anafernandes/Downloads/mcdonald.csv
```

Leia da esquerda para a direita, e cada barra vira a palavra “dentro de”:

Pedago	O que é
/Users (ou C:/Users)	a parte do disco onde ficam as pastas das pessoas
anafernandes	a sua pasta pessoal, com o nome do seu usuário
Downloads	a pasta para onde o navegador manda tudo
mcdonald.csv	finalmente, o arquivo

Ou seja: *dentro de Users, dentro de anafernandes, dentro de Downloads, o arquivo mcdonald.csv*. É comprido, mas não tem mistério nenhum: é o mesmo caminho que você percorre clicando pasta por pasta, só que escrito em uma linha.

No Windows, cuidado com a barra. O Explorer mostra o caminho com barra invertida (`C:\Users\...`), mas o R não aceita essa barra sozinha. Troque todas por barra normal (`C:/Users/...`), ou duplique-as (`C:\\Users\\...`). É um detalhe bobo que gera muito erro.

A boa notícia é que existem quatro formas de dizer isso ao R, e **três delas não exigem que você entenda de pastas**. Vamos ver as quatro, da mais simples para a mais técnica:

1. **Pelo botão do RStudio**, apontando o arquivo na tela.
2. **Pelo endereço da internet**, sem nem baixar o arquivo.
3. **Escolhendo o arquivo em uma janela**, que o próprio R abre para você.
4. **Escrevendo o caminho da pasta**, que é o que você vai usar quando os dados forem seus.

Comece pela primeira. As outras fazem mais sentido depois que você viu uma funcionar.

11.2 Forma 1: pelo botão Import Dataset

Esta é a forma mais segura para começar, porque você **navega até o arquivo com o mouse**, do mesmo jeito que faz para abrir uma foto ou um documento. E tem um bônus: no fim, o RStudio **escreve o código para você**.

1. Faça o *download* do banco de dados **mcdonald.csv**, clicando aqui: <https://ana-mat-br.github.io/dados/mcdonald.csv> (fonte original: <https://www.kaggle.com/datasets/mcdonalds/nutrition-facts>). Repare em qual pasta o seu navegador salvou o arquivo — quase sempre é a **Downloads**.
2. Na área de ambiente de memória, localize **Import Dataset**, ao clicar nessa opção você terá o seguinte:
 - Como queremos importar um arquivo csv, a melhor opção é a segunda **From Text (readr)**
 - **readr** é uma pacote do R que faz a leitura de arquivo csv (se o pacote ainda não estiver instalado no seu computador, o R fará a instalação, se você concordar!)
3. Clicando na opção **From Text (readr)**, no botão **browser** indique onde (no seu computador) está localizado o arquivo a ser importado. É aqui que você navega até a pasta Downloads e clica no arquivo. A seguinte tela será apresentada:
 - No quadro **Data Preview**, temos uma “prévia” com os nomes da variáveis, seus tipos computacionais e os primeiros valores que estão armazenados no banco de dados.




Figure 11.1: Figura: Importando banco de dados




Figure 11.2: Figura: Prévia dos dados

- No quadro **Import Options** temos as opções de importação, fique atento ao **Name** do seu banco de dados, geralmente usamos nomes sem espaços ou caracteres especiais (', ~ ou ç), é até permitido usar alguns desses caracteres especiais, mas evite.
 - Ainda no quadro **Import Options**, observe que a opção **Open Data Viewer** está marcada, isso significa que ao importar o banco de dados, o arquivo de banco de dados será aberto pelo RStudio. Caso esteja trabalhando com bancos com muitos dados (como os bancos do dataSUS), talvez seja melhor desmarcar essa opção para não sobrecarregar o processamento do seu computador.
 - O quadro **Code Preview** mostra como é a importação (leitura) do banco de dados via código. É interessante copiar esse trecho de código para o arquivo de script.
4. Clique no botão **Import** e observe que no ambiente de memória será criado o objeto do tipo **Data** com o nome do banco de dados que foi importado.




Figure 11.3: Figura: Import dataset

- Observe que esse objeto do tipo **Data** é diferente dos objetos do tipo **Values** que vimos nos exemplos iniciais.
- Ao clicar no ícone ao lado do nome do objeto, temos acesso aos nomes e tipos computacionais das variáveis, e ao clicar sobre o nome do objeto, o banco será aberto!

Olhe de novo para o quadro Code Preview antes de clicar em Import. Aquele texto esquisito, cheio de barras, é o **caminho** do arquivo: é o endereço da pasta onde ele está, escrito do jeito que o computador entende. O botão fez por você exatamente o que você faria à mão. Copie esse código para o seu script: da próxima vez, basta executá-lo, sem precisar repetir os cliques.

11.3 Forma 2: sem baixar nada

Se o arquivo está na internet e você sabe o endereço dele, o R busca sozinho. Não precisa baixar, não precisa saber de pasta nenhuma, não precisa de caminho. Você copia o endereço e coloca entre aspas, no lugar do nome do arquivo:

```
library(readr)
nascimentos <- read_csv("https://ana-mat-br.github.io/dados/nascimentos.csv")
nrow(nascimentos)
```

```
## [1] 3602
```

Pronto: o banco está na memória do R. Esta é a forma mais rápida de todas, e é a que usaremos nos exemplos deste livro, justamente para que você possa copiar o código e executá-lo sem nenhum preparo.

A única exigência é estar conectado à internet. Se a conexão cair, o R não encontra o arquivo.

11.4 Forma 3: escolhendo o arquivo na tela

Existe um meio-termo entre o botão e o caminho escrito: a função `file.choose()`. Ela abre a mesma janelinha de procurar arquivo que você já conhece, e devolve o caminho para o R automaticamente.

```
# a janela de escolher arquivo vai abrir; navegue até o arquivo e clique nele
mcdonald <- read_csv(file.choose())
```

É prática e não exige saber onde nada está. A desvantagem é que ela **pergunta toda vez**: se você fechar o RStudio e voltar amanhã, terá que procurar o arquivo de novo. Por isso ela serve para um teste rápido, mas não para um trabalho que você vai repetir.

11.5 Forma 4: escrevendo o caminho

Esta é a forma que você vai usar quando os dados forem **seus**, porque os seus dados não vão estar em endereço nenhum da internet. E é a que exige entender a ideia de pasta — mas o RStudio tem um recurso que resolve quase todo o problema.

11.5.1 O Projeto do RStudio

Um **Projeto** é simplesmente **uma pasta que o RStudio considera a sua casa**. Tudo o que estiver dentro dela, o R acha sozinho, sem você precisar escrever caminho nenhum.

Para criar um: no menu, **File New Project New Directory New Project**, escolha um nome (por exemplo, **estatistica**) e um lugar para ele ficar. O RStudio cria a pasta e abre o projeto. Você vai ver o nome dele no **canto superior direito** da tela — se estiver escrito ali, você está dentro do projeto.

Agora, se você **arrastar o arquivo mcdonald.csv para dentro dessa pasta**, o R passa a encontrá-lo só pelo nome:

```
mcdonald <- read_csv("mcdonald.csv")
```

Sem barras, sem endereço, sem nada. É por isso que vale a pena criar o Projeto logo no começo: ele transforma o problema de “onde está o arquivo” em “está aqui do lado”.

Se você quiser organizar melhor e criar uma subpasta chamada **dados** dentro do projeto, o nome dela entra antes, separado por uma barra:

```
mcdonald <- read_csv("dados/mcdonald.csv")
```

A barra quer dizer “dentro de”. Leia como: *dentro da pasta dados, o arquivo mcdonald.csv*.

Se aparecer o erro **does not exist in current working directory**, o R não achou o arquivo. Na ordem, confira: (1) o nome do projeto aparece no canto superior direito do RStudio? (2) o arquivo está mesmo dentro da pasta do projeto? (3) o nome está escrito exatamente igual, inclusive maiúsculas e a terminação **.csv**? Quase sempre é uma dessas três.

11.6 Importando um banco xls

Na área de ambiente de memória, localize **Import Dataset**, ao clicar sobre essa opção, escolha **From Excel...**

- Se for a primeira vez que você estiver importando um arquivo Excel, pode ser necessária a instalação do pacote que fornece a biblioteca que tem a função de leitura de arquivo xls (**readxl**)! O RStudio mostrará um aviso parecido com este:

11.7 Exemplo 1

Como obter a média da variável **Calories** que é uma coluna do objeto **mcdonald**, que por sua vez, é um objeto do tipo **Data**?




Figure 11.4: Figura: Importando banco de dados




Figure 11.5: Figura: Aviso para instalação de pacote

```
# Usamos o operador $
# Para calcular a média precisamos informar para função:
# mean( NOME DO BANCO $ NOME DA COLUNA ):
mean(mcdonald$Calories)
```

11.8 Exemplo 2

Como armazenar os valores de uma variável (coluna), em um objeto do tipo **Values** e depois calcular a média?

```
# Uso o operador <-
# Criamos o objeto
caloria <- mcdonald$Calories
# Agora podemos usar o objeto que criamos, por exemplo para calcular a média e o desvio padrão
mean(caloria)
sd(caloria)
```

11.9 Exemplo 3

O que acontece se usamos a função **summary()** para o objeto **mcdonald**, sem usar o operador, isto é sem indicar uma variável?

```
# No console será mostrado o resumo de todas as variáveis do banco!
summary(mcdonald)
```

Essa forma de obter os resultados não é a melhor forma, vamos **instalar um pacote** para obter os resultados em uma tabela bem formatada que podemos copiar e colar diretamente para um editor de texto.

11.10 Exemplo 4: um banco da sua área

Os exemplos anteriores usaram o **mcdonald**, que serve bem para aprender o mecanismo da importação. Agora vamos repetir os mesmos três passos — importar, olhar uma variável, resumir o banco — em um banco da **sua** área.

Repare que todos eles têm **dados faltantes**, como qualquer coleta real. Vamos aprender a lidar com isso já aqui.

11.10.1 Onde estão estes bancos

Banco	Área	Endereço
nascimentos.csv	Medicina	https://ana-mat-br.github.io/dados/nascimentos.csv
saude-mental.csv	Psicologia	https://ana-mat-br.github.io/dados/saude-mental.csv
aptidao-fisica.csv	Educação Física	https://ana-mat-br.github.io/dados/aptidao-fisica.csv

Nos exemplos abaixo usamos a **Forma 2**, o endereço da internet, para que você possa copiar o código e executar na hora. Se preferir baixar o arquivo e usar o botão **Import Dataset**, clique no endereço da tabela e siga a **Forma 1** — o resultado é exatamente o mesmo.

11.10.2 Medicina: nascidos vivos em Uberaba

O arquivo `nascimentos.csv` traz os **3.602 nascimentos registrados em Uberaba em 2022**, extraídos do SINASC, o Sistema de Informações sobre Nascidos Vivos do DATASUS. São dados reais e públicos.

```
library(readr)
nascimentos <- read_csv("https://ana-mat-br.github.io/dados/nascimentos.csv")

# quantas linhas e colunas?
dim(nascimentos)

## [1] 3602  10

# média do peso ao nascer, em gramas
mean(nascimentos$peso_g)

## [1] 3095.784
```

As variáveis são: `peso_g` (peso ao nascer em gramas), `idade_mae`, `sem_gestacao` (semanas de gestação), `consultas_pn` (consultas de pré-natal), `apgar5`, `sexo`, `parto` (vaginal ou cesáreo), `escol_mae` (escolaridade da mãe) e `raca_mae`.

11.10.3 Psicologia: saúde mental de universitários

O arquivo `saude-mental.csv` traz escores de 320 universitários em três instrumentos que você viu no capítulo de conceitos fundamentais: **PSS-10** (estresse percebido, de 0 a 40), **GAD-7** (ansiedade, de 0 a 21) e **WHO-5** (bem-estar, de 0 a 100).

```
saude <- read_csv("https://ana-mat-br.github.io/dados/saude-mental.csv")
dim(saude)

## [1] 320  9

# média do escore de estresse percebido
mean(saude$pss10)

## [1] 19.59062
```

As variáveis são: `pss10`, `gad7`, `who5`, `horas_sono`, `curso`, `sexo`, `idade` e `ansiedade` (alta ou baixa, pelo ponto de corte do GAD-7).

Atenção: este banco é **simulado**. Ele não vem de uma coleta real: foi gerado por computador com médias e desvios plausíveis para universitários brasileiros. O script que o gera está aqui: **gera-bancos-simulados.R**. Usamos simulação aqui porque bancos reais com escalas psicométricas raramente são públicos, e porque as grandes pesquisas nacionais que teriam esses dados (como a PNS) exigem técnicas de amostragem complexa que estão além do nosso escopo.

11.10.4 Educação Física: aptidão física e atividade semanal

O arquivo `aptidao-fisica.csv` traz 280 participantes com minutos semanais de atividade física, IMC, percentual de gordura e VO máximo estimado.

```
aptidao <- read_csv("https://ana-mat-br.github.io/dados/aptidao-fisica.csv")
dim(aptidao)

## [1] 280  9

# mediana de minutos de atividade física por semana
median(aptidao$min_af_semana)

## [1] 161
```

As variáveis são: `min_af_semana`, `vo2max`, `imc`, `perc_gordura`, `modalidade`, `sexo`, `idade` e `ativo` (sim ou não, pelo critério de 150 minutos semanais da OMS).

Assim como o banco de Psicologia, este é **simulado**, e gerado pelo mesmo script.

11.10.5 E quando aparece NA?

Experimente calcular a média de uma variável que tenha dados faltantes:

```
# no banco de nascimentos, 135 registros não têm o número de consultas
mean(nascimentos$consultas_pn)
```

```
## [1] NA
```

O resultado é NA, e não um número. O R está sendo honesto: ele não sabe quanto vale a média se alguns valores são desconhecidos. Para calcular a média apenas com quem tem informação, use o argumento `na.rm = TRUE` (de *remove NA*):

```
mean(nascimentos$consultas_pn, na.rm = TRUE)
```

```
## [1] 8.024517
```

```
# quantos valores faltam em cada variável?
colSums(is.na(nascimentos))
```

```
##      peso_g      idade_mae sem_gestacao consultas_pn      apgar5      sexo
##      0          0          2          135          2          0
##      parto      escol_mae      raca_mae      baixo_peso
##      0          0          366          0
```

Isto vale para o resto do livro. As funções `mean()`, `median()`, `sd()`, `var()`, `min()`, `max()` e `quantile()` todas devolvem NA se houver um único valor faltante, e todas aceitam `na.rm = TRUE`. Antes de qualquer análise, vale rodar `colSums(is.na(seu_banco))` para saber com o que você está lidando — e **relatar quantos casos foram perdidos** quando escrever seus resultados.

Chapter 12

Instalando pacotes

Quando instalamos nosso ambiente computacional R e RStudio, instalamos uma versão básica, onde apenas os recursos básicos do R estão disponíveis, o pacote básico (**base**) do R.

Os pacotes (**packages**) do R são compostos por uma biblioteca (**library**) que é um conjunto de funções. Por exemplo, do pacote **base** usamos as funções `min()`, `max()`, `mean()`, `median()`, `table()`, `var()`, `sd()`, `summary()`, etc.

Para ver a lista de funções que compõem a biblioteca do pacote base, execute o código:

```
library(help = "base")
```

Os pacotes são análogos aos aplicativos que instalamos nos nossos celulares, são módulos que agregam funcionalidades específicas. Ao longo das nossas atividades usaremos alguns desses pacotes.

Como nesse momento estamos interessados em otimizar o trabalho para realizar uma análise descritiva dos dados, então vamos instalar um pacote chamado **gtsummary** (<https://www.danielsjoberg.com/gtsummary/>).

O pacote **gtsummary** nos fornecerá uma tabela resumo de todo banco de dados, otimizando bastante nosso trabalho de resumir o banco de dados.

- IMPORTANTE 1: instalamos um pacote apenas uma vez (como um aplicativo no celular... a gente só refaz a instalação se o app *bugar*!)
- IMPORTANTE 2: toda vez precisamos carregar o pacote com as funções que queremos usar por meio da função `library()`

Veja o código:

```
# comando para instalar o pacote gtsummary
install.packages("gtsummary")

# comando para carregar a biblioteca de funções do gtsummary
library(gtsummary)

# a função que vamos usar para gerar uma tabela que resume os dados é
# tbl_summary
tbl_summary(mcdonald)
```

- Ao executar `tbl_summary(mcdonald)` a tabela de resultados será mostrada na área de arquivos, gráficos, pacotes... na aba **Viewer**, no quadrante abaixo do ambiente de memória.
- Essa tabela pode ser copiada e colada para o editor de texto que você utiliza para escrever seus trabalhos, claro essa tabela pode ser melhorada!
- Observe no rodapé da tabela a seguinte legenda **n (%)**; **Median (IQR)**, isso significa que para

- **variáveis qualitativas:** n é a contagem (frequência absoluta) e entre parênteses (%) é mostrado a porcentagem de cada categoria.
- **variáveis quantitativas:** Median é a mediana e entre parênteses (IQR - de Interquartile Range) estão o primeiro e terceiro quartil respectivamente.

12.1 Exemplo 1

Como mostrar o resultado com a média e desvio padrão?

```
# acrescente nos argumentos da função tbl_summary() a opção:
# statistic = list(all_continuous() ~ "{mean} ({sd})"
tbl_summary(
  mcdonald,
  statistic = list(all_continuous() ~ "{mean} ({sd})")
)
```

12.2 Exemplo 2

Como selecionar somente algumas variáveis do banco de dados?

```
# Precisamos do pacote tidyverse, tire o símbolo de # se precisar instalar!
# install.packages("tidyverse")

# ative tidyverse
library(tidyverse)

# vamos usar a função select() do pacote tidyverse
dadosSelecionados <- select (mcdonald, Cholesterol, Sodium, Carbohydrates)

# faça uma tabela para o objeto dadosSelecionados
tbl_summary(dadosSelecionados)
```

12.3 Exemplo 3

Algumas vezes é mais fácil excluir algumas variáveis, por exemplo queremos todas, menos **Item** e **Serving Size**

```
# vamos usar a função select() do pacote tidyverse e colocar o sinal de menos (-)
# antes dos nomes das variáveis que queremos excluir
# IMPORTANTE: Serving Size é um nome de variável com espaço
# então devemos referenciá-la entre aspas: `Serving Size`
dadosSelecionados2 <- select (mcdonald, -Item, -`Serving Size`)

# faça uma tabela para o objeto dadosSelecionados2
tbl_summary(dadosSelecionados2)
```

12.4 Exemplo 4

Como selecionar um conjunto de variáveis que estão em sequência, por exemplo, de **Carbohydrates** a **Cholesterol (% Daily Value)**

```
# vamos usar a função select() do pacote tidyverse e colocar o sinal de dois pontos (:)
# entre a primeira variável e a última da sequência
# IMPORTANTE: Cholesterol (% Daily Value) é um nome de variável com espaço
# então devemos referenciá-la entre aspas: `Cholesterol (% Daily Value)`
```

```
dadosSelecionados3 <- select (mcdonald, Carbohydrates:`Cholesterol (% Daily Value)`)  
  
# faça uma tabela para o objeto dadosSelecionados  
tbl_summary(dadosSelecionados3)
```

Saiba mais sobre o Tidyverse <https://www.tidyverse.org/packages/>

12.5 Atividade 5

Escolha outro banco de dados (você pode até criar um banco fictício!), faça uma tabela descritiva dos dados e escreva sobre os dados (um ou dois parágrafos), afinal, o nosso trabalho não é só obter a tabela, é dissertar sobre o que essa tabela revela sobre a amostra em estudo!

Chapter 13

Gráficos

Nesse link <https://r-graph-gallery.com/> estão algumas possibilidades de gráficos que podemos fazer usando o R. Para fazer gráficos mais elaborados (aparentemente mais atrativos visualmente) usamos o pacote **GGPlot2** <https://ggplot2.tidyverse.org/>.

Focaremos nossa atenção em dois gráficos específicos para variáveis quantitativas: **Histograma** e **Boxplot**, e nem faremos nada atrativo, usaremos o pacote básico do R que nos fornece as funções **hist()** e **boxplot()**, pois o nosso objetivo para esse momento é simplesmente estudar a importância desses gráficos.

O que a gente levaria um tempinho... é simplesmente assim em código R:

```
Batimentos <- c(62, 55, 56, 46, 75, 67, 62, 75, 60, 54, 69, 63, 39, 57, 40, 39, 64, 71, 61, 54, 120)



# Para fazer o Histograma de Batimentos
hist(Batimentos)

# Para fazer o Boxplot de Batimentos
boxplot(Batimentos)
```

Na área de gráficos (**Plots**), abaixo do ambiente de memória, serão mostrados os gráficos:

Histograma

Histogram of Batimentos



- Os gráficos mostram a informação batimentos de duas formas diferentes, mas elas estão relacionadas!
- Observe que eixo horizontal do histograma corresponde ao eixo vertical do boxplot

13.1 Histograma

O histograma é um gráfico usado para variáveis quantitativas contínuas.

O histograma pode nos dar uma noção do tipo de **distribuição de probabilidade** que os dados seguem.

A ideia desse gráfico é agrupar os dados em **classes** (cada barra do histograma é uma classe) e no eixo vertical tem-se a contagem (frequência) de quantos valores foram alocados em cada classe.

Para fazer a **leitura do histograma**:

- Identifique as classes no “eixo x”
- Identifique quantos elementos tem em cada classe no “eixo y”

Acredito que nesse exemplo, é fácil verificar:

- A segunda classe: 40 - 50 batimentos, que tem 1 elemento (verifique no objeto Batimentos)
Atenção: por padrão o R fecha as classes à direita, isto é, os intervalos são (30, 40], (40, 50], e assim por diante. Por isso o valor 40 conta na classe 30 - 40, e não na classe 40 - 50. O único elemento da segunda classe é o 46.
- A terceira classe: 50 - 60 batimentos, que tem 6 elementos
- Então, a **amplitude das classes** é igual a 10. Logo, a primeira classe é de 30 - 40.
- As classes 80 - 90; 90 - 100 e 100 - 110 não tiveram ocorrências!
- A classe 110-120 possui 1 elemento, que é aquele valor discrepante em relação aos demais valores.

Se não for fácil identificar as classes (eixo x) você pode usar o comando abaixo:

```
# Para obter as "quebras" de cada classe
hist(Batimentos)$breaks
```

Se não for fácil identificar as frequências (eixo y) você pode usar o comando abaixo:

```
# Para obter a frequência em cada classe
hist(Batimentos)$count
```

De fato, o que estamos lendo por meio do histograma é o que chamamos de **tabela de frequência**:


Classe	Frequência
30 - 40	3
40 - 50	1
50 - 60	6
60 - 70	7
70 - 80	3
80 - 90	0
90 - 100	0
100 - 110	0
110 - 120	1
<i>n</i>	21

- Por meio do histograma ou da tabela podemos concluir que a classe modal (moda) é a classe de 60 - 70 batimentos;
- A frequência foi apresentada em termos absolutos mas pode ser transformada em frequência percentual.
- Quando estamos aprendendo a fazer um histograma manualmente, primeiro construímos essa tabela de frequência, e para construí-la é necessário calcular o número ótimo de classes, uma das regras mais usadas é a Regra de Sturges (essa é a opção padrão do R).

Podemos usar o pacote básico R para melhorar a aparência desse gráfico.

```
hisBat <- hist(Batimentos,
               main = "Histograma",
               xlab = "Batimentos cardíacos",
               sub = "por classes",
               ylab = "Frequência absoluta",
               xlim = c(20, 120),
               ylim = c(0, 8),
               col = "lightgreen")
text(hisBat$mids, hisBat$count, labels=hisBat$count, adj = c(0.5,-0.5))
```

```
# adicionar linha para indicar a média
abline(v = mean(Batimentos),
      col = "red",
      lwd = 3)
```



13.2 Boxplot

Boxplot ou diagrama de caixa, é um gráfico que mostra as medidas: menor valor, primeiro quartil, mediana, terceiro quartil e máximo valor.

- Valores discrepantes (*outliers*) são detectados pelo boxplot. Veja a figura:




Figure 13.1: Figura: “Anatomia de um boxplot”

Essa figura foi retirada do site da Prof. Fernanda <https://fernandafperes.com.br/blog/interpretacao-boxplot/>


(uma excelente referência para estudar estatística!)

Geralmente eles são representados na vertical, mas também é comum a representação na horizontal.

```
# Para fazer o Boxplot de Batimentos na horizontal  
boxplot(Batimentos, horizontal = TRUE)
```


É uma forma de comparar dois grupos em relação a uma medida, por exemplo os batimentos cardíacos de um grupo de homens e de mulheres

```
# Geração de amostras simuladas  
set.seed(1)  
BatimentosMulheres <- rnorm(30, 70, 3)  
BatimentosHomens <- rnorm(30, 75, 8)  
# Boxplot para os dois grupos Homens e Mulheres  
boxplot(BatimentosHomens, BatimentosMulheres)
```




O boxplot também pode nos informar se uma distribuição de probabilidade é simétrica ou não. Analise os gráficos abaixo, veja a conexão entre histograma e boxplot.

Distribuição SIMÉTRICA



Distribuição ASSIMÉTRICA



13.3 Atividade 6

Para o banco de dados escolhido na atividade 5, faça gráficos como o histograma e boxplot, além disso, pesquise outras formas de fazer gráficos no R.

Chapter 14

Pacote ggplot

O `ggplot2` é um dos pacotes mais populares do R para a criação de gráficos estatísticos sofisticados e visualmente atraentes. Baseado no conceito da “Gramática dos Gráficos”, o `ggplot2` permite construir gráficos de maneira flexível e modular, combinando camadas (layers) de dados, geometrias, escalas e temas.

14.1 Principais Vantagens

- Produz gráficos de alta qualidade e personalizáveis.
- Permite adicionar camadas de informação facilmente.
- Suporta uma variedade de tipos de gráficos.

14.2 Exemplos de Gráficos Simples e Bonitos com ggplot2

Antes de começar, certifique-se de instalar e carregar o pacote:

```
install.packages("ggplot2")  
library(ggplot2)
```


Para ilustrar alguns gráficos utilizando o `ggplot2`, empregaremos o conjunto de dados *iris*, que já está disponível nativamente no R.

O *iris* é um dos bancos de dados mais clássicos e utilizados em estatística e aprendizado de máquina, trazendo informações sobre 150 flores de três espécies diferentes, com quatro variáveis quantitativas (comprimento e largura das sépalas e pétalas). Ele é amplamente utilizado para exemplos de análise exploratória de dados, classificação e visualização de padrões.


Além do *iris*, o R oferece outros conjuntos de dados nativos bastante úteis para exercícios e demonstrações em diversas áreas, como *mtcars* (carros), *ToothGrowth* (crescimento de dentes em cobaias), *sleep* (efeito de medicamentos no sono), *airquality* (qualidade do ar em Nova Iorque) e *CO2* (absorção de CO2 em plantas).

14.2.1 Gráfico de Dispersão (Scatterplot)

```
library(ggplot2)  
# Exemplo com o dataset iris  
ggplot(iris, aes(x = Sepal.Length, y = Sepal.Width, color = Species)) +  
  geom_point(size = 3, alpha = 0.7) +  
  theme_minimal() +  
  labs(title = "Gráfico de Dispersão: iris",  
        x = "Comprimento da Sépala",  
        y = "Largura da Sépala")
```




```
# Contagem das espécies no dataset iris
ggplot(iris, aes(x = Species, fill = Species)) +
  geom_bar() +
  theme_classic() +
  labs(title = "Gráfico de Barras: Contagem de Espécies",
       x = "Espécie",
       y = "Contagem")
```




```
# Distribuição do comprimento da sépala
ggplot(iris, aes(x = Sepal.Length, fill = Species)) +
  geom_histogram(binwidth = 0.3, color = "white", alpha = 0.7, position = "identity") +
  theme_light() +
  labs(title = "Histograma: Comprimento da Sépala",
       x = "Comprimento da Sépala",
       y = "Frequência")
```

Histograma: Comprimento da Sépala



```
# Distribuição do comprimento da pétala por espécie
ggplot(iris, aes(x = Species, y = Petal.Length, fill = Species)) +
  geom_boxplot(alpha = 0.7) +
  theme_bw() +
  labs(title = "Boxplot: Comprimento da Pétala por Espécie",
       x = "Espécie",
       y = "Comprimento da Pétala")
```

Boxplot: Comprimento da Pétala por Espécie



O `ggplot2` oferece diversas opções de personalização, como cores, temas e anotações, permitindo criar gráficos bonitos e informativos para diferentes finalidades.

14.3 Exemplos de Bancos de Dados do R

Banco de Dados	Pacote	Área/Descrição
iris	datasets	Botânica, estatística, aprendizado de máquina (flores)
mtcars	datasets	Automóveis, regressão, análise multivariada
airquality	datasets	Qualidade do ar, saúde ambiental
ToothGrowth	datasets	Farmacologia, saúde, crescimento de dentes
sleep	datasets	Psicologia, farmacologia, estudo do sono
ChickWeight	datasets	Nutrição, crescimento animal
USArrests	datasets	Sociologia, estatísticas criminais dos EUA
CO2	datasets	Biologia, fisiologia vegetal
BOD	datasets	Biologia, demanda bioquímica de oxigênio
Boston	MASS	Imobiliário, regressão, análise multivariada
lung	survival	Medicina, análise de sobrevivência (dados de câncer de pulmão)
bfi	psych	Psicologia, personalidade (Big Five Inventory)
NHANES	NHANES	Saúde pública, epidemiologia (pesquisa nacional dos EUA)
titanic	titanic	Sobrevivência, estatística, aprendizado de máquina
worldcup	faraway	Esportes (Copa do Mundo de Futebol)

Nota:

Os bancos do pacote `datasets` já vêm instalados por padrão no R. Outros, como `MASS`, `psych`, `NHANES`, `survival`, `titanic` e `faraway`, podem ser instalados via `install.packages("nome_do_pacote")`. Verifique sempre a documentação do pacote para acessar o nome correto dos bancos de dados e exemplos de uso.

Chapter 15

Distribuição de Probabilidade

Uma distribuição de probabilidade é um modelo matemático que descreve a relação entre os valores possíveis de uma variável e as probabilidades de ocorrência desses valores. Essencialmente, ela nos permite prever a probabilidade de eventos com base em um conjunto de dados.

Entre as distribuições mais comuns, destacam-se:

- Distribuição Normal (ou Gaussiana)
- Distribuição Binomial
- Distribuição Poisson
- Distribuição Exponencial
- Distribuição Uniforme
- Distribuição Qui-quadrado
- Distribuição t-Student
- Distribuição Gama, entre outras.

Cada tipo de distribuição possui características próprias e é aplicada em diferentes contextos. A distribuição normal é uma das mais amplamente utilizadas, especialmente para modelar fenômenos naturais e sociais, como a altura de indivíduos ou o tempo de vida de produtos.

Propriedades Gerais das Distribuições de Probabilidade

- **Área total sob a curva é igual a 1:** Isso significa que a soma de todas as probabilidades possíveis de ocorrência dos eventos é igual a 100%.
- **A área sob a curva representa a probabilidade de um evento.** Por exemplo, a probabilidade de um evento ocorrer entre dois valores quaisquer pode ser calculada pela área sob a curva entre esses dois pontos.

15.1 Distribuição Normal

A distribuição normal é uma das mais conhecidas na estatística. Ela modela fenômenos que seguem um comportamento simétrico em torno de uma média. A distribuição normal tem várias aplicações, desde a análise de medidas biológicas (como a pressão arterial) até a previsão de fenômenos econômicos (como o preço das ações).

A distribuição normal é definida por dois parâmetros principais:

- **Média (μ):** Representa o valor central da distribuição.
- **Desvio Padrão (σ):** Mede a dispersão dos dados em relação à média.

Características da Distribuição Normal

- **Forma de sino:** A distribuição normal tem a forma de um sino simétrico, com a maior concentração de dados perto da média.
- **Simetria:** A distribuição é simétrica em relação à média.

- **Média, Mediana e Moda:** Para uma distribuição normal, a média, mediana e moda são “iguais” e localizam-se no centro da distribuição.

Teoricamente o comportamento da Distribuição Normal é dado por:




Figure 15.1: Figura: Distribuição Normal teórica (Fonte: <https://www.inf.ufsc.br/~andre.zibetti/probabilidade/figures/normal.PNG>)

Onde:

- A média está representada por
- O desvio padrão está representado por

Regra empírica 68% - 95% - 99,7% Se os dados seguem uma distribuição normal, é possível fazer afirmações sobre a concentração dos dados em torno da média, conforme a regra empírica:

- 68% dos dados estão no intervalo de uma vez o desvio padrão (± 1).
- 95% dos dados estão no intervalo de duas vezes o desvio padrão (± 2).
- 99,7% dos dados estão no intervalo de três vezes o desvio padrão (± 3).

Importante: Dados fora do intervalo de ± 3 são considerados raros.

Exemplo de distribuição Normal, com dados simulados usando a função `rnorm()`.


```
# semente de geração de números aleatórios
set.seed(1)

# Será simulada uma amostra com a seguinte característica:
# 1000 valores
# média ~ 70
# desvio padrão ~ 3
# A função rnorm() gera números randômicos com comportamento de uma distribuição Normal
BatimentosMulheres <- rnorm(1000, 70, 3)

# Arredondamento sem casas depois da vírgula
BatimentosMulheres <- round(BatimentosMulheres, 0)

# histograma
hist(BatimentosMulheres)
```

Histogram of BatimentosMulheres




```
# Classes e frequências do histograma
hist(BatimentosMulheres)$breaks
```

```
## [1] 60 62 64 66 68 70 72 74 76 78 80 82
hist(BatimentosMulheres)$count
```

```
## [1] 8 35 85 177 264 227 128 57 17 1 1
# histograma e curva de densidade (da Dist. Normal)
hist(BatimentosMulheres, prob = TRUE)
lines(density(BatimentosMulheres), col = 4, lwd = 2)

# indicação da média
abline(v = mean(BatimentosMulheres), col = 2, lwd = 3)
```

Histogram of BatimentosMulheres



```
# medidas resumo
summary(BatimentosMulheres)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      61.00  68.00   70.00   69.97  72.00   81.00
```

```
sort(table(BatimentosMulheres), decreasing = T)
```

```
## BatimentosMulheres
##  69  70  71  72  68  67  73  66  74  75  65  64  63  76  77  61  62  78  79  81
## 138 126 116 111  95  82  82  56  46  41  29  18  17  16  15  4  4  2  1  1
```

```
sd(BatimentosMulheres)
```

```
## [1] 3.10594
```

```
# CV em %
sd(BatimentosMulheres)/mean(BatimentosMulheres)*100
```

```
## [1] 4.438833
```

As funções **pnorm()** e **dnorm()** são usadas para calcular a probabilidade de um evento que segue uma distribuição, a qual conhecemos a média e o desvio padrão.

Exemplo: Sabendo que os batimentos cardíacos de mulheres de 18 a 65 anos tem média de 70bpm e desvio padrão igual a 3bpm.

Calcule as probabilidades:

- de uma mulher ter batimentos inferior a 70bpm, ou seja, $P(x < 70)$:

```
# pnorm(): Calcula a probabilidade acumulada até um valor específico. Ou seja, retorna a probabilidade de
```

```
# observação: a resposta é 0.5 pois a média 70.
```

```
pnorm(70, 70, 3)
```

```
## [1] 0.5
```

- de uma mulher ter batimentos superior a 70bpm, ou seja, $P(x > 70)$:

```
# observação: 1 é o valor da área total
# a pnorm() fornece a área à esquerda
1 - pnorm(70, 70, 3)
```

```
## [1] 0.5
```

- a **densidade de probabilidade** no ponto 70bpm:

```
# dnorm(): Calcula a DENSIDADE de probabilidade em um valor específico.
# Atenção: densidade NÃO é probabilidade!
dnorm(70, 70, 3)
```

```
## [1] 0.1329808
```

E qual é a probabilidade de uma mulher ter batimentos exatamente iguais a 70bpm?

Ela é **zero**: $P(X = 70) = 0$.

Isso vale para *qualquer* valor isolado de uma variável contínua. A probabilidade é a **área** sob a curva, e a área sobre um único ponto é nula — um ponto não tem largura. O que a `dnorm()` devolve é a **altura** da curva naquele ponto (a densidade), que serve para desenhar o gráfico, mas não pode ser lida como probabilidade.

É exatamente por isso que, com variáveis contínuas, sempre perguntamos pela probabilidade em um **intervalo** — como nos próximos exemplos.

- de uma mulher ter batimentos entre 67 e 73bpm $P(67 < x < 73)$:

```
# Observe que estamos testando a regra empírica (68%)
pnorm(73, 70, 3) - pnorm(67, 70, 3)
```

```
## [1] 0.6826895
```

- de uma mulher ter batimentos entre 64 e 76bpm $P(64 < x < 76)$:

```
# Observe que estamos testando a regra empírica (95%)
pnorm(76, 70, 3) - pnorm(64, 70, 3)
```

```
## [1] 0.9544997
```

- de uma mulher ter batimentos entre 61 e 79bpm $P(61 < x < 79)$:

```
# Observe que estamos testando a regra empírica (99,7%)
pnorm(79, 70, 3) - pnorm(61, 70, 3)
```

```
## [1] 0.9973002
```

- de uma mulher ter batimentos maior que 90bpm $P(x > 90)$:

```
# Um evento raro
1 - pnorm(90, 70, 3)
```

```
## [1] 1.308398e-11
```

- de uma mulher ter batimentos menor que 65bpm $P(x < 65)$:

```
pnorm(65, 70, 3)
```

```
## [1] 0.04779035
```

15.2 Gráfico QQ

Uma maneira comum de verificar a normalidade de uma distribuição é utilizando o gráfico QQ. Ele compara os quantis de uma amostra com os quantis de uma distribuição normal padrão, e é muito útil para identificar

se os dados seguem uma distribuição normal.

Distribuição Normal Padrão

A distribuição normal padrão tem duas características importantes:

- Média () igual a 0
- Desvio padrão () igual a 1

Cálculo do Escore Z

Qualquer distribuição normal pode ser transformada na distribuição normal padrão utilizando o escore Z. O **escore Z** é calculado pela fórmula:

$$z = \frac{(x - \mu)}{\sigma}$$


Onde:

- x é o valor da observação.
- μ é a média da distribuição.
- σ é o desvio padrão da distribuição.

O gráfico QQ realiza exatamente o que a fórmula do escore Z descreve: ele transforma os dados da amostra para a distribuição normal padrão (média 0 e desvio padrão 1) e então compara esses valores transformados com os quantis da distribuição normal teórica. Se os pontos formarem uma linha reta, isso sugere que os dados seguem uma distribuição normal.

Veja um exemplo no R para uma Distribuição Normal Padrão:

```
set.seed(1)
# rnorm(10000, 0, 1): normal padrão média 0, dp=1
# ou simplesmente rnorm(10000)
NormalPadrao <- rnorm(10000)
hist(NormalPadrao, probability = T)
lines(density(NormalPadrao), col = 4, lwd = 2)
axis(side = 1, at = seq(-3, 3, by = 1), labels = seq(-3, 3, by = 1))
abline(v = mean(NormalPadrao), col = 2, lwd = 3)
```




No gráfico QQ, os quantis da amostra são comparados com os quantis da distribuição normal padrão. Se a amostra segue uma distribuição normal, os pontos no gráfico QQ devem se alinhar aproximadamente a uma linha reta.

Se os pontos se afastam dessa linha reta de forma sistemática, isso indica que os dados não seguem uma distribuição normal. O tipo de desvio pode dar pistas sobre a natureza dessa não-normalidade (por exemplo, se os pontos se curvam para cima ou para baixo, pode indicar assimetria ou caudas pesadas).

Distribuição normal é usada para dados contínuos!


```
# Gráfico QQ
set.seed(1)
BatimentosMulheres <- rnorm(1000, 70, 3)
qqnorm(BatimentosMulheres)
qqline(BatimentosMulheres, col="red")
```

Normal Q-Q Plot



```
# Faça o arredondamento
BatimentosMulheresR <- round(BatimentosMulheres,0)
qqnorm(BatimentosMulheresR)
qqline(BatimentosMulheresR)
```

Normal Q-Q Plot



A distribuição Normal é uma distribuição para modelar variáveis **CONTÍNUAS**!

15.3 Atividade 7

Utilizando o banco de dados escolhido para as atividades 5 e 6, gere gráficos QQ para as variáveis quantitativas. Em seguida, avalie visualmente se essas variáveis seguem uma distribuição normal.

Chapter 16

Exemplos de distribuições


16.1 Distribuições Discretas

16.1.1 Binomial

Modela o número de sucessos em n tentativas com probabilidade p .

```
n <- 10
p <- 0.5
x <- 0:n
y <- dbinom(x, size = n, prob = p)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  labs(title = "Distribuição Binomial (n = 10, p = 0.5)", x = "Número de Sucessos", y = "Probabilidade")
```




16.1.2 Poisson

Modela o número de eventos raros num intervalo fixo.

```
lambda <- 3
x <- 0:15
y <- dpois(x, lambda)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_bar(stat = "identity", fill = "darkorange") +
  labs(title = "Distribuição de Poisson", x = "Número de Eventos", y = "Probabilidade")
```




16.1.3 Geométrica

Modela o número de falhas antes do primeiro sucesso.

```
p <- 0.3
x <- 0:10
y <- dgeom(x, prob = p)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_bar(stat = "identity", fill = "purple") +
  labs(title = "Distribuição Geométrica (p = 0.3)", x = "Número de falhas antes do 1º sucesso", y = "Probabilidade")
```




16.2 Distribuições Contínuas

16.2.1 Normal

Modela fenômenos naturais e erros de medida.

```
x <- seq(-4, 4, length.out = 100)
y <- dnorm(x)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_line(color = "darkgreen", linewidth = 1.2) +
  labs(title = "Distribuição Normal (média = 0, sd = 1)", x = "x", y = "Densidade")
```




16.2.2 Exponencial

Tempo até um evento ocorrer.

```
lambda <- 1
x <- seq(0, 5, length.out = 100)
y <- dexp(x, rate = lambda)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_line(color = "firebrick", linewidth = 1.2) +
  labs(title = "Distribuição Exponencial", x = "Tempo", y = "Densidade")
```




16.2.3 Uniforme Contínua

Todos os valores têm a mesma chance.

```
x <- seq(0, 1, length.out = 100)
y <- dunif(x, min = 0, max = 1)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_line(color = "goldenrod", linewidth = 1.2) +
  labs(title = "Distribuição Uniforme Contínua (0 a 1)", x = "x", y = "Densidade")
```




16.2.4 t de Student

Usada em testes com amostras pequenas.

```
x <- seq(-4, 4, length.out = 100)
y <- dt(x, df = 5)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_line(color = "navy", linewidth = 1.2) +
  labs(title = "Distribuição t de Student (df = 5)", x = "x", y = "Densidade")
```

Distribuição t de Student (df = 5)




16.2.5 Qui-Quadrado (χ)

Usada para testes de aderência e independência.

```
x <- seq(0, 20, length.out = 100)
y <- dchisq(x, df = 5)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_line(color = "tomato", linewidth = 1.2) +
  labs(title = "Distribuição Qui-quadrado (df = 5)", x = "x", y = "Densidade")
```




16.2.6 F de Fisher

Usada em ANOVA para comparar variâncias.

```
x <- seq(0, 5, length.out = 100)
y <- df(x, df1 = 5, df2 = 10)

ggplot(data.frame(x, y), aes(x, y)) +
  geom_line(color = "darkviolet", linewidth = 1.2) +
  labs(title = "Distribuição F de Fisher (df1 = 5, df2 = 10)", x = "x", y = "Densidade")
```

Distribuição F de Fisher (df1 = 5, df2 = 10)



Cada distribuição tem uma aplicação específica conforme o tipo de variável (discreta ou contínua), o contexto do problema e as suposições do modelo. Entender suas formas e usos ajuda na escolha correta da análise estatística.

Chapter 17

Normal ou Não?

Antes de avançarmos para a aplicação dos testes estatísticos, é importante avaliarmos se os dados seguem ou não uma distribuição normal. Essa verificação inicial é muito importante porque muitos testes paramétricos, como o teste t e a ANOVA, partem da suposição de normalidade dos dados. Compreender esse aspecto permite escolher os métodos estatísticos mais adequados, aumentando a confiabilidade dos resultados e evitando interpretações equivocadas que poderiam comprometer a análise.


Esta seção apresenta uma análise visual da normalidade dos dados por meio de gráficos QQ (Quantil-Quantil), com a comparação de três cenários distintos: dados que seguem uma distribuição normal, dados que levantam dúvidas quanto à normalidade e dados que claramente não seguem essa distribuição.

- Dados normalmente distribuídos
- Dados que geram dúvida quanto à normalidade
- Dados que claramente não seguem distribuição normal

```
set.seed(10)
dados_normais <- rnorm(500, mean = 0, sd = 1)


hist(dados_normais, main = "Histograma - Distribuição Normal", col = "lightblue")
```

Histograma – Distribuição Normal




```
boxplot(dados_normais, main = "Boxplot - Distribuição Normal")
```

Boxplot – Distribuição Normal



```
qqnorm(dados_normais, main = "QQ Plot - Distribuição Normal")  
qqline(dados_normais, col = "blue", lwd = 2)
```

QQ Plot – Distribuição Normal




Observação: Os pontos seguem de perto a linha, indicando que os dados são normalmente distribuídos.

```
set.seed(20)
dados_mistos <- c(rnorm(250, 0, 1), rnorm(250, 2, 1))


hist(dados_mistos, main = "Histograma - Mistura de Normais", col = "lightgreen")
```

Histograma – Mistura de Normais




```
boxplot(dados_mistos, main = "Boxplot - Mistura de Normais")
```

Boxplot – Mistura de Normais



```
qqnorm(dados_mistos, main = "QQ Plot - Mistura de Normais")  
qqline(dados_mistos, col = "orange", lwd = 2)
```

QQ Plot – Mistura de Normais




Observação: As caudas do gráfico QQ começam a se afastar da linha, o que pode gerar dúvida sobre a normalidade.

```
set.seed(30)
dados_chi <- rchisq(500, df = 3)


hist(dados_chi, main = "Histograma - Distribuição Qui-quadrado", col = "lightpink")
```

Histograma – Distribuição Qui-quadrado




```
boxplot(dados_chi, main = "Boxplot - Qui-quadrado")
```

Boxplot – Qui-quadrado



```
qqnorm(dados_chi, main = "QQ Plot - Qui-quadrado")  
qqline(dados_chi, col = "red", lwd = 2)
```

QQ Plot – Qui-quadrado




Observação: A forte curvatura do gráfico QQ indica clara violação da normalidade (assimetria à direita).

```
set.seed(42)
dados_repetidos <- c(rep(18, 5), rep(23, 10), rep(26,7))


# Histograma
hist(dados_repetidos, main = "Histograma - Dados Repetidos", col = "lightblue", xlab = "Valor", ylab = "Frequência")
```

Histograma – Dados Repetidos




```
# Boxplot  
boxplot(dados_repetidos, main = "Boxplot - Dados Repetidos", col = "lightgreen")
```

Boxplot – Dados Repetidos



```
# QQ Plot  
qqnorm(dados_repetidos, main = "QQ Plot - Dados Repetidos")  
qqline(dados_repetidos, col = "red", lwd = 2)
```

QQ Plot – Dados Repetidos



O gráfico QQ é uma ferramenta visual poderosa para avaliar se um conjunto de dados segue uma distribuição normal. Em conjunto com histogramas e boxplots, permite identificar desvios, outliers e assimetrias de maneira clara.

Chapter 18

Estatística Inferencial

A **estatística inferencial** é uma área essencial da estatística que permite fazer generalizações sobre uma população com base em dados coletados de uma amostra. Um passo fundamental nesse processo é o **cálculo amostral**, que determina o tamanho ideal da amostra para garantir a validade dos resultados, e esse cálculo depende diretamente do **tipo de teste estatístico** que será utilizado, pois diferentes testes exigem diferentes parâmetros, como variabilidade, efeito esperado e poder do teste.

Ao conduzir uma análise inferencial, formulam-se **hipóteses**: a **hipótese nula (H_0)**, que representa a ausência de efeito ou diferença, e a **hipótese alternativa (H_a)**, que sugere a existência de um efeito ou diferença. Define-se também um **nível de significância (α)**, geralmente 0,05 (5%), que representa a probabilidade de rejeitar H_0 quando ela é verdadeira (**erro tipo I**). O **valor-p**, calculado a partir dos dados, indica a probabilidade de obter um resultado tão extremo quanto o observado, supondo que H_0 seja verdadeira. Com base na comparação entre o valor-p e o nível de significância, aplica-se o **critério de decisão**: se o valor-p for menor que α , rejeita-se H_0 , o que indica **evidências estatísticas suficientes para apoiar a hipótese alternativa**.

18.1 Etapas de um Teste Estatístico

Para realizar qualquer **teste estatístico**, seguimos uma sequência básica de passos:

1. **Escrevemos as hipóteses do teste**, começando com a **hipótese nula (H_0)**, que geralmente afirma que não há efeito ou diferença, e a **hipótese alternativa (H_a)**, que propõe o contrário.
2. **Definimos o nível de significância (α)**, que é a margem de erro aceitável. Esse valor, geralmente 0,05 (ou 5%), já foi considerado no **cálculo do tamanho da amostra**, garantindo que os resultados tenham confiabilidade.
3. **Escolhemos o teste adequado e verificamos seus pressupostos** — o tipo das variáveis, se os grupos são pareados ou independentes, quantos grupos existem e se os dados seguem distribuição normal. É essa etapa que decide entre um teste paramétrico e um não paramétrico.
4. **Utilizamos um recurso computacional**, como um software estatístico, para calcular o **valor-p**, que mostra a probabilidade de observarmos os dados coletados **ou dados ainda mais extremos**, caso a hipótese nula seja verdadeira.
5. **Comparamos o valor-p com o nível de significância**. Se o valor-p for menor que α , **rejeitamos a hipótese nula**. Caso contrário, não rejeitamos.
6. Por fim, **chegamos à conclusão do teste**, que nos diz se há ou não **evidência estatística** suficiente para apoiar a hipótese alternativa.

18.2 Erros Tipo I e Tipo II

Em um **teste estatístico**, tomamos uma decisão com base nos dados coletados de uma amostra: **rejeitar** ou **não rejeitar a hipótese nula (H)**. Por isso, é fundamental realizar um **cálculo amostral adequado**, selecionar cuidadosamente a **técnica de amostragem** e estar atento às possíveis **fontes de vieses**, garantindo que a amostra seja representativa e que os resultados do teste sejam confiáveis.

Entretanto, essa decisão envolve **riscos de erro**, que são inerentes ao processo justamente porque estamos baseando nossas conclusões em uma amostra e não na população inteira. Esses erros se dividem em dois tipos:

- **Erro Tipo I () – Falso Positivo**

Ocorre quando **rejeitamos H mesmo ela sendo verdadeira**.

É como afirmar que existe um efeito quando, na verdade, não existe.

Exemplo na medicina: concluir que um novo medicamento reduz a pressão arterial quando ele não tem efeito real, o que pode levar à aprovação de um tratamento ineficaz.

Exemplo no esporte: afirmar que um programa de treinamento melhora o desempenho dos atletas quando ele não traz benefício real, gerando investimentos desnecessários.

Exemplo na psicologia: dizer que uma terapia cognitivo-comportamental reduz a ansiedade, mesmo sem efeito comprovado, gerando falsas expectativas nos pacientes.

Essa é a chance de um **falso positivo**, e o **nível de significância** (geralmente 0,05) representa a probabilidade de cometer esse erro.

- **Erro Tipo II () – Falso Negativo**

Ocorre quando **não rejeitamos H mesmo ela sendo falsa**.

É como deixar passar um efeito real sem detectá-lo.

Exemplo na medicina: não identificar que o medicamento é eficaz, rejeitando seu uso quando ele realmente funciona.

Exemplo no esporte: não perceber a melhora no desempenho causada pelo programa de treinamento, deixando de adotá-lo e prejudicando os atletas.

Exemplo na psicologia: não detectar que a terapia é eficaz para reduzir a ansiedade, levando à rejeição de um tratamento que poderia beneficiar os pacientes.

Isso é um **falso negativo**, e é a probabilidade de cometer esse erro.

18.3 Poder do Teste Estatístico

- O **poder do teste** é a probabilidade de **detectar um efeito real quando ele realmente existe**, ou seja, **rejeitar H quando H é falsa**.
- O poder é calculado como:
Poder = 1 -

Um teste com **alto poder** (geralmente desejado acima de 80%) tem menos chance de cometer erro tipo II, o que significa maior capacidade de detectar diferenças reais quando elas existem. O poder depende do **tamanho da amostra**, do **nível de significância**, da **variabilidade dos dados** e da **magnitude do efeito** que se deseja identificar.

18.4 Tabela: Erros, Decisões e Poder do Teste

Situação Real	Decisão: Rejeitar H	Decisão: Não Rejeitar H
H é verdadeira	Erro Tipo I ()	Decisão correta
H é falsa	Decisão correta (<i>poder</i>)	Erro Tipo II ()

- **Poder do teste:** Probabilidade de rejeitar H quando H é falsa (ou seja, evitar o erro tipo II).

18.5 Tamanho do Efeito

18.5.1 O que é o Tamanho do Efeito?

O **tamanho do efeito** é uma medida que indica **o quanto uma diferença ou relação observada nos dados é relevante na prática**.

Enquanto o **valor-p** nos informa se um resultado é estatisticamente significativo (ou seja, se é improvável que tenha ocorrido por acaso), o tamanho do efeito **complementa essa análise mostrando a magnitude real do efeito observado**.

18.5.2 Exemplos para Entender Melhor

Imagine que um novo remédio reduza a pressão arterial em média em **1 mmHg** comparado ao tratamento padrão.

Com uma amostra muito grande, essa pequena diferença pode ser estatisticamente significativa ($\text{valor-}p < 0,05$), mas **cl clinicamente irrelevante**. O tamanho do efeito, neste caso, mostra que, apesar do resultado ser significativo, **o impacto prático é muito pequeno**.

Suponha um estudo que compara dois métodos de treinamento de força e encontra uma diferença média de **0,5 kg** no aumento de carga máxima entre os grupos após 8 semanas.

Com uma amostra grande, essa diferença pode ser estatisticamente significativa, mas **na prática, esse ganho é muito pequeno** para justificar a troca de método. O tamanho do efeito indica que, embora exista diferença detectada, **ela tem pouco impacto real no desempenho atlético**.

Considere uma pesquisa que compara níveis de ansiedade entre terapia online e presencial, com diferença média de **1 ponto** (em escala de 0 a 100).

Mesmo que essa diferença seja estatisticamente significativa, **não representa uma mudança clinicamente relevante** no estado emocional dos pacientes. O tamanho do efeito ajuda a perceber que a diferença entre as modalidades pode ser mínima na prática.

18.6 Medidas Comuns de Tamanho do Efeito

A escolha da medida depende do tipo de teste e das variáveis analisadas.

18.6.1 d de Cohen (teste t)

Usado para comparar médias entre dois grupos, mede a diferença em unidades de desvio padrão.

Valor do d	Interpretação
0.2	Efeito pequeno
0.5	Efeito médio
0.8	Efeito grande

18.6.2 V de Cramér (teste qui-quadrado)

Mede a associação entre variáveis categóricas (varia de 0 a 1). Em tabelas 2x2 o V de Cramér coincide com o coeficiente Phi (ϕ).

Valor de V	Interpretação
0,1	Associação fraca
0,3	Associação moderada
0,5	Associação forte

Cuidado para não confundir o **V** de Cramér com o **C** (coeficiente de contingência de Pearson), que é outra medida, com outra escala. Veremos o V de Cramér em detalhe no capítulo de associação entre variáveis.

18.6.3 Coeficiente de Correlação de Pearson (r)

Mede a força da relação linear entre duas variáveis quantitativas.

Valor de r	Interpretação
0.1	Correlação fraca
0.3	Correlação moderada
0.5	Correlação forte
0	Nenhuma correlação
±1	Correlação perfeita

18.7 Por que o Tamanho do Efeito é Importante?

Um resultado estatisticamente significativo **nem sempre indica relevância prática**. O tamanho do efeito responde à pergunta: “**Esse resultado faz diferença no mundo real?**”

18.8 Testes

Nas próximas seções, abordaremos os testes de **comparação entre grupos** com base em uma variável quantitativa, os testes de **associação entre variáveis categóricas** nominais, e os testes de **correlação**, que podem envolver variáveis quantitativas ou qualitativas ordinais. Essa abordagem visa facilitar a compreensão e a interpretação dos resultados estatísticos em variados contextos, ressaltando sempre a importância de avaliar a relevância prática dos achados para uma tomada de decisão mais informada.

Chapter 19

Testes de Comparação entre Grupos

Os testes de comparação são usados para verificar se existem diferenças significativas entre grupos em relação a uma variável quantitativa. Essas comparações podem variar conforme a relação entre os grupos, o número de grupos e o tipo de dado.

19.1 Comparações Pareadas (Dependentes)

Quando os grupos comparados são relacionados ou “ligados” de alguma forma, dizemos que a comparação é **pareada** ou entre grupos **dependentes**. Isso acontece, por exemplo, quando medimos a mesma amostra em dois momentos diferentes — antes e depois de uma intervenção — ou quando comparamos pares de indivíduos relacionados, como gêmeos.

Exemplos:

- Avaliar a pressão arterial dos pacientes antes e depois de um tratamento.
- Medir a força muscular dos atletas antes e após um programa de treinamento.
- Aplicar um teste de ansiedade em pacientes antes e depois de uma terapia.

19.2 Comparações Não-Pareadas (Independentes)

As comparações são **não-pareadas** ou entre grupos **independentes** quando os grupos não têm relação entre si, ou seja, os participantes de um grupo não pertencem ao outro. Cada observação é independente das outras.

Exemplos:

- Comparar a pressão arterial entre pacientes que receberam medicamento e pacientes que receberam placebo.
- Comparar a velocidade média de corrida entre dois times diferentes.
- Comparar níveis de estresse entre grupos que fizeram terapia presencial e terapia online.

19.3 Número de Grupos na Comparação

A comparação pode ser feita entre **dois grupos** ou **mais de dois grupos**:

- **Dois grupos:** Por exemplo, comparar o desempenho entre dois métodos de ensino.
- **Mais de dois grupos:** Por exemplo, comparar o efeito de três diferentes dietas no peso corporal.

19.4 Testes Paramétricos e Não Paramétricos

Para escolher o teste estatístico adequado, é importante considerar as características dos dados:

- **Testes Paramétricos:**

Utilizados quando os dados seguem certas condições, como distribuição normal e variância homogênea, permitindo uma análise mais precisa.

- **Testes Não Paramétricos:**

Indicados quando os dados não atendem às condições dos testes paramétricos, como em distribuições assimétricas ou dados ordinais, oferecendo uma alternativa robusta para comparação.

Chapter 20

Comparação entre dois grupos

O fluxograma abaixo apresenta a sequência de etapas para a escolha do teste estatístico mais adequado na comparação entre dois grupos, considerando o tipo de comparação entre os dois grupos (pareada ou não pareada) e a verificação da normalidade dos dados.

Exemplos didáticos para comparação entre dois grupos são mostrados a seguir.

20.1 Teste t pareado

O teste t (pareado ou não pareado) é um teste **paramétrico**, por isso, antes de aplicar o teste, recomenda-se verificar a normalidade dos dados.

O teste t pareado avalia se há diferença entre as médias de dois conjuntos dependentes (ex: antes e depois em um mesmo grupo).

Hipóteses:

H: A média antes é igual à média depois (não há efeito).

H: A média antes é diferente da média depois (há efeito).

```
# Simulando dados: pressão antes e depois
set.seed(123)
antes <- rnorm(20, mean=120, sd=10)
depois <- antes + rnorm(20, mean=-5, sd=8) # espera-se uma redução média de 5

# Teste t pareado
t.test(antes, depois, paired = TRUE)

##
## Paired t-test
##
## data:  antes and depois
## t = 3.644, df = 19, p-value = 0.001726
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
##  2.302671 8.517443
## sample estimates:
## mean difference
##      5.410057
```

No R, fazer o teste t pareado é muito fácil. Você só precisa usar uma linha: `t.test(antes, depois, paired = TRUE)`.

Basta colocar os seus dois conjuntos de dados (por exemplo, as medidas antes e depois) e escrever `paired = TRUE` para avisar ao R que os dados são do mesmo grupo em dois momentos.

Assim, o R faz todo o cálculo para você!

Ao realizar o teste t pareado no R, a saída apresenta várias informações importantes:

- **t**: Este é o valor do teste t calculado a partir dos dados. Ele indica o quanto a diferença média observada entre os grupos se afasta do que seria esperado se não houvesse diferença real.
- **df**: Significa “degrees of freedom” (graus de liberdade), que neste caso é igual ao número de pares menos 1 (aqui, 19).
- **p-value**: É a probabilidade de observarmos uma diferença igual ou maior que a encontrada, caso a hipótese nula (de que não há diferença) seja verdadeira. Um p-valor pequeno (por exemplo, menor que 0,05) indica que a diferença é estatisticamente significativa.
- **alternative hypothesis**: Mostra qual hipótese alternativa está sendo testada – neste caso, que a diferença média entre “antes” e “depois” é diferente de zero.
- **95 percent confidence interval**: Indica o intervalo de valores no qual a verdadeira diferença média está com 95% de confiança. Aqui, podemos dizer que a diferença média entre os grupos está provavelmente entre 2,30 e 8,52.
- **mean difference**: É a diferença média observada nos dados, neste exemplo, aproximadamente 5,41.

Resumo:

O resultado sugere que há uma diferença significativa entre “antes” e “depois” ($p = 0,0017$), com a diferença média estimada em 5,41 unidades e um intervalo de confiança que não inclui zero.

Observação: Se p é maior que 0,05, não rejeitamos H_0 , nesse caso a conclusão seria que não há evidência de diferença significativa.

20.2 Wilcoxon pareado

O teste de Wilcoxon para amostras pareadas é a alternativa não paramétrica ao teste t pareado, sendo utilizado quando os dados não seguem uma distribuição normal.

Hipóteses:

H_0 : As distribuições dos pares são iguais (não há diferença entre antes e depois).

H_a : As distribuições dos pares são diferentes (há diferença entre antes e depois).

Formalmente, o teste verifica se a **distribuição das diferenças entre os pares** é simétrica em torno de zero. Quando essa condição de simetria é atendida, podemos interpretar o teste como uma comparação das **medianas** das duas situações (por exemplo, antes e depois).

Hipóteses:

H_0 : A mediana das diferenças entre os pares é igual a zero (não há diferença entre antes e depois).

H_a : A mediana das diferenças entre os pares é diferente de zero (há diferença entre antes e depois).

Observação: Esta formulação das hipóteses em termos de mediana é válida quando as diferenças apresentam distribuição simétrica.

```
wilcox.test(antes, depois, paired = TRUE)
```

```
##
## Wilcoxon signed rank exact test
##
## data:  antes and depois
## V = 179, p-value = 0.004221
## alternative hypothesis: true location shift is not equal to 0
```

Ao fazer o teste de Wilcoxon pareado no R, a resposta traz as seguintes informações:

- **V:** É o valor da estatística do teste de Wilcoxon, calculado a partir das diferenças entre os pares. Não precisamos interpretar esse número diretamente; ele serve para o cálculo do p-valor.
- **p-value:** É a chance de observarmos uma diferença igual ou maior que a encontrada, caso não exista diferença real entre os grupos. Se o p-valor for menor que 0,05, dizemos que há diferença significativa entre “antes” e “depois”.
- **alternative hypothesis:** Mostra qual hipótese alternativa foi testada. Nesse caso, que a posição central (mediana) dos dois momentos não é igual.

No R, por padrão, a função `wilcox.test()` não mostra o intervalo de confiança para a mediana das diferenças. No entanto, você pode pedir para calcular o intervalo de confiança usando o argumento `conf.int = TRUE`:

```
wilcox.test(antes, depois, paired = TRUE, conf.int = TRUE)
```

```
##
## Wilcoxon signed rank exact test
##
## data:  antes and depois
## V = 179, p-value = 0.004221
## alternative hypothesis: true location shift is not equal to 0
## 95 percent confidence interval:
##  2.291397 8.680443
## sample estimates:
## (pseudo)median
##      5.545154
```

Observações sobre o intervalo de confiança do teste de Wilcoxon

95 percent confidence interval:

O intervalo de confiança de 95% vai de 2,29 até 8,68. Isso significa que, com 95% de confiança, a verdadeira mediana da diferença entre “antes” e “depois” está entre esses valores.

Como esse intervalo **não inclui o zero**, temos mais uma indicação de que existe diferença significativa entre os dois momentos.

(pseudo)median:

O valor de 5,55 é a estimativa do deslocamento central entre os pares.

Atenção: ele **não** é a mediana das diferenças observadas — esta seria `median(antes - depois)`, que dá 6,12. É chamado de “pseudo-median” porque, no teste de Wilcoxon, é calculado de outra maneira, e é uma estimativa mais robusta do deslocamento central.

O termo “pseudo-median” aparece no teste de Wilcoxon porque, nesse teste, a maneira de calcular a “mediana” é um pouco diferente da mediana comum.

Mediana comum: É o valor do meio quando colocamos todos os números em ordem.

Pseudo-median: No teste de Wilcoxon, em vez de pegar só o valor do meio, o cálculo usa todos os pares possíveis de diferenças entre os grupos. Ele faz uma média especial desses valores do meio. Por isso, chama-se “pseudo” (uma “falsa” ou “quase” mediana).

20.3 Teste t não pareado

Se você olhar no fluxograma apresentado no início do capítulo, você verá que antes de executar o teste t para amostras não pareadas, é necessário executar o teste de variância.

20.3.1 Teste de variância

É um pré-requisito para o teste t não pareado Verifica se as variâncias de dois grupos não pareados podem ser consideradas iguais ou não.

Hipóteses:

H: As variâncias dos dois grupos são iguais.

H: As variâncias dos dois grupos são diferentes.

Interpretação:

Se $p < 0,05$, rejeitamos H e concluímos que as variâncias são diferentes

No teste t acrescentado o argumento `var.equal=FALSE` ou `var.equal=F`.

Se $p > 0,05$, consideramos as variâncias iguais.

No teste t acrescentado o argumento `var.equal=TRUE` ou `var.equal=T`

Importante:

O argumento `var.equal` dentro de `t.test()` define qual versão do teste será utilizada: se `var.equal = TRUE`, o teste assume variâncias iguais; se `var.equal = FALSE`, é usada a correção de Welch, que não assume homogeneidade. A escolha incorreta desse parâmetro pode comprometer a validade do p-valor obtido, afetando a conclusão do teste.

Explicação didática

Imagine que você quer comparar as médias de duas turmas. A Turma A tem poucos alunos e notas parecidas; a Turma B tem muitos alunos, mas as notas variam bastante.

Se você comparar as médias assumindo que ambas têm a mesma variação, o resultado pode ser injusto.

A correção de Welch resolve isso: ela ajusta o cálculo do teste para considerar que as turmas são diferentes — olhando para a variação e o tamanho de cada grupo separadamente. Assim, o teste fica mais confiável quando os grupos são desiguais.

O teste t para amostras não pareadas compara médias de dois grupos independentes.

Hipóteses:

H: A média do grupo A é igual à média do grupo B.

H: As médias dos grupos são diferentes.

```
# Simulando dados
set.seed(456)
grupoA <- rnorm(30, mean=50, sd=7)
grupoB <- rnorm(30, mean=55, sd=7)

# Teste de variância (pré-requisito do t independente)
var.test(grupoA, grupoB)

##
## F test to compare two variances
##
## data: grupoA and grupoB
## F = 1.8842, num df = 29, denom df = 29, p-value = 0.09347
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.896797 3.958627
## sample estimates:
## ratio of variances
##      1.884167

# Teste t independente
t.test(grupoA, grupoB, var.equal = TRUE)

##
## Two Sample t-test
##
```

```
## data: grupoA and grupoB
## t = -2.4453, df = 58, p-value = 0.01753
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -8.1306016 -0.8110054
## sample estimates:
## mean of x mean of y
## 51.6222 56.0930
```

Descrição dos resultados do teste F para comparação de variâncias

- **F = 1.8842**: Este é o valor da estatística F, que compara as duas variâncias. Ele é calculado dividindo a variância do grupo com maior variância pela variância do outro grupo.
- **num df = 29, denom df = 29**: Esses são os graus de liberdade, relacionados ao tamanho de cada grupo ($n - 1$), neste caso ambos com 30 participantes.
- **p-value = 0.09347**: Este é o valor de significância. Ele mostra a probabilidade de observarmos uma diferença entre as variâncias tão grande quanto a encontrada, caso as variâncias dos grupos fossem realmente iguais. Como o p-valor é maior que 0,05, não podemos dizer que as variâncias são diferentes de forma significativa.
- **alternative hypothesis: true ratio of variances is not equal to 1**: Isso mostra que o teste está verificando se as variâncias são diferentes (não iguais).
- **95 percent confidence interval: 0.896797 a 3.958627**: Com 95% de confiança, o verdadeiro valor da razão entre as variâncias está entre aproximadamente 0,90 e 3,96. Como esse intervalo inclui o valor 1, não há diferença significativa entre as variâncias.
- **ratio of variances = 1.884167**: Esse é o valor observado da razão entre as variâncias dos dois grupos. O grupo com maior variância tem uma variância cerca de 1,88 vezes maior que o outro grupo.

Resumo:

O teste F mostrou que não há diferença estatisticamente significativa entre as variâncias dos grupos A e B, pois o p-valor é maior que 0,05 e o intervalo de confiança inclui o valor 1.

Descrição dos resultados do teste t para duas amostras não pareadas

- **t = -2.4453**: Este é o valor da estatística t, que indica o quanto as médias dos grupos A e B diferem em relação à variação dos dados.
- **df = 58**: São os graus de liberdade do teste, relacionados ao tamanho das amostras.
- **p-value = 0.01753**: O p-valor representa a probabilidade de encontrar uma diferença igual ou maior que a observada entre as médias, caso realmente não haja diferença entre os grupos. Como o p-valor é menor que 0,05, podemos considerar que há diferença estatisticamente significativa entre as médias de grupoA e grupoB.
- **alternative hypothesis: true difference in means is not equal to 0**: O teste verifica se existe diferença entre as médias dos dois grupos (hipótese alternativa de diferença).
- **95 percent confidence interval: -8.13 a -0.81**: Com 95% de confiança, a diferença real entre as médias está entre -8,13 e -0,81. Como esse intervalo não inclui o zero, reforça a indicação de diferença significativa.
- **mean of x (grupoA): 51.62**
mean of y (grupoB): 56.09

As médias dos grupos mostram que o grupo B teve, em média, um valor maior que o grupo A.

Resumo:

O teste t indicou que existe uma diferença estatisticamente significativa entre as médias dos grupos A e B. O grupo B apresentou média maior que o grupo A, e essa diferença dificilmente ocorreu ao acaso.

20.4 Wilcoxon não pareado

O teste é também conhecido como Wilcoxon-Mann-Whitney. É a alternativa não paramétrica ao t independente para comparar dois grupos independentes.

Hipóteses:

H: As distribuições dos grupos são iguais.

H: As distribuições dos grupos são diferentes.

```
wilcox.test(grupoA, grupoB)
```

```
##
## Wilcoxon rank sum exact test
##
## data: grupoA and grupoB
## W = 316, p-value = 0.04789
## alternative hypothesis: true location shift is not equal to 0
```

Descrição dos resultados do teste de Wilcoxon para duas amostras não pareadas

- **W = 316:** Este é o valor da estatística de Wilcoxon, que representa a soma dos postos atribuídos aos valores dos grupos ao comparar suas distribuições.
- **p-value = 0.04789:** O valor de p indica a probabilidade de observar uma diferença igual ou maior entre os grupos, caso não exista diferença real. Como é menor que 0,05, isso sugere que há diferença estatisticamente significativa entre os grupos A e B.
- **alternative hypothesis: true location shift is not equal to 0:** O teste está avaliando se há diferença (deslocamento) entre as localizações centrais dos dois grupos (medianas diferentes).

Resumo:

O teste de Wilcoxon mostrou que há uma diferença estatisticamente significativa nas distribuições dos grupos A e B, indicando que eles provavelmente apresentam medianas diferentes.

20.5 Teste bilateral vs. teste unilateral

20.5.1 O que são?

- **Teste bilateral (bicaudal ou two-sided):**
 - Verifica se há diferença **em qualquer direção** entre os grupos ou condições.
 - Exemplo: “Será que a média do grupo A é **diferente** da média do grupo B?” (pode ser maior ou menor).
- **Teste unilateral (caudal ou one-sided):**
 - Verifica se há diferença **em uma direção específica**.
 - Exemplo: “Será que a média do grupo A é **maior** que a média do grupo B?” ou “Será que é **menor**?”.

20.5.2 Formulação das hipóteses

- **Teste bilateral:**
 - Hipótese nula (H_0): não há diferença ($A = B$)
 - Hipótese alternativa (H_1): há diferença ($A \neq B$)
- **Teste unilateral (maior):**
 - Hipótese nula (H_0): $A \leq B$
 - Hipótese alternativa (H_1): $A > B$
- **Teste unilateral (menor):**
 - Hipótese nula (H_0): $A \geq B$
 - Hipótese alternativa (H_1): $A < B$

20.5.3 Influência no cálculo do p-valor

- **Teste bilateral:**

O p-valor representa a probabilidade de encontrar um resultado tão extremo quanto o observado **em**

ambas as direções (para mais ou para menos).

É mais rigoroso, pois considera desvios para cima e para baixo.

- **Teste unilateral:**

O p-valor considera apenas **uma direção** (maior ou menor).

Geralmente, o p-valor do teste unilateral é a metade do bilateral, para o mesmo dado e direção, tornando o teste **mais sensível** a detectar diferenças naquela direção, mas exige justificativa teórica para ser usado.

20.5.4 O que muda nas funções `t.test()` e `wilcox.test()`

Nas duas funções, você controla o tipo de teste pelo argumento `alternative`:

- **Teste bilateral (padrão):**
– `alternative = "two.sided"`
- **Teste unilateral (maior):**
– `alternative = "greater"`
- **Teste unilateral (menor):**
– `alternative = "less"`

Exemplo:

```
# Teste t bilateral (padrão)
t.test(x, y, alternative = "two.sided")

# Teste t unilateral (x maior que y)
t.test(x, y, alternative = "greater")

# Teste de Wilcoxon unilateral (x menor que y)
wilcox.test(x, y, alternative = "less")
```

Ou seja: - O argumento `alternative` define se o teste é bilateral ou unilateral. - Isso altera a formulação das hipóteses, o cálculo do p-valor e a interpretação do resultado.

20.6 Exercício 1

Comparação da velocidade dos Pokémons verdes e amarelos

1. **Baixe o banco de dados**

Use o banco de dados `Pokemon.csv`.

Importe o arquivo para o RStudio pelo botão **Import Dataset**, ou leia direto pelo endereço:

```
library(readr)
Pokemon <- read_csv("https://ana-mat-br.github.io/dados/Pokemon.csv")
```

2. **Pergunta do exercício**

Teste se existe diferença significativa entre a velocidade (**speed**) dos Pokémons verdes (**green**) e amarelos (**yellow**).

3. **Formulação das hipóteses de acordo com os testes**

Hipótese nula (H_0):

Hipótese alternativa (H_1):

4. **Nível de significância**

Considere $\alpha = 0,05$.

5. **Passos para executar o teste adequado**

- a) Separe os dados dos Pokémons de cor verde e de cor amarela.
- b) Verifique a normalidade dos dados de velocidade de cada grupo (gráfico QQ).
- c) Escolha o teste mais apropriado:
 - Se as duas amostras seguirem distribuição Normal teste de variância teste t
 - Se uma das amostras não seguir distribuição Normal teste de Wilcoxon
- d) Execute o teste, compare o p-valor com α e conclua

6. Conclusão

- Se $p\text{-valor} < 0,05$: rejeite a hipótese nula e conclua que há diferença significativa nas velocidades.
- Se $p\text{-valor} \geq 0,05$: não rejeite a hipótese nula e conclua que não há diferença significativa nas velocidades.

Resposta Posit.cloud

20.7 Exercício 2

Considere a tabela de resultados publicados no artigo Resposta da Pressão Arterial ao Esforço em Adolescentes: Influência do Sobrepeso e Obesidade:

Grupo	GSO Meninas (n = 24)	GE Meninas (n = 24)	p
Idade (anos)	12,1 $\pm$ 1,3	12,0 $\pm$ 1,5	0,86
Peso (kg)	59,3 $\pm$ 12,9	38,8 $\pm$ 9,3**	<0,0001
Estatutura (m)	1,53 $\pm$ 0,09	1,46 $\pm$ 0,10*	0,02
IMC (kg/m ²)	25,2 $\pm$ 3,8	17,9 $\pm$ 2,3**	<0,0001
RT/S (mm)	0,85 $\pm$ 0,19	1,43 $\pm$ 0,40**	<0,0001
PAS repouso (mmHg)	114 $\pm$ 12	108 $\pm$ 10	0,07
PAD repouso (mmHg)	66 $\pm$ 6	67 $\pm$ 8	0,51
PAM repouso (mmHg)	82 $\pm$ 7	81 $\pm$ 8	0,67
FC (bpm)	84 $\pm$ 10	87 $\pm$ 9	0,34

*Teste t-Student para amostras independentes; p 0,05; **p 0,01.*
Diferenças entre médias do grupo de sobrepeso e obesos vs eutróficos.

IMC - índice de massa corporal (peso/estatura²);

RT/S - relação tríceps/subescapular;

PAS - pressão arterial sistólica;

PAD - pressão arterial diastólica;

PAM - pressão arterial média;

FC - frequência cardíaca média.*

Contexto:

A tabela acima apresenta características antropométricas e hemodinâmicas de meninas do grupo de sobrepeso/obesidade (GSO) e do grupo eutrófico (GE). Os autores utilizaram o teste t de Student para amostras independentes.

Pergunta:

Escolha uma variável da tabela e formule as hipóteses nula e alternativa para a comparação entre os grupos GSO e GE. Depois, descreva a conclusão dos autores com base no valor de p apresentado na tabela.

Exemplo de resposta:

Variável escolhida: Peso (kg)

Hipóteses:

- Hipótese nula (H):
As médias de peso (kg) dos grupos GSO e GE são iguais.
- Hipótese alternativa (H):
As médias de peso (kg) dos grupos GSO e GE são diferentes.

Nível de significância: = 0,05

Valor de p na tabela: $p < 0,0001$

Conclusão:

Como o valor de p é menor que 0,05, rejeita-se a hipótese nula. Portanto, os autores concluem que existe diferença estatisticamente significativa entre as médias de peso dos grupos GSO e GE, sendo o peso significativamente maior no grupo GSO.

Você pensou nisso? O peso é a variável intrínseca à comparação, pois define os grupos.

20.8 Exercício 3

O artigo Sintomas de estresse pré-competitivo em atletas adolescentes de handebol utilizou como instrumento a Lista de Sintomas de Estresse Pré-competitivo Infanto-juvenil (LSSPCI), uma escala do tipo Likert (De Rose Jr., 1998). A LSSPCI contém 31 sintomas, para os quais cada atleta responde em uma escala de 1 (nunca) a 5 (sempre) sobre a frequência com que cada situação ocorreu nas 24 horas anteriores à competição. Os escores dos sintomas são somados para cada atleta, resultando em um escore total de estresse. Analise os resultados da Tabela 1 do artigo:

Tabela 1. Médias, desvios-padrão, valores p da diferença de médias e mediana dos sintomas de estresse medidos pela LSSPCI em atletas adolescentes de handebol, segundo o sexo (n = 97)

Sintomas de estresse – LSSPCI	Meninos	Meninas	Valor p
Meu coração bate mais rápido que o normal	2,2 ± 1,0 (2,0)	2,5 ± 0,9 (2,5)	0,1
Suo bastante	2,5 ± 1,2 (2,0)	2,4 ± 1,3 (2,0)	0,4
Fico agitado (a)	3,0 ± 0,9 (3,0)	3,2 ± 1,3 (3,0)	0,5
Fico preocupado (a) com críticas das pessoas	2,9 ± 1,5 (3,0)	2,6 ± 1,4 (2,0)	0,2
Sinto muita vontade de fazer xixi	2,0 ± 1,3 (1,0)	2,0 ± 1,2 (2,0)	0,7
Fico preocupado (a) com meus adversários	2,7 ± 1,2 (3,0)	2,9 ± 1,4 (3,0)	0,5
Bebo muita água	2,5 ± 1,2 (3,0)	2,9 ± 1,5 (3,0)	0,3
Roo (como) as unhas	2,5 ± 1,9 (2,0)	2,1 ± 1,5 (1,0)	0,2
Fico empolgado (a)	3,5 ± 1,3 (4,0)	3,6 ± 1,5 (4,0)	0,6
Fico aflito (a)	2,3 ± 1,7 (2,0)	2,8 ± 1,3 (3,0)	0,1
Tenho medo de competir mal	2,6 ± 1,4 (3,0)	2,9 ± 1,4 (3,0)	0,4
Demoro muito para dormir	2,8 ± 2,4 (3,0)	2,3 ± 2,0 (2,0)	0,05
Tenho dúvidas sobre minha capacidade de competir	2,4 ± 1,8 (2,0)	2,4 ± 1,2 (2,0)	0,7
Sonho com a competição	2,4 ± 1,2 (2,0)	1,9 ± 1,3 (1,0)	0,04
Fico nervoso (a)	3,1 ± 1,6 (3,0)	3,3 ± 1,2 (3,0)	0,6
Fico preocupado (a) com o resultado da competição	3,1 ± 1,4 (3,0)	3,7 ± 1,4 (4,0)	0,1
Minha boca fica seca	2,4 ± 1,3 (2,0)	2,3 ± 1,4 (2,0)	0,6
Sinto muito cansaço no fim do treino	2,6 ± 1,3 (2,0)	2,7 ± 1,3 (2,0)	0,9
A presença de meus pais na competição me preocupa	3,1 ± 1,7 (2,0)	2,6 ± 1,6 (2,0)	0,1
Falo muito sobre a competição	3,0 ± 1,5 (3,0)	3,2 ± 1,3 (3,0)	0,6

Sintomas de estresse – LSSPCI	Meninos	Meninas	Valor p
Tenho medo de perder	2,9 $\pm$ 1,4 (3,0)	3,1 $\pm$ 1,4 (3,0)	0,4
Fico impaciente	2,4 $\pm$ 1,1 (2,0)	2,6 $\pm$ 1,3 (2,5)	0,5
Não penso em outra coisa a não ser na competição	2,2 $\pm$ 1,2 (2,0)	2,7 $\pm$ 1,4 (2,0)	0,2
Não vejo a hora de competir	3,2 $\pm$ 1,4 (3,0)	3,3 $\pm$ 1,4 (3,0)	0,7
Fico emocionado (a)	1,8 $\pm$ 1,3 (1,0)	2,3 $\pm$ 1,3 (2,0)	0,1
Fico ansioso (a)	3,6 $\pm$ 1,2 (3,0)	3,4 $\pm$ 1,5 (4,0)	0,7
No dia da competição acordo mais cedo do que o normal	3,1 $\pm$ 1,7 (3,0)	3,0 $\pm$ 1,6 (3,0)	0,8
Tenho medo de decepcionar as pessoas	2,7 $\pm$ 1,4 (3,0)	3,0 $\pm$ 1,5 (3,0)	0,3
Sinto-me mais responsável	3,1 $\pm$ 1,3 (3,0)	2,7 $\pm$ 1,3 (3,0)	0,2
Sinto que as pessoas exigem muito de mim	2,5 $\pm$ 1,4 (2,0)	2,4 $\pm$ 1,4 (2,0)	0,8
Tenho medo de cometer erros na competição	3,4 $\pm$ 1,4 (3,0)	3,6 $\pm$ 1,3 (4,0)	0,4

Média $\pm$ DP (mediana); Teste de Wilcoxon não pareado; $p < 0,05$.

Com base na Tabela 1, qual sintoma de estresse apresentou diferença estatisticamente significativa entre meninos e meninas segundo o teste de Wilcoxon? Explique como interpretar esse resultado considerando o contexto da escala LSSPCI.

20.9 Exercício 4

O artigo Qualidade de vida de estudantes de Psicologia avaliou a qualidade de vida de acadêmicos de psicologia e correlacionou-a com fatores sociodemográficos. Participaram 310 alunos de psicologia que responderam a um questionário sociodemográfico e ao The Medical Outcomes Study 36-item Short-Form Health Survey (SF-36) para avaliar a qualidade de vida. Veja os resultados da comparação entre os gêneros na Tabela 2:

Tabela 2: Comparação entre gêneros nas dimensões de qualidade de vida

Dimensões	Variável	Média	DP	F	p-valor
Capacidade funcional	Masculino	89,74	14,49	2,44	0,119
	Feminino	86,95	11,6		
Aspectos físicos	Masculino	79,74	25,84	0,76	0,383
	Feminino	75,82	31,84		
Dor	Masculino	74,93	22,05	4,33	0,038
	Feminino	68,26	22,00		
Estado geral de saúde	Masculino	75,21	20,36	1,15	0,284
	Feminino	72,32	17,67		
Vitalidade	Masculino	61,38	22,47	1,50	0,222
	Feminino	57,92	18,57		
Aspectos sociais	Masculino	71,34	27,61	0,06	0,804
	Feminino	70,43	24,31		
Aspecto emocional	Masculino	63,16	40,67	0,38	0,536
	Feminino	59,51	39,85		
Saúde mental	Masculino	70,55	19,97	3,05	0,082
	Feminino	65,7	18,80		

Com base na Tabela 2, em qual dimensão da qualidade de vida foi observada diferença estatisticamente significativa entre estudantes do sexo masculino e feminino? O que esse resultado sugere sobre a experiência dos alunos nesses grupos?

Por que a coluna traz F e não t?

Quando comparamos **dois** grupos, a estatística F e a estatística t carregam exatamente a mesma informação, porque $F = t^2$ (com 1 grau de liberdade no numerador). Muitos softwares reportam F mesmo em comparações de duas médias.

Se quiser converter, basta tirar a raiz quadrada: para a dimensão *Dor*, $t = 4,33 = 2,08$.

Confira você mesmo(a) no R que os dois caminhos dão o mesmo valor-p:

```
pf(4.33, df1 = 1, df2 = 308, lower.tail = FALSE)    # 0,0383  
2 * pt(-sqrt(4.33), df = 308)                      # 0,0383
```


Chapter 21

Cálculo amostral no R

O cálculo do tamanho da amostra é fundamental para garantir a validade estatística de um estudo. No R, esse cálculo pode ser realizado de forma prática utilizando diversos pacotes.

21.1 Principais Pacotes para Cálculo Amostral

- **pwr**: Utilizado para análise de poder estatístico e cálculo do tamanho da amostra para diferentes testes (t-test, ANOVA, correlação, etc.).
- **epiDisplay**: Oferece funções para cálculos amostrais em estudos epidemiológicos.
- **epiR**: Bastante utilizado em epidemiologia, com funções para diferentes desenhos de estudo.
- **samplesize**: Possui métodos para cálculo de tamanho amostral em diferentes contextos.

21.2 Exemplo de cálculo amostral para teste t

```
# Instale o pacote se necessário
# install.packages("pwr")
library(pwr)

# Cálculo do tamanho da amostra para detectar um efeito de tamanho médio (d = 0.5)
# com poder de 80% e nível de significância de 5%
pwr.t.test(d = 0.5, power = 0.8, sig.level = 0.05, type = "two.sample")
```

O uso de funções e pacotes específicos no R torna o cálculo amostral mais acessível, permitindo maior precisão no planejamento de estudos. Sempre leve em conta os parâmetros do seu estudo, como efeito esperado, variância, poder e nível de significância.

No exemplo os seguintes parâmetros foram utilizados:

- **d = 0.5**
Tamanho do efeito (Effect size): Representa a magnitude da diferença que se espera detectar entre as médias dos grupos, em unidades de desvio padrão. Quanto maior o efeito, mais fácil é detectá-lo com uma amostra menor.
 - O tamanho do efeito pode ser estimado a partir de dados prévios, estudos semelhantes ou com base em uma suposição informada.
 - Categorias comuns: pequeno ($\sim 0,2$), médio ($\sim 0,5$) e grande ($\sim 0,8$).
- **power = 0.8**
Poder estatístico (Power): É a probabilidade de detectar uma diferença real quando ela de fato existe (ou seja, de rejeitar corretamente a hipótese nula se ela for falsa).
 - Poder = $1 - \alpha$, onde α é a probabilidade de erro tipo II (falso negativo).

- O valor padrão mais utilizado é 0,80 (ou 80%).
- **sig.level = 0.05**
Nível de significância (): É a probabilidade de rejeitar a hipótese nula quando ela é verdadeira (erro tipo I, falso positivo).
 - O valor padrão é 0,05 (ou 5%), indicando que aceitamos até 5% de chance de um falso positivo.
- **type = “two.sample”**
 Indica que estamos comparando dois grupos independentes (teste t para duas amostras).

Interpretação dos Resultados

Ao rodar o comando acima, o R retorna o tamanho mínimo de amostra necessário **em cada grupo** para que seja possível detectar uma diferença de tamanho de efeito $d = 0.5$ com 80% de poder e 5% de nível de significância, usando um teste t para duas amostras.

Por exemplo, o resultado pode ser algo assim:

```
Two-sample t test power calculation

      n = 63.76561
      d = 0.5
sig.level = 0.05
  power = 0.8
alternative = two.sided
```

NOTE: n is number in **each** group

Explicação:

- *n 64*: Você precisaria de pelo menos **64 participantes em cada grupo** para ter 80% de chance de detectar uma diferença de tamanho médio (0,5 desvios padrão) entre os grupos, com risco de 5% de um falso positivo.

Considerações

- O tamanho da amostra depende diretamente do tamanho do efeito esperado, do poder estatístico desejado e do nível de significância escolhido.
- Quanto maior o efeito esperado, menor precisa ser a amostra.
- Quanto maior o poder ou menor o nível de significância, maior será o tamanho da amostra necessária.
- Use dados prévios, literatura ou cálculos exploratórios para definir o tamanho do efeito.

21.3 O que é o d de Cohen?

O d de Cohen é uma **medida padronizada** do tamanho do efeito para comparar a diferença entre duas médias, levando em conta a variabilidade dos dados. Ele é muito utilizado para quantificar o quão grande é a diferença entre dois grupos em termos de desvios padrão.

21.3.1 Fórmula Geral para Dados Não Pareados (Amostras Independentes)

$$d = \frac{X_1 - X_2}{s_p}$$

Onde:

- X_1 = média do grupo 1
- X_2 = média do grupo 2
- s_p = desvio padrão combinado (pooled) dos dois grupos

Como calcular o desvio padrão combinado

$$s_p = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

Onde:

- n_1, n_2 = tamanhos das amostras dos grupos 1 e 2
- s_1, s_2 = desvios padrão dos grupos 1 e 2

21.3.1.1 Exemplo prático em R

Suponha:

- Grupo 1: média = 10, desvio padrão = 2, n = 30
- Grupo 2: média = 8, desvio padrão = 2.5, n = 35

```
media1 <- 10
media2 <- 8
sd1 <- 2
sd2 <- 2.5
n1 <- 30
n2 <- 35

# Desvio padrão combinado
sp <- sqrt( ((n1-1)*sd1^2 + (n2-1)*sd2^2) / (n1 + n2 - 2) )

# d de Cohen para dados não pareados
d_np <- (media1 - media2) / sp
d_np

## [1] 0.8758557
```

21.3.2 Fórmula para Dados Pareados (Amostras Dependentes)

Quando os dados são pareados (por exemplo, antes e depois para o mesmo grupo de indivíduos), o cálculo do d de Cohen é diferente:

$$d = \frac{d}{s_d}$$

Onde:

- d = média das diferenças entre os pares
- s_d = desvio padrão das diferenças

21.3.2.1 Exemplo prático em R

Suponha que temos as diferenças entre as medições de 5 sujeitos: -0,5; 0; 0,6; 1,2 e 1,7.

```
diferencas <- c(-0.5, 0.0, 0.6, 1.2, 1.7)

media_dif <- mean(diferencas)
sd_dif <- sd(diferencas)

# d de Cohen para dados pareados
```

```
d_p <- media_dif / sd_dif
d_p
```

```
## [1] 0.6771992
```

Valores típicos para d de Cohen:

- **0.2:** efeito pequeno
- **0.5:** efeito médio
- **0.8:** efeito grande

Assim, quanto maior o valor de d, maior a diferença entre os grupos em relação à variabilidade dos dados.

Pense no **d de Cohen** como uma régua que compara a diferença entre as médias de dois grupos, levando em conta o quanto os dados variam dentro desses grupos.

- Se d é pequeno, significa que a diferença entre as médias dos grupos é pequena em relação à “bagunça” (variação) dos dados – ou seja, os grupos são parecidos.
- Se d é grande, significa que a diferença entre as médias é grande em comparação com a variação dos dados – ou seja, os grupos são bem diferentes.

Um valor alto de d indica que os grupos são realmente diferentes entre si, enquanto um valor baixo mostra que eles são muito parecidos, considerando o quanto os dados “dispersam” dentro de cada grupo.

21.4 Exemplos práticos

A seguir, apresento exemplos práticos para Medicina, Psicologia e Educação Física.

21.4.1 Medicina: Comparação de dois tratamentos para dor

Cenário:

Um estudo clínico quer comparar dois medicamentos para dor crônica.

- Tamanho do efeito esperado (Cohen’s d): 0.2 (pequeno)
- Poder desejado: 0.80
- Nível de significância: 0.05

```
library(pwr)
# Calculando o tamanho da amostra necessária para cada grupo
pwr.t.test(d = 0.2, power = 0.8, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 393.4057
##              d = 0.2
##      sig.level = 0.05
##              power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

Tamanho da amostra: 394 em cada grupo

21.4.2 Psicologia: Intervenção para redução de ansiedade

Cenário:

Um psicólogo quer testar se uma nova terapia reduz a ansiedade em relação ao tratamento padrão.

- Tamanho do efeito esperado (Cohen's d): 0.6 (médio/grande)
- Poder desejado: 0.80
- Nível de significância: 0.05

```
library(pwr)
# Calculando o tamanho da amostra necessária para cada grupo
pwr.t.test(d = 0.6, power = 0.8, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 44.58577
##              d = 0.6
##      sig.level = 0.05
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

Tamanho da amostra: 45 em cada grupo

21.4.3 Educação Física: Efeito de um programa de treinamento na performance de corrida

Cenário:

Um preparador físico quer comparar a performance de alunos submetidos a dois programas de treinamento diferentes.

- Tamanho do efeito esperado (Cohen's d): 0.8 (grande)
- Poder desejado: 0.80
- Nível de significância: 0.05

```
library(pwr)
# Calculando o tamanho da amostra necessária para cada grupo
pwr.t.test(d = 0.8, power = 0.8, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 25.52458
##              d = 0.8
##      sig.level = 0.05
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

Tamanho da amostra: 26 em cada grupo

- O resultado de cada função indica o **número mínimo de participantes em cada grupo** para atingir o **poder estatístico** desejado.

21.5 Como calcular o poder do teste quando você já tem o tamanho da amostra

O pacote `pwr` do R não serve apenas para calcular o tamanho da amostra necessário. Ele também permite **descobrir o poder do teste** caso você já saiba quantos participantes terá em cada grupo.

21.5.1 Exemplo

Suponha que você fez um estudo com **26 participantes em cada grupo** e espera encontrar um **tamanho de efeito grande ($d = 0.8$)**. O nível de significância que você escolheu é o padrão, **0,05**. Você quer saber: *com essa amostra, qual é o poder do meu teste?*

Você pode usar:

```
pwr.t.test(n = 26, d = 0.8, power = NULL, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 26
##              d = 0.8
##      sig.level = 0.05
##      power = 0.8074866
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

Explicação dos parâmetros

- `n = 26`: tamanho da amostra em cada grupo já definido.
- `d = 0.8`: tamanho do efeito (Cohen's d), aqui considerado grande.
- `sig.level = 0.05`: nível de significância (chance máxima de um falso positivo).
- `type = "two.sample"`: teste t para dois grupos independentes.
- `power = NULL`: ao deixar o parâmetro `power` em `NULL`, você está dizendo ao R para calcular **qual é o poder do teste** com esses valores.

Nesse caso o poder do teste é de aproximadamente **80,7%** (`power = 0.8074866` na saída acima).

O que acontece nesse cálculo?

O R resolve a equação para o poder estatístico usando os valores que você forneceu. Ou seja, ele vai informar a **probabilidade de detectar uma diferença real (de tamanho $d = 0.8$) entre os grupos, com 26 participantes em cada grupo**, considerando o nível de significância especificado.

Por que isso é útil?

- Se o poder calculado for **menor que 0,80** (80%), pode ser interessante aumentar a amostra para garantir maior chance de detectar diferenças reais.
- Se o poder já for **maior que 0,80**, seu estudo tem boa sensibilidade para o efeito esperado.

Neste exemplo, o poder de 80,7% fica **acima** do mínimo recomendado: com 26 participantes por grupo, o estudo tem boa sensibilidade para detectar um efeito grande ($d = 0.8$). E isso não é coincidência — foi exatamente o `pwr.t.test()` do exemplo anterior que indicou 26 por grupo como o mínimo necessário para esse efeito com 80% de poder.

Resumindo

- Você pode usar `pwr.t.test` para calcular o poder do teste, **bastando informar `n` e deixar `power = NULL`**.
- Isso é útil para analisar experimentos já realizados ou planejar com base em restrições de amostra.

21.6 Cálculo do Tamanho da Amostra para Testes t Pareado e Wilcoxon

Além do teste t para amostras independentes, você pode calcular o tamanho da amostra para outras situações, como o teste t pareado e os testes não paramétricos de Wilcoxon (para amostras pareadas ou não pareadas). Para os testes não paramétricos, recomenda-se aumentar o tamanho da amostra em 15% em relação ao cálculo do teste t correspondente.

21.6.1 Teste t Pareado

Cenário:

Você quer testar se uma intervenção reduz o nível de estresse dos mesmos participantes antes e depois do tratamento.

- Tamanho do efeito esperado (d de Cohen): 0.5
- Poder desejado: 0.80
- Nível de significância: 0.05

```
library(pwr)
# Tamanho da amostra para teste t pareado
pwr.t.test(d = 0.5, power = 0.8, sig.level = 0.05, type = "paired")
```

```
##
##      Paired t test power calculation
##
##              n = 33.36713
##              d = 0.5
##      sig.level = 0.05
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number of *pairs*
```

Observe o argumento **type = "paired"** indicando que o cálculo é para amostras pareadas.

21.6.2 Teste de Wilcoxon para Amostras Não Pareadas

Cenário:

Você deseja comparar dois grupos de pacientes com dados não normalmente distribuídos.

- Tamanho do efeito esperado (d de Cohen): 0.5
- Poder desejado: 0.80
- Nível de significância: 0.05

```
library(pwr)
# Tamanho da amostra para teste t de duas amostras
pwr.t.test(d = 0.5, power = 0.8, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 63.76561
##              d = 0.5
##      sig.level = 0.05
##      power = 0.8
```

```
## alternative = two.sided
##
## NOTE: n is number in *each* group
# Acrescentar 15% para o teste de Wilcoxon
63.76 * 1.15
```

```
## [1] 73.324
```

Acrescentando 15% ao cálculo amostral realizado com o `pwr.t.test`, são necessárias 74 amostras. Os testes não paramétricos, como o teste de Wilcoxon, geralmente apresentam menor poder estatístico em comparação aos testes paramétricos. Para compensar essa diferença e obter um poder semelhante ao dos testes paramétricos, recomenda-se aumentar o tamanho da amostra em cerca de 15%. Assim, o teste não paramétrico passa a ter uma chance semelhante de detectar um efeito real, caso ele exista.

21.6.3 Teste de Wilcoxon Pareado

Cenário:

Você avalia o desempenho dos mesmos alunos antes e depois de um programa de treinamento, com dados não normalmente distribuídos.

- Tamanho do efeito esperado (d de Cohen): 0.5
- Poder desejado: 0.80
- Nível de significância: 0.05

```
library(pwr)
# Tamanho da amostra para teste t pareado
pwr.t.test(d = 0.5, power = 0.8, sig.level = 0.05, type = "paired")
```

```
##
## Paired t test power calculation
##
## n = 33.36713
## d = 0.5
## sig.level = 0.05
## power = 0.8
## alternative = two.sided
##
## NOTE: n is number of *pairs*
# Acrescentar 15% para o teste de Wilcoxon
34 * 1.15
```

```
## [1] 39.1
```

Acrescentando 15% ao cálculo amostral realizado com o `pwr.t.test`, são necessárias aproximadamente 40 amostras.

Chapter 22

Mememes de Estatística: p-valor

O p-valor é um dos conceitos mais populares (e polêmicos) da estatística. A seguir, veja alguns memes famosos sobre p-valor, acompanhados de interpretações e tradução para o português.

Mememes ajudam a ilustrar de forma divertida como o p-valor é frequentemente mal interpretado ou supervalorizado. Rejeitar H_0 não é tudo: pense criticamente sobre seus resultados!

22.1 Quando você encontra um p-valor baixo e sabe que deve rejeitar H_0




Figure 22.1: Fonte: <https://library.fiveable.me/ap-stats/unit-6/concluding-test-for-population-proportion/study-guide/THZeUpkm11DAwnNb6p4g>

Tradução:

Quando você encontra um p-valor baixo e sabe que deve rejeitar a hipótese nula.

Interpretação:

O meme brinca com o entusiasmo de muitos pesquisadores ao encontrar um p-valor baixo (menor que 0,05),

pois sabem que isso permite rejeitar a hipótese nula (H_0). No entanto, é importante lembrar que rejeitar H_0 não garante que o resultado seja relevante do ponto de vista prático ou científico. O p-valor indica o quanto os resultados observados seriam inesperados caso a hipótese nula fosse verdadeira, mas não informa o tamanho ou a relevância prática dessa diferença encontrada.

22.2 Homem-Aranha apontando




Figure 22.2: Fonte: <https://danawanzer.github.io/stats-with-jamovi/alpha-p-values.html>

Tradução:

$P < 0,05$

Rejeitar a hipótese nula

Estatisticamente significativo

Interpretação:

Esse meme mostra como as pessoas frequentemente confundem ou usam como sinônimos as expressões “ $p < 0,05$ ”, “rejeitar a hipótese nula” e “significância estatística”. Na prática, são conceitos relacionados, mas não exatamente iguais: um p-valor menor que o nível de significância leva à rejeição de H_0 , o que é chamado de resultado estatisticamente significativo. Mas lembre-se: um resultado pode ser estatisticamente significativo e, mesmo assim, não ter importância prática no mundo real.

22.3 Namorado distraído



Figure 22.3: Fonte: <https://imgflip.com/i/2b00xk>

Tradução:

p-valor 0,083

>

Nível de significância 0,05

Interpretação:

O pesquisador está andando tranquilamente com sua fiel companheira, o nível de significância 0,05, mas não resiste e joga aquele olhar para o p-valor 0,083 que acabou de passar. Mesmo sabendo que, tecnicamente, 0,083 é “maior” do que 0,05 e não deveria chamar tanta atenção, ele fica tentado a inventar desculpas para dar uma chance àquele resultado quase-significativo: “ah, mas foi quase!”, “quem nunca, né?”. No fundo, esse é o típico caso do pesquisador que se empolga com resultados que chegaram perto do valor de corte, tentando transformar um “quase” em uma grande descoberta. Mas é importante lembrar: resultado quase significativo ainda não é significativo!

22.4 Willy Wonka e o p-valor menor que 0,05

Tradução:

Ah, você encontrou um p-valor menor que 0,05?

Por favor, me conte tudo sobre sua grande descoberta.

Interpretação:

Willy Wonka ironiza a empolgação de quem encontra um p-valor abaixo de 0,05, sugerindo que nem sempre isso significa uma grande descoberta. O meme alerta para a importância de interpretar o p-valor no contexto



Figure 22.4: Fonte: <https://naturallyspeaking.blog/2015/06/03/episode-25-the-problem-with-p-values/>

do estudo, considerando tamanho de efeito, relevância prática e outros fatores além da simples significância estatística. O próprio Wonka pediria: “me convença de que seu resultado importa de verdade!”

22.5 Cantada Nerd

Tradução:

Ei, garota, seu p deve ser maior que 0,05, porque eu falho em te rejeitar.

Interpretação:

Esse meme faz uma brincadeira romântica usando a linguagem estatística: em vez de rejeitar a hipótese nula, a pessoa está dizendo que não consegue rejeitar a garota, assim como um p -valor acima de 0,05 geralmente significa que não rejeitamos H_0 . É o clássico “não posso te rejeitar, cientificamente falando!” Uma piada para conquistar corações e estatísticos ao mesmo tempo.

22.6 P-valor não é tudo

Tradução:

Cena de duas pessoas no carro, uma com expressão de frustração ao ouvir “ p -values”, enquanto a outra está alegre ou satisfeita.

Interpretação:

A graça do meme está justamente no contraste entre frustração e alegria: enquanto uma pessoa demonstra cansaço ou desapontamento ao ouvir sobre p -values de novo, a outra parece satisfeita só com isso. O meme brinca com as diferentes expectativas na análise estatística, há quem se contente apenas com a significância estatística ($p < 0,05$), enquanto outros esperam uma análise completa, considerando também o tamanho do efeito, intervalos de confiança, e a real relevância dos achados. É um lembrete de que estatística vai além do p -value!



Figure 22.5: Fonte: <https://varshitasher.medium.com/memorizing-p-value-interpretation-through-coronavirus-76e36606b5ff>





Figure 22.6: Fonte: https://x.com/data_question/status/1675416773665890304

22.7 Coitado do tamanho do efeito

**Tradução:**

À esquerda, uma fila enorme se forma na barraca “p-values”. À direita, a barraca “effect sizes” está vazia, quase ouvindo grilos.

Interpretação:

Este meme é o retrato da triste (e hilária) realidade dos artigos científicos: todo mundo corre para saber se o valor de p é menor que 0,05, como se fosse a última coca-cola do deserto. Já o tamanho do efeito, que realmente diz se o resultado é relevante, é solenemente ignorado. Moral estatística: enquanto os p -values lotam (mesmo que tragam resultados irrelevantes), o effect size fica sozinho no canto, esperando alguém notar sua real importância. Quem entende estatística sabe: tamanho do efeito merece atenção!



Figure 22.7: Formato “One does not simply”, de O Senhor dos Anéis

22.8 Senhora estatística

Tradução:

Em cima: “ONE DOES NOT SIMPLY” (“SIMPLESMENTE NÃO SE...”) Embaixo: “REPORT P-VALUES WITHOUT EFFECT SIZES” (“RELATA P-VALORES SEM TAMANHOS DE EFEITO”)

Interpretação:

Esse meme faz referência ao clássico da cultura pop (O Senhor dos Anéis) para lembrar que estatística não é terra sem lei: não basta encontrar um $p < 0,05$ e sair comemorando. Relatar apenas o valor de p é igual a contar só metade da fofoca: falta o contexto! O tamanho do efeito é quem diz se a diferença é daquelas que mudam a vida ou se é só uma diferença microscópica e irrelevante. Em outras palavras, estatística de verdade combina significado estatístico (p-value) com significado prático (effect size). Não faça estatística “pela metade”!

22.9 Pobre do gatinho

Tradução:

Primeira cena: Pessoa abraça um cachorro chamado “P-VALUES”. Atrás, um gato (effect sizes) observa, excluído.

Demais cenas: Close no gato “effect sizes”, visivelmente triste, segurando um brinquedo, ignorado.

Interpretação:

O meme mostra o drama dos tamanhos de efeito: sempre deixados de lado, enquanto os p-values recebem todo o carinho e atenção. É como se o cachorro (p-value) ganhasse petiscos só por latir, enquanto o gato (effect size), que realmente entrega o conteúdo, só observa de longe. Estatisticamente, é como celebrar um resultado significativo sem saber se ele realmente importa no mundo real. O gato chora, e o revisor do artigo também!

Esses memes ilustram, com bom humor, que o p-valor sozinho não conta toda a história. Um resultado estatisticamente significativo não garante relevância prática. O tamanho do efeito é fundamental para avaliar se uma diferença observada tem impacto real, e não apenas estatístico. Ao analisar dados, valorize tanto o p-valor quanto o tamanho do efeito para conclusões mais robustas e informativas.



Figure 22.8: Fonte: https://x.com/Jente_O/status/1698942647493153251

Chapter 23

Pacotes `pwr`, `rstatix` e `effsize`

Nesse capítulo, abordaremos como calcular tamanho de amostra, poder estatístico e tamanho do efeito em diferentes testes estatísticos usando os pacotes `pwr`, `rstatix` e `effsize`. O foco será nos testes t (pareado e não pareado) e Wilcoxon (pareado e não pareado), com exemplos práticos e orientações sobre interpretação dos resultados.

Importante: Antes de começar, certifique-se de instalar o pacote `pwr`, `rstatix` e `effsize`:

```
install.packages(c("pwr", "rstatix", "effsize"))
```

23.1 Cálculos de tamanho de amostra, poder e efeito com o pacote `pwr`

O pacote `pwr` permite calcular:

- **Tamanho de amostra** necessário para detectar um determinado efeito;
- **Poder estatístico** de um teste para amostras de tamanho fixo;
- **Menor tamanho de efeito** que pode ser detectado para um dado poder e amostra.

23.1.1 Exercício 1: Tamanho da amostra para teste t não pareado

Calcule o tamanho da amostra necessário para detectar um efeito moderado ($d = 0.5$), com poder de 0.8 e nível de significância de 0.05, em um teste t bilateral para duas amostras independentes.

```
library(pwr)
# Tamanho da amostra para teste t não pareado
pwr.t.test(d = 0.5, power = 0.8, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 63.76561
##              d = 0.5
##      sig.level = 0.05
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

23.1.2 Exercício 2: Poder do teste t não pareado para n fixo

Se você dispõe de 26 observações em cada grupo, qual é o poder do teste para detectar um efeito de 0.5, com $\text{sig.level} = 0.05$?

```
# Poder do teste t não pareado para n = 26 por grupo
pwr.t.test(n = 26, d = 0.5, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 26
##              d = 0.5
##      sig.level = 0.05
##      power = 0.4240344
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

23.1.3 Exercício 3: Menor efeito detectável no teste t não pareado

Com 26 observações por grupo, poder de 0.8 e sig.level de 0.05, qual o menor tamanho de efeito detectável?

```
# Tamanho do efeito detectável
pwr.t.test(n = 26, power = 0.8, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 26
##              d = 0.7923522
##      sig.level = 0.05
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

23.1.4 Exercício 4: Repita para outros testes

23.1.4.1 a) Teste t pareado

```
# Tamanho da amostra para teste t pareado
pwr.t.test(d = 0.5, power = 0.8, sig.level = 0.05, type = "paired")
```

```
##
##      Paired t test power calculation
##
##              n = 33.36713
##              d = 0.5
##      sig.level = 0.05
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number of *pairs*
```

```
# Poder para n = 26 pares
pwr.t.test(n = 26, d = 0.5, sig.level = 0.05, type = "paired")
```

```
##
##      Paired t test power calculation
##
##              n = 26
##              d = 0.5
##      sig.level = 0.05
##      power = 0.6881801
##      alternative = two.sided
##
## NOTE: n is number of *pairs*
# Tamanho do efeito detectável
pwr.t.test(n = 26, power = 0.8, sig.level = 0.05, type = "paired")
```

```
##
##      Paired t test power calculation
##
##              n = 26
##              d = 0.5717051
##      sig.level = 0.05
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number of *pairs*
```

23.1.4.2 b) Wilcoxon não pareado

```
# Tamanho da amostra para Wilcoxon não pareado (aproximação pelo teste t)
pwr.t.test(d = 0.5, power = 0.8, sig.level = 0.05, type = "two.sample")
```

```
##
##      Two-sample t test power calculation
##
##              n = 63.76561
##              d = 0.5
##      sig.level = 0.05
##      power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

Dica: O pacote `pwr` não possui funções específicas para testes não-paramétricos como Wilcoxon. Por isso, costuma-se usar o cálculo para teste t como aproximação, aumentando o tamanho da amostra em cerca de 15% (multiplique o valor obtido por 1,15), já que testes não-paramétricos geralmente requerem amostras maiores para o mesmo poder estatístico.

```
# Recalculando o tamanho da amostra
63.76561*1.15
```

```
## [1] 73.33045
```

O tamanho do efeito para o teste de Wilcoxon pode ser aproximado por $d \in 0,86$, sendo d o tamanho do efeito de Cohen, desde que as distribuições dos grupos sejam aproximadamente normais e com variâncias semelhantes (Lehmann, 2006; Noether, 1987).

```
# Poder da amostra para Wilcoxon não pareado (aproximação pelo teste t)
pwr.t.test(n = 26, d = 0.5*0.86, sig.level = 0.05, type = "two.sample")
```

```
##
```

```
##      Two-sample t test power calculation
##
##          n = 26
##          d = 0.43
##      sig.level = 0.05
##          power = 0.3304646
##      alternative = two.sided
##
## NOTE: n is number in *each* group
```

23.1.4.3 c) Wilcoxon pareado

```
# Tamanho da amostra para Wilcoxon pareado (aproximação pelo teste t pareado)
pwr.t.test(d = 0.5, power = 0.8, sig.level = 0.05, type = "paired")
```

```
##
##      Paired t test power calculation
##
##          n = 33.36713
##          d = 0.5
##      sig.level = 0.05
##          power = 0.8
##      alternative = two.sided
##
## NOTE: n is number of *pairs*
```

```
# Poder da amostra para Wilcoxon PAREADO (aproximação pelo teste t pareado)
pwr.t.test(n = 26, d = 0.5*0.86, sig.level = 0.05, type = "paired")
```

```
##
##      Paired t test power calculation
##
##          n = 26
##          d = 0.43
##      sig.level = 0.05
##          power = 0.5588403
##      alternative = two.sided
##
## NOTE: n is number of *pairs*
```

Atenção: O **d de Cohen** foi criado para testes paramétricos, como o teste t. Para testes não paramétricos (Wilcoxon), utilize medidas específicas, pois a interpretação do d não se aplica ao contexto de ranks.

23.1.5 Argumentos principais da função `pwr.t.test()`

A função `pwr.t.test()` possui os seguintes argumentos principais:

- **n:** tamanho da amostra em cada grupo (ou número de pares, para teste pareado)
- **d:** tamanho do efeito (diferença padronizada entre grupos)
- **power:** poder estatístico desejado
- **sig.level:** nível de significância (geralmente 0.05)
- **type:** tipo de teste t: "two.sample", "paired" ou "one.sample"

Dica: Deixe como NULL o parâmetro que você deseja calcular. - Para calcular o tamanho do efeito: `d = NULL` - Para calcular o poder: `power = NULL` - Para calcular o tamanho da amostra: `n = NULL`

Exemplo para calcular o tamanho do efeito:

```
pwr.t.test(n = 26, d = NULL, power = 0.8, sig.level = 0.05, type = "two.sample")
```

Neste exemplo, o argumento `d` é o valor a ser calculado.

23.1.6 Grupos Desbalanceados: usando `pwr.t2n.test()`

Quando os grupos têm tamanhos diferentes, use `pwr.t2n.test()` para calcular o poder.

```
# Exemplo: grupo 1 com 95, grupo 2 com 30 observações
library(pwr)
pwr.t2n.test(n1 = 95, n2 = 30, d = 0.5, sig.level = 0.05)
```

```
##
##      t test power calculation
##
##              n1 = 95
##              n2 = 30
##              d = 0.5
##      sig.level = 0.05
##      power = 0.6586749
##      alternative = two.sided
```

- **n1**: tamanho do primeiro grupo
- **n2**: tamanho do segundo grupo

Atenção: Grupos desbalanceados podem comprometer o poder do teste, aumentar a variância e dificultar a interpretação dos resultados. Sempre que possível, busque amostras equilibradas.

23.2 Tamanho do efeito em testes de Wilcoxon

O tamanho do efeito complementa a análise estatística, indicando a magnitude da diferença entre grupos. Para testes paramétricos (como o `t`), usa-se o **d de Cohen**. Para testes não paramétricos (Wilcoxon), utilize medidas apropriadas, como **r de Wilcoxon** e **Delta de Cliff**.

23.2.1 Por que NÃO usar d de Cohen no Wilcoxon?

- O `d` de Cohen pressupõe distribuição normal e comparação direta de médias/desvios.
- O Wilcoxon compara **ranks**, não médias.
- Aplicar o `d` de Cohen em dados de Wilcoxon pode gerar interpretações erradas.

23.2.2 Medidas recomendadas para Wilcoxon:

- **r de Wilcoxon**: Calculado com o pacote `rstatix`.
- **Cliff's Delta**: Disponível no pacote `effsize`.

23.2.2.1 r de Wilcoxon (Wilcoxon rank-sum, não pareado)

```
library(rstatix)
library(readr)


# Importe o banco de dados Pokemon
Pokemon <- read_csv("https://ana-mat-br.github.io/dados/Pokemon.csv")
```

```
# Subconjunto com Pokémons verdes ou amarelos
dados_filtrados <- subset(Pokemon, Color %in% c("Green", "Yellow"))

# Verifique os dados após o filtro
print(table(dados_filtrados$Color))
```

```
##
##  Green Yellow
##    79    64
```

```
# Boxplot
boxplot(dados_filtrados$Speed ~ dados_filtrados$Color)
```



```
# Teste de Wilcoxon não pareado
wilcox.test(dados_filtrados$Speed ~ dados_filtrados$Color)
```

```
##
##  Wilcoxon rank sum test with continuity correction
##
## data:  dados_filtrados$Speed by dados_filtrados$Color
## W = 1920.5, p-value = 0.01363
## alternative hypothesis: true location shift is not equal to 0
```

```
# Tamanho do efeito r de Wilcoxon para Green vs Yellow
wilcox_effsize(dados_filtrados, Speed ~ Color)
```

```
## # A tibble: 1 x 7
##   .y. group1 group2 effsize    n1    n2 magnitude
## * <chr> <chr>  <chr>    <dbl> <int> <int> <ord>
## 1 Speed Green  Yellow  0.206   79   64 small
```

```
# Ordem em que os grupos são comparados
unique(dados_filtrados$Color)
```

```
## [1] "Green" "Yellow"
```

A tabela apresentada é resultado da função `wilcox_effsize()` do pacote `rstatix` e resume o tamanho do efeito (r de Wilcoxon) para a comparação entre dois grupos (“Green” e “Yellow”) em relação à variável

“Speed”. Veja como interpretar cada coluna:

- **.y.:** variável de interesse analisada, neste caso, “Speed” (velocidade dos Pokémons).
- **group1:** primeiro grupo comparado (“Green”).
- **group2:** segundo grupo comparado (“Yellow”).
- **effsize:** valor ABSOLUTO do tamanho de efeito calculado, aqui 0.206.
- O resultado apresentado na coluna **effsize** é sempre positivo, independentemente da ordem dos grupos definidos na variável categórica.
- **n1:** número de observações no grupo 1 (79 Pokémons verdes).
- **n2:** número de observações no grupo 2 (64 Pokémons amarelos).
- **magnitude:** classificação qualitativa do tamanho de efeito (“small”, ou seja, efeito pequeno).

Interpretação:

A diferença de velocidade entre Pokémons verdes e amarelos é estatisticamente significativa ($W = 1920.5$, $p\text{-value} = 0.01363$), porém de **pequena magnitude** ($r = 0.206$). Isso indica que, embora exista uma diferença, ela é discreta do ponto de vista prático.

No caso de teste pareado, os dados precisam estar no **formato longo** (uma linha por observação, com uma coluna de valor e uma coluna indicando o momento), como fazemos no capítulo de comparação entre mais de dois grupos com a função `pivot_longer()`. Aí basta acrescentar o argumento `paired = TRUE`:

```
wilcox_effsize(dados_long, nota ~ momento, paired = TRUE)
```

23.2.2.2 Delta de Cliff

```
library(effsize)

# Calcule o Delta de Cliff
cliff.delta(dados_filtrados$Speed ~ dados_filtrados$Color)

##
## Cliff's Delta
##
## delta estimate: -0.2403085 (small)
## 95 percent confidence interval:
##      lower      upper
## -0.41405995 -0.04966082
```

O **Delta de Cliff** estimado foi de **-0,24**, classificado como efeito **pequeno** (“small”). O intervalo de confiança de 95% vai de aproximadamente **-0,41** a **-0,05**, indicando que, com alta confiança, o efeito verdadeiro é negativo e pequeno.

- **Sinal negativo:** Indica que o grupo “Yellow” tende a apresentar velocidades maiores do que o grupo “Green”. Ou seja, ao comparar aleatoriamente um Pokémon amarelo com um verde, é mais provável que o amarelo tenha uma velocidade superior.
- **Magnitude pequena:** O valor absoluto de -0,24 mostra que a diferença entre os grupos existe, mas é de pouca relevância prática.
- **Intervalo de confiança não inclui zero:** Como o intervalo vai de -0,41 a -0,05, podemos afirmar que existe uma diferença real entre os grupos, embora seja pequena.
- **Interpretação prática:** Apesar de haver uma diferença estatística, ela não é marcante. É importante avaliar se essa diferença tem relevância biológica ou prática no contexto do seu estudo.

O Delta de Cliff indica que Pokémons amarelos tendem a ser um pouco mais rápidos do que os verdes, mas a diferença é pequena do ponto de vista prático.

23.2.3 Comparação entre o r de Wilcoxon e o Delta de Cliff

Quando realizamos testes não paramétricos para comparar grupos, como o teste de Wilcoxon (Mann-Whitney ou Wilcoxon pareado), é importante complementar o resultado do teste com uma medida de tamanho de efeito. As duas opções mais comuns são o **r de Wilcoxon** e o **Delta de Cliff**. Veja a seguir uma comparação entre elas:

23.2.4 r de Wilcoxon

- **Definição:** Mede a magnitude da diferença entre grupos com base nos postos (ranks) dos dados. O cálculo é semelhante ao coeficiente de correlação de Pearson, mas aplicado a dados não paramétricos.
- **Variação dos valores:** O r de Wilcoxon varia de -1 a 1.
 - Valores próximos de 0 indicam pouca diferença entre grupos.
 - Valores próximos de -1 ou 1 indicam diferenças muito grandes.
 - O sinal indica a direção da diferença.

Qualificação dos valores, segundo Cohen (1988):

Valor absoluto de r	Interpretação
aproximadamente 0,10	Pequeno
aproximadamente 0,30	Moderado
maior ou igual a 0,50	Grande

Exemplos:

- **Efeito pequeno:**
Se o valor absoluto de r estiver próximo de **0,10**, a diferença entre os grupos é pequena.
(Exemplo: $|r| = 0,10$ efeito pequeno)
- **Efeito moderado:**
Se o valor absoluto de r estiver próximo de **0,30**, a diferença entre os grupos é moderada.
(Exemplo: $|r| = 0,30$ efeito moderado)
- **Efeito grande:**
Se o valor absoluto de r for igual ou superior a **0,50**, a diferença é grande.
(Exemplo: $|r| = 0,55$ efeito grande)

23.2.5 Delta de Cliff ()

- **Definição:** Mede a probabilidade de um valor de um grupo ser maior do que de outro grupo, subtraída da probabilidade contrária. É totalmente não paramétrico e não depende de distribuição, sendo adequado para variáveis ordinais ou dados assimétricos.
- **Variação dos valores:** O Delta de Cliff varia de -1 a 1.
 - Valor 0: não há diferença entre os grupos.
 - Valor positivo: o grupo 1 tende a ter valores maiores que o grupo 2.
 - Valor negativo: o grupo 2 tende a ter valores maiores que o grupo 1.
- **Como interpretar os valores do Delta de Cliff?**
O **Delta de Cliff** mostra o tamanho da diferença entre dois grupos. O mais comum é considerar o valor absoluto de (ou seja, ignorar se é positivo ou negativo e olhar só para o tamanho do número).

Classificação da magnitude do efeito, segundo Romano et al. (2006)

Valor absoluto de	Interpretação
menor que 0.147	Desprezível
de 0.147 e menor que 0.33	Pequeno
de 0.33 e menor que 0.474	Médio
maior ou igual a 0.474	Grande

Exemplos:

- **Efeito desprezível:**
Se o valor absoluto do delta for menor que **0,147**, a diferença entre os grupos é desprezível.
(Exemplo: $|| = 0,10$ efeito desprezível)
- **Efeito pequeno:**
Se o valor absoluto do delta for igual ou maior que **0,147** e menor que **0,33**, a diferença é pequena.
(Exemplo: $|| = 0,20$ efeito pequeno)
- **Efeito médio:**
Se o valor absoluto do delta for igual ou maior que **0,33** e menor que **0,474**, a diferença é média.
(Exemplo: $|| = 0,40$ efeito médio)
- **Efeito grande:**
Se o valor absoluto do delta for igual ou maior que **0,474**, a diferença é grande.
(Exemplo: $|| = 0,50$ efeito grande)

Resumindo:

Quanto mais próximo de zero, menor a diferença. Quanto mais próximo de 1 (ou -1), maior a diferença entre os grupos.

Dica: Sempre use o valor absoluto, ou seja, olhe apenas para o tamanho do número, sem se preocupar se ele é positivo ou negativo.

23.2.6 Qual é melhor usar?

- **Ambos** são válidos e amplamente aceitos para dados não paramétricos.
- O **r de Wilcoxon** é intuitivo se você já está acostumado com o coeficiente de correlação, e é facilmente interpretável em contextos onde se deseja uma analogia ao r de Pearson.
- O **Delta de Cliff** é mais robusto em situações com muitos empates, diferentes tamanhos de grupo ou dados ordinais, e fornece uma interpretação mais direta da diferença de probabilidades entre grupos.
- **Recomendação prática:**
 - Para estudos com dados ordenados, amostras desbalanceadas ou muitos empates, o Delta de Cliff pode ser preferido.
 - Se você busca uma medida análoga ao r de Pearson para facilitar comparações, use o r de Wilcoxon.
 - Em muitos casos, apresentar ambos os valores enriquece a interpretação dos resultados.

Não existe uma medida “melhor” de forma absoluta; a escolha depende do contexto do estudo e das características dos dados. Ambas são úteis para interpretar a relevância prática das diferenças identificadas em testes não paramétricos.

Nota: Para a comparação entre os grupos *Green* e *Yellow* na variável *Speed*, o tamanho de efeito calculado pelo **r de Wilcoxon** foi **0,206** (efeito pequeno), enquanto o **delta de Cliff** foi **-0,240** (efeito pequeno, IC 95%: -0,414 a -0,050). É esperado que os valores numéricos dessas métricas difiram, pois são baseados em cálculos estatísticos distintos, mas ambos apontam para uma diferença de pequena magnitude entre os grupos.

No entanto, é importante destacar que, neste caso, o valor negativo do delta de Cliff está condizente com o observado no boxplot: o grupo *Yellow* tende a apresentar valores de *Speed* ligeiramente maiores que o grupo *Green*, o que é evidenciado pela direção negativa do delta.

Esse alinhamento entre o resultado numérico do delta de Cliff e a visualização gráfica reforça a importância de sempre analisar os dados de forma complementar, utilizando tanto medidas estatísticas quanto representações visuais (como boxplots). A visualização gráfica pode revelar padrões, tendências e assimetrias que enriquecem a interpretação do tamanho de efeito e facilitam a comunicação dos resultados.

Chapter 24

Teste de Normalidade

Antes de aplicar muitos testes estatísticos, é importante verificar se os dados seguem uma distribuição normal (ou “distribuição gaussiana”). Essa etapa é fundamental porque vários testes paramétricos (como o teste t de Student e a ANOVA) assumem a normalidade dos dados. Quando essa condição não é atendida, a escolha do teste estatístico pode mudar para opções não paramétricas.

24.1 Hipóteses nos Testes de Normalidade

Os testes de normalidade propriamente ditos avaliam as seguintes hipóteses:

- **Hipótese Nula (H):** Os dados seguem uma distribuição normal.
- **Hipótese Alternativa (H):** Os dados **não** seguem uma distribuição normal.

Atenção: existem também testes que examinam apenas um aspecto da normalidade, como a assimetria ou a curtose isoladamente. Neles a hipótese nula é outra (por exemplo, “a assimetria é igual a zero”), e um resultado não significativo não garante normalidade. Veremos um caso desses adiante.

- Se o valor de p for menor que 0,05: **Rejeitamos** a hipótese nula.
- Se o valor de p for maior ou igual a 0,05: **Não rejeitamos** a hipótese nula.

24.2 Principais Testes de Normalidade

Abaixo estão os testes de normalidade mais conhecidos, quando são mais recomendados e os pacotes em R:

Teste	Quando Usar	Pacote no R
Shapiro-Wilk	Amostras pequenas e médias ($n < 50$ até ~ 2000)	stats
Kolmogorov-Smirnov (K-S)	Amostras maiores; pode comparar duas distribuições, mas menos potente para normalidade	stats
Lilliefors	Versão do K-S ajustado para média e desvio amostrais	nortest
Anderson-Darling	Mais sensível nas caudas da distribuição; recomendado para médias e grandes amostras	nortest
Jarque-Bera	Teste baseado em assimetria (skewness) e curtose (kurtosis); comum em econometria	tseries
D’Agostino (assimetria)	Testa apenas se a assimetria difere de zero — não é um teste de normalidade completo	moments
Anscombe-Glynn (curtose)	Testa apenas se a curtose difere da esperada na Normal	moments

24.2.1 Dicas de Uso

- Para **amostras pequenas** ($n < 50$): prefira o **Shapiro-Wilk** (função `shapiro.test()` do pacote `base` stats).
- Para **amostras médias a grandes**: considere **Anderson-Darling** (`ad.test()` do pacote `nortest`).
- Para investigar **por que** os dados fogem da normalidade, use `agostino.test()` (assimetria) e `anscombe.test()` (curtose), ambos do pacote `moments`. Atenção: cada um testa um aspecto isolado, não a normalidade como um todo.
- O **Kolmogorov-Smirnov** (`ks.test()`) é mais geral, mas menos recomendado quando a média e desvio padrão são estimados dos próprios dados.
- O **Lilliefors** (`lillie.test()` do pacote `nortest`) é uma boa alternativa ao K-S para dados amostrais.
- Para análises em econometria ou séries temporais, o **Jarque-Bera** (`jarque.bera.test()` do pacote `tseries`) é bastante utilizado.


24.2.2 Exemplo Prático em R

```
#install.packages("nortest")
#install.packages("moments")

# Importe o banco de dados Pokemon
library(readr)
Pokemon <- read_csv("https://ana-mat-br.github.io/dados/Pokemon.csv")

# Veja o QQ
qqnorm(Pokemon$Speed)
qqline(Pokemon$Speed)
```

Normal Q-Q Plot



```
# Shapiro-Wilk
shapiro.test(Pokemon$Speed)
```

```
##
##  Shapiro-Wilk normality test
##
```

```
## data: Pokemon$Speed
## W = 0.98574, p-value = 1.757e-06

# Anderson-Darling
library(nortest)
ad.test(Pokemon$Speed)

##
## Anderson-Darling normality test
##
## data: Pokemon$Speed
## A = 3.0665, p-value = 1.064e-07

# Lilliefors
lillie.test(Pokemon$Speed)

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: Pokemon$Speed
## D = 0.06446, p-value = 1.662e-07

# D'Agostino: testa APENAS a assimetria (H0: assimetria = 0)
library(moments)
agostino.test(Pokemon$Speed)

##
## D'Agostino skewness test
##
## data: Pokemon$Speed
## skew = 0.27799, z = 3.02335, p-value = 0.0025
## alternative hypothesis: data have a skewness

# Anscombe-Glynn: testa APENAS a curtose (H0: curtose = 3)
anscombe.test(Pokemon$Speed)

##
## Anscombe-Glynn kurtosis test
##
## data: Pokemon$Speed
## kurt = 2.5486, z = -3.1154, p-value = 0.001837
## alternative hypothesis: kurtosis is not equal to 3
```

Repare na saída dos dois últimos testes: o R imprime “*D’Agostino skewness test*” e “*Anscombe-Glynn kurtosis test*”. Eles respondem a perguntas específicas — a distribuição é assimétrica? é mais pontuda ou mais achatada que a Normal? — e complementam os testes de normalidade, mas não os substituem.

Resumo

- Sempre comece analisando a normalidade dos seus dados.
- Escolha o teste de acordo com o tamanho da amostra e o objetivo da análise.
- Use gráficos (histograma, boxplot e principalmente o QQ) junto com testes estatísticos para uma análise mais completa.

Importante: Testes de normalidade são sensíveis ao tamanho da amostra. Em amostras muito grandes, pequenos desvios podem resultar em p-valores baixos; em amostras pequenas, a potência dos testes é baixa.

24.3 Assimetria e Curtose: O que são e por que são importantes?

Quando analisamos dados, é importante entender não só a média e o desvio padrão, mas também o **formato da distribuição** dos valores. Duas medidas ajudam muito nisso: **assimetria** e **curtose**. Vamos entender cada uma de forma simples:

24.3.1 O que é Assimetria (Skewness)?

A **assimetria** mostra se os dados estão “puxados” para algum lado, ou seja, se a distribuição tem uma cauda maior para a direita ou para a esquerda.

- **Assimetria zero:** Os dados estão distribuídos de forma equilibrada ao redor da média (exemplo: distribuição normal perfeita).
- **Assimetria positiva (à direita):** A cauda é mais longa à direita, ou seja, há mais valores extremos acima da média.
- **Assimetria negativa (à esquerda):** A cauda é mais longa à esquerda, há mais valores extremos abaixo da média.

Por que isso importa?

A distribuição Normal é um exemplo de distribuição simétrica.

24.3.2 O que é Curtose (Kurtosis)?

A **curtose** indica o quanto a distribuição é “pontuda” ou “achatada” em relação à Distribuição Normal.

- **Curtose alta (leptocúrtica):** Distribuição muito “pontuda”, com muitas observações próximas da média, mas também mais valores extremos (outliers).
- **Curtose baixa (platicúrtica):** Distribuição mais achatada, com menos valores extremos.
- **Curtose média (mesocúrtica):** Parecida com a distribuição normal.

Por que isso importa?

A presença de muita curtose (valores muito altos ou baixos) pode indicar que há mais outliers do que o esperado, o que também pode afetar os resultados de testes estatísticos.

- **Assimetria:** mostra se a distribuição “pende” para um lado.
- **Curtose:** mostra se a distribuição é “pontuda” e cheia de extremos, ou mais “achatada”.

Essas duas medidas ajudam a entender melhor o comportamento dos seus dados e garantem que você escolha os testes estatísticos mais adequados para a sua análise!

Chapter 25

Comparação de mais de dois grupos

Assim como na comparação entre dois grupos, ao desejarmos comparar mais de dois grupos em uma análise estatística, é fundamental selecionar o teste mais adequado de acordo com as características dos dados. Os testes podem ser **paramétricos** ou **não paramétricos**, e a escolha correta depende da verificação prévia de alguns pressupostos, como normalidade, homogeneidade de variâncias e independência das observações.

25.1 Revisando as hipóteses da comparação entre dois grupos

- **Paramétrico (Teste t)**
 - **Não pareado (t de Student):**
 - * H: As médias dos dois grupos são iguais (=)
 - * H: As médias dos dois grupos são diferentes (≠)
 - **Pareado (t pareado):**
 - * H: A média das diferenças entre os pares é igual a zero ($\mu_d = 0$)
 - * H: A média das diferenças entre os pares é diferente de zero ($\mu_d \neq 0$)
- **Não paramétrico**
 - **Não pareado (Mann-Whitney/Wilcoxon rank-sum):**
 - * H: As distribuições dos dois grupos são iguais
 - * H: As distribuições dos dois grupos são diferentes
 - **Pareado (Wilcoxon signed-rank):**
 - * H: A distribuição das diferenças entre os pares é simétrica em torno de zero
 - * H: A distribuição das diferenças entre os pares não é simétrica em torno de zero

Na comparação entre **dois grupos**, tanto nos testes paramétricos quanto nos não paramétricos, a hipótese nula (H_0) geralmente afirma que as médias (ou distribuições) dos dois grupos são iguais, enquanto a hipótese alternativa (H_a) aponta que elas são diferentes. Ou seja, o teste busca identificar uma diferença específica entre os dois grupos analisados.

25.2 Hipóteses para a comparação entre mais de dois grupos

- **Paramétrico (ANOVA)**
 - **Não pareado (ANOVA one-way):**
 - * H: As médias dos grupos são todas iguais ($\mu_1 = \mu_2 = \dots = \mu_k$)
 - * H: Pelo menos uma média de grupo é diferente das outras
 - **Pareado (ANOVA de medidas repetidas):**
 - * H: As médias dos tratamentos (ou condições) são iguais
 - * H: Pelo menos uma média de tratamento é diferente das outras
- **Não paramétrico**
 - **Não pareado (Kruskal-Wallis):**
 - * H: As distribuições dos grupos são todas iguais
 - * H: Pelo menos uma distribuição de grupo é diferente das outras

– **Pareado (Friedman):**

- * H: As distribuições dos tratamentos (ou condições) são todas iguais
- * H: Pelo menos uma distribuição de tratamento é diferente das outras

Na comparação entre **mais de dois grupos** (por exemplo, usando ANOVA ou Kruskal-Wallis), a hipótese nula (H) é que **todas** as médias (ou distribuições) dos grupos são iguais. Por outro lado, a hipótese alternativa (H) não especifica qual grupo é diferente, mas sim que **pelo menos um dos grupos se difere dos demais**. Ou seja, a rejeição da hipótese nula indica que existe pelo menos uma diferença, mas não revela imediatamente entre quais grupos essa diferença ocorre.

Atenção: É importante notar que, no contexto de mais de dois grupos, a hipótese alternativa não identifica quais grupos são diferentes, apenas aponta que existe pelo menos uma diferença.

25.3 Testes Paramétricos

- **Não Pareados:** O teste mais utilizado é a **ANOVA de uma via**, que compara as médias de três ou mais grupos independentes.
- **Pareados:** Utiliza-se a **ANOVA para medidas repetidas** quando as medições são feitas nos mesmos indivíduos em diferentes condições ou tempos.

25.3.1 Pré-requisitos para ANOVA (dados pareados ou não)

1. **Normalidade dos resíduos:** Os resíduos do modelo devem seguir uma distribuição normal.
2. **Homogeneidade de variâncias:** As variâncias dos grupos devem ser semelhantes.
3. **Esfericidade** (apenas para medidas repetidas): A variância das diferenças entre todas as combinações de pares de grupos deve ser semelhante.
4. **Independência das observações:** Para grupos independentes.

Se algum desses pré-requisitos não for atendido, é recomendado utilizar testes não paramétricos.

25.4 Testes Não Paramétricos

- **Não Pareados:** O teste de **Kruskal-Wallis** é utilizado para comparar mais de dois grupos independentes.
- **Pareados:** O teste de **Friedman** é usado para comparar três ou mais grupos pareados.

25.5 ANOVA de uma via no R


A seguir, apresentamos um exemplo de ANOVA de uma via e do teste de Kruskal-Wallis, incluindo a verificação dos pré-requisitos.

25.5.1 Simulação de Dados

```
set.seed(123)
grupo <- factor(rep(c("A", "B", "C"), each = 10))
valor <- c(rnorm(10, mean = 5, sd = 1),
          rnorm(10, mean = 6, sd = 1),
          rnorm(10, mean = 7, sd = 1))
dados <- data.frame(grupo, valor)
```

25.5.2 Visualização dos Dados

```
boxplot(valor ~ grupo, data = dados, main = "Boxplot dos Grupos", ylab = "Valor")
```




25.5.3 Verificação dos Pré-requisitos para ANOVA

```
modelo_aov <- aov(valor ~ grupo, data = dados)
residuos <- residuals(modelo_aov)

shapiro.test(residuos)
```

```
##
## Shapiro-Wilk normality test
##
## data:  residuos
## W = 0.96213, p-value = 0.3507
qqnorm(residuos)
qqline(residuos)
```

Normal Q-Q Plot



- A função `aov` no R é utilizada para realizar **análise de variância (ANOVA)**.
- `modelo_aov <- aov(valor ~ grupo, data = dados)`
Esta linha ajusta um modelo de ANOVA de uma via, avaliando se a média da variável `valor` difere entre os diferentes níveis do fator `grupo`, usando os dados do data frame `dados`.
- `residuos <- residuals(modelo_aov)`
Esta linha extrai os resíduos do modelo ajustado, ou seja, as diferenças entre os valores observados e os valores previstos pelo modelo. A análise dos resíduos é fundamental para verificar os pressupostos da ANOVA, como a normalidade.

Neste exemplo, tanto o teste de normalidade quanto a inspeção visual do gráfico QQ sugerem que os resíduos seguem uma distribuição normal.

25.5.3.2 Homogeneidade de variâncias

```
# Instale 'car' se necessário: install.packages("car")
library(car)
leveneTest(valor ~ grupo, data = dados)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value Pr(>F)
## group 2    5e-04 0.9995
##      27
```

- O *teste de Levene* avalia a homogeneidade das variâncias entre os grupos, que é um dos pré-requisitos para a ANOVA.
- **Valor de p ($\text{Pr}(>F)$) = 0.9995:** O valor de p é muito maior que 0,05, indicando que **não há evidências para rejeitar a hipótese nula de igualdade das variâncias**.

Nesse exemplo, as variâncias dos grupos podem ser consideradas homogêneas. Portanto, o pré-requisito de homogeneidade de variâncias para a ANOVA foi atendido.

25.5.4 ANOVA de Uma Via

```
summary(modelo_aov)
```

```
##              Df Sum Sq Mean Sq F value    Pr(>F)
## grupo         2  12.24    6.122    6.435 0.00518 **
## Residuals    27   25.68    0.951
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Valor de p ($\Pr(>F)$) = 0.00518:** O valor de p é menor que 0,05, indicando que existem diferenças estatisticamente significativas entre as médias dos grupos analisados.
- Rejeita-se a hipótese nula de igualdade das médias. Isso significa que pelo menos um dos grupos difere significativamente dos demais. Recomenda-se realizar *testes post hoc* (por exemplo, *Tukey*) para identificar quais grupos apresentam diferenças entre si.

25.5.4.1 Teste Post Hoc (se ANOVA for significativa)

```
TukeyHSD(modelo_aov)
```

```
##      Tukey multiple comparisons of means
##      95% family-wise confidence level
##
## Fit: aov(formula = valor ~ grupo, data = dados)
##
## $grupo
##           diff             lwr             upr             p adj
## B-A 1.1339963  0.05254072  2.215452  0.0384525
## C-A 1.5008155  0.41935988  2.582271  0.0052283
## C-B 0.3668192 -0.71463643  1.448275  0.6812485
```

O teste de Tukey compara as médias dos grupos dois a dois, após a ANOVA indicar diferença significativa entre eles. Os resultados mostram as diferenças entre as médias dos grupos (**diff**), os limites inferior (**lwr**) e superior (**upr**) do intervalo de confiança de 95%, e o valor de p ajustado (**p adj**).

Resultados:

- **B vs A:**
Diferença = 1.13; IC 95% = [0.05, 2.22]; p = 0.038
O grupo B tem média significativamente maior que o grupo A.
- **C vs A:**
Diferença = 1.50; IC 95% = [0.42, 2.58]; p = 0.005
O grupo C tem média significativamente maior que o grupo A.
- **C vs B:**
Diferença = 0.37; IC 95% = [-0.71, 1.45]; p = 0.681
Não há diferença significativa entre os grupos C e B.

Os grupos B e C apresentam médias significativamente maiores do que o grupo A. Não foi observada diferença significativa entre os grupos B e C.

25.6 Kruskal-Wallis no R

Se os pré-requisitos da ANOVA não forem atendidos, utilize o Kruskal-Wallis:

```
kruskal.test(valor ~ grupo, data = dados)
```

```
##
##      Kruskal-Wallis rank sum test
```

```
##
## data: valor by grupo
## Kruskal-Wallis chi-squared = 8.1858, df = 2, p-value = 0.01669
```

- **Valor de p (p-value) = 0.01669:** O valor de p é menor que 0,05, indicando que há diferença estatisticamente significativa entre pelo menos dois dos grupos analisados.
- Rejeita-se a hipótese nula de que as distribuições dos grupos são todas iguais. Ou seja, pelo menos um dos grupos apresenta distribuição diferente dos demais. Para identificar especificamente quais grupos diferem entre si, é recomendada a realização de testes post hoc apropriados (por exemplo, Dunn ou pairwise Wilcoxon com ajuste para múltiplas comparações).

25.6.1 Teste Post Hoc para Kruskal-Wallis

```
# Instale PMCMRplus se necessário: install.packages("PMCMRplus")
library(PMCMRplus)
kwAllPairsDunnTest(valor ~ grupo, data = dados)
```

```
##      A      B
## B 0.058 -
## C 0.021 0.611
```

O teste de Dunn é um teste pós-hoc não-paramétrico, utilizado após o teste de Kruskal-Wallis para identificar quais pares de grupos diferem significativamente entre si.

Os *p-valores* apresentados pelo teste compara todos os pares possíveis entre os grupos (neste exemplo: A, B e C):

- **A vs. B:** $p = 0.058$
- **A vs. C:** $p = 0.021$
- **B vs. C:** $p = 0.611$

Portanto, os resultados sugerem que apenas os grupos A e C, para a variável analisada, são estatisticamente diferentes entre si.

25.7 Por que não é indicado comparar os grupos dois a dois diretamente?

Quando se tem mais de dois grupos, pode parecer tentador realizar múltiplos testes de comparação entre pares de grupos (por exemplo, vários testes t para todos os pares possíveis). No entanto, esse procedimento **não é recomendado**, pois aumenta significativamente o risco de cometer um **erro do tipo I** (falso positivo).

Cada teste realizado tem uma determinada probabilidade de indicar uma diferença por acaso (erro tipo I), geralmente 5% se $\alpha = 0,05$. Ao fazer muitos testes independentes, a probabilidade de encontrar pelo menos um resultado “significativo” apenas por acaso aumenta. Esse fenômeno é chamado de **inflacionamento da taxa de erro tipo I**.

Por isso, para comparação de mais de dois grupos, utiliza-se primeiro um teste global (como ANOVA ou Kruskal-Wallis). Se o resultado for significativo, aí sim são realizados testes post hoc, que já incluem correções para múltiplas comparações (como o teste de Tukey), controlando o risco de erro tipo I.

25.8 ANOVA para Dados Repetidos no R

Vamos analisar o desempenho de 20 alunos em 3 provas diferentes (Prova 1, Prova 2 e Prova 3). Cada aluno fez todas as provas, ou seja, temos medidas repetidas!

25.8.1 Gerar dados simulados

```
set.seed(123)
n <- 20
dados <- data.frame(
  aluno = factor(1:n),
  prova1 = round(rnorm(n, mean = 7, sd = 1), 1),
  prova2 = round(rnorm(n, mean = 7.5, sd = 1), 1),
  prova3 = round(rnorm(n, mean = 8, sd = 1), 1)
)
head(dados)
```

```
##   aluno prova1 prova2 prova3
## 1     1    6.4    6.4    7.3
## 2     2    6.8    7.3    7.8
## 3     3    8.6    6.5    6.7
## 4     4    7.1    6.8   10.2
## 5     5    7.1    6.9    9.2
## 6     6    8.7    5.8    6.9
```

25.8.2 Converter para formato longo

```
library(tidyr)
dados_long <- pivot_longer(
  dados,
  cols = c("prova1", "prova2", "prova3"),
  names_to = "prova",
  values_to = "nota"
)
head(dados_long)
```

```
## # A tibble: 6 x 3
##   aluno prova  nota
##   <fct> <chr> <dbl>
## 1 1     prova1  6.4
## 2 1     prova2  6.4
## 3 1     prova3  7.3
## 4 2     prova1  6.8
## 5 2     prova2  7.3
## 6 2     prova3  7.8
```

Transformar os dados para o formato longo é fundamental para análises de medidas repetidas porque permite que o R identifique corretamente as repetições de cada aluno ao longo das diferentes provas. Sem isso, não é possível fazer ANOVA de medidas repetidas de forma adequada!


25.8.3 Visualização (opcional)

```
library(ggplot2)
library(RColorBrewer)

# Use uma paleta de cores apropriada para até 20 alunos
cores <- colorRampPalette(brewer.pal(9, "Set1"))(20)


ggplot(dados_long, aes(x = prova, y = nota, group = aluno, color = aluno)) +
  geom_line(alpha = 0.7, linewidth = 1) +
  geom_point(size = 2) +
  labs(x = "Avaliações", y = "Pontuação") +
```

```
scale_color_manual(values = cores) +
labs(title = "Notas dos Alunos nas Três Provas", color = "Aluno") +
theme_minimal() +
theme(legend.position = "right")
```



```
dif12 <- dados$prova1 - dados$prova2
dif13 <- dados$prova1 - dados$prova3
dif23 <- dados$prova2 - dados$prova3

qqnorm(dif12)
qqline(dif12)
```




```
shapiro.test(dif12)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data:  dif12  
## W = 0.94596, p-value = 0.3099
```

```
qqnorm(dif13)  
qqline(dif13)
```


Normal Q-Q Plot



```
shapiro.test(dif13)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data:  dif13  
## W = 0.96929, p-value = 0.7398
```

```
qqnorm(dif23)  
qqline(dif23)
```



```
shapiro.test(dif23)
```

```
##
## Shapiro-Wilk normality test
##
## data:  dif23
## W = 0.97175, p-value = 0.7914
```

As diferenças seguem distribuição normal.

25.8.5 ANOVA de medidas repetidas com afex (testa e corrige esfericidade)

A função `aov_ez()`, do pacote `afex` realiza toda a ANOVA de medidas repetidas de forma prática e automática.

```
# Instale se necessário: install.packages("afex")
library(afex)
modelo_afex <- aov_ez(
  id = "aluno",
  dv = "nota",
  within = "prova",
  data = dados_long
)
modelo_afex
```

```
## Anova Table (Type 3 tests)
##
## Response: nota
##   Effect      df  MSE      F ges p.value
## 1  prova 1.91, 36.27 0.94 5.53 ** .168    .009
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '+' 0.1 ' ' 1
##
## Sphericity correction method: GG
```

- **Effect:** O fator analisado (*prova*), ou seja, se as notas variam entre as provas.
- **df:** Graus de liberdade. Note que aparecem valores decimais (1.91, 36.27) porque foi aplicada a correção de Greenhouse-Geisser (GG).
- **MSE:** Erro quadrático médio.
- **F:** Estatística F da ANOVA.
- **ges:** Generalized Eta Squared, uma medida de tamanho de efeito.
- **p.value:** Valor de p associado ao teste F. Neste caso, $p = 0.009$ indica que há diferença significativa entre as médias das provas ($p < 0.05$).
- **Observação sobre esfericidade:** A linha `Sphericity correction method: GG` informa apenas **qual correção o pacote aplicou**, e não que a esfericidade tenha sido violada. O `aov_ez()` aplica Greenhouse-Geisser **por padrão**, como postura conservadora, independentemente do resultado do teste de Mauchly. Neste exemplo, aliás, o Mauchly **não** indicou violação ($p = 0,64$) — o que se vê nos graus de liberdade é o fator de correção $= 0,954$ multiplicando os df originais ($2 \times 0,954 = 1,91$ e $38 \times 0,954 = 36,27$).

Para ver o teste de Mauchly e os graus de liberdade sem correção, use `summary(modelo_afex)`.

A análise de variância (ANOVA) mostrou que o fator “prova” teve um efeito significativo sobre as notas ($F(1.91, 36.27) = 5.53$, $p = 0.009$, $ges = 0.168$), indicando que as médias das notas diferem entre as provas.

25.8.6 Pós-hoc: Comparações múltiplas entre as provas

```
# Instale se necessário: install.packages("emmeans")
library(emmeans)
emm <- emmeans(modelo_afex, ~ prova)
pairs(emm, adjust = "bonferroni") # ou "holm", "sidak", etc.
```

```
## contrast      estimate    SE df t.ratio p.value
## prova1 - prova2  -0.315 0.300 19  -1.050  0.9212
## prova1 - prova3  -0.975 0.326 19  -2.993  0.0225
## prova2 - prova3  -0.660 0.269 19  -2.455  0.0717
##
## P value adjustment: bonferroni method for 3 tests
```

- **prova1 vs prova2:** Não há diferença significativa ($p = 0.9212$).
- **prova1 vs prova3:** Diferença significativa ($p = 0.0225$). As médias dessas provas são estatisticamente diferentes.
- **prova2 vs prova3:** Não há diferença significativa ($p = 0.0717$).

A análise revelou que existe diferença significativa nas notas entre as provas. Especificamente, a única diferença significativa foi entre as provas 1 e 3, indicando que as médias dessas avaliações diferem estatisticamente. Entre as demais provas, não foram observadas diferenças significativas após o ajuste de Bonferroni.

25.9 Teste de Friedman

```
# O teste de Friedman compara as três provas considerando a repetição por aluno
friedman.test(as.matrix(dados[, c("prova1", "prova2", "prova3")]))
```

```
##
## Friedman rank sum test
##
## data: as.matrix(dados[, c("prova1", "prova2", "prova3")])
## Friedman chi-squared = 10.101, df = 2, p-value = 0.006405
```

25.9.1 Pós-teste: Comparações Múltiplas (Wilcoxon pareado)

```
pairwise.wilcox.test(  
  dados_long$nota,  
  dados_long$prova,  
  paired = TRUE,  
  p.adjust.method = "bonferroni"  
)  
  
##  
## Pairwise comparisons using Wilcoxon signed rank test with continuity correction  
##  
## data:  dados_long$nota and dados_long$prova  
##  
##          prova1 prova2  
## prova2 0.729  -  
## prova3 0.033  0.087  
##  
## P value adjustment method: bonferroni
```

Após o teste de Friedman indicar que há diferença nas notas das provas, fazemos um pós-teste para descobrir entre quais provas há diferença.

- Apenas **entre Prova 1 e Prova 3 existe diferença significativa** ($0.033 < 0.05$).
- Entre Prova 1 e 2, e entre Prova 2 e 3, não há diferença significativa (valores maiores que 0.05).

Chapter 26

Correlação entre variáveis

A correlação é uma forma de medir o grau de relação entre duas variáveis. Quando duas variáveis estão correlacionadas, significa que podemos esperar que, ao mudar uma delas, a outra também sofra alguma alteração. Se ambas aumentam juntas, dizemos que a correlação é positiva; se uma aumenta enquanto a outra diminui, a correlação é negativa.

É importante destacar que a correlação indica apenas que as variáveis variam juntas, mas não prova que uma causa a mudança na outra. Outros fatores podem estar influenciando essa relação, ou pode ser apenas uma coincidência. Por isso, correlação mostra como as variáveis estão relacionadas, mas não estabelece uma relação de causa e efeito.

Na medicina, um exemplo clássico é investigar a correlação entre o índice de massa corporal (IMC) e a pressão arterial sistólica. Pesquisadores podem avaliar se pessoas com IMC mais elevado tendem a ter pressão arterial mais alta, o que ajuda a entender riscos cardiovasculares.

Na psicologia, pode-se analisar a correlação entre a pontuação em uma escala de ansiedade (por exemplo, a pontuação total em um questionário) e o número de horas de sono por noite. Essa relação ajuda a compreender como o sono influencia o nível de ansiedade.


Na educação física, um exemplo é estudar a correlação entre o tempo gasto em atividade física semanal (em horas) e a porcentagem de gordura corporal. Isso auxilia na avaliação do impacto do exercício sobre a composição corporal.

26.1 Tipos de Variáveis

Para analisar correlação, usamos variáveis numéricas (quantitativas ou qualitativas ordinais).

26.2 Diagrama de Dispersão

O diagrama de dispersão é um gráfico que permite visualizar a relação entre duas variáveis. A seguir, exemplos de diferentes padrões de correlação:



Para criar um gráfico de dispersão no R, você pode usar a função `plot()`. Os argumentos básicos que você deve fornecer entre os parênteses são:

- “x”: um vetor numérico com os valores do eixo x (variável independente).
- “y”: um vetor numérico com os valores do eixo y (variável dependente).

Ou seja, algo como: `plot(x,y)`

26.3 Coeficientes de Correlação

Existem diferentes métodos para medir a correlação entre variáveis, cada um adequado a tipos específicos de dados e relações. Os três tipos mais comuns são: a **correlação de Pearson**, que avalia a relação linear entre variáveis numéricas contínuas; a **correlação de Spearman**, que mede associações monotônicas usando postos, sendo indicada para dados ordinais ou quando a relação não é estritamente linear; e a **correlação de Kendall**, também baseada em postos, que é especialmente útil em amostras pequenas ou com muitos empates nos dados. Conhecer essas diferenças é fundamental para escolher o método mais apropriado em cada situação.

26.3.1 Coeficiente de Correlação de Pearson

O coeficiente de correlação de **Pearson** (r) é utilizado quando se deseja avaliar a relação linear entre duas variáveis quantitativas contínuas. Ele pressupõe que os dados de ambas as variáveis seguem uma **distribuição normal** (ou aproximadamente normal) e que a relação entre elas é linear, ou seja, uma linha reta pode descrever bem o padrão dos dados em um gráfico de dispersão. É sensível a outliers.

26.3.2 Coeficiente de Correlação de Spearman

O coeficiente de **Spearman** (r_s) avalia a força e a direção da associação entre duas variáveis com base em seus **ranks** (postos) em vez dos valores originais. Ele é indicado quando a relação entre as variáveis é **monotônica**, ou seja, conforme uma variável aumenta, a outra também aumenta ou diminui, mas não necessariamente de maneira linear. O Spearman é apropriado para dados que não seguem a normalidade ou para situações em que a relação não pode ser descrita por uma linha reta. Além disso, é menos sensível a outliers do que o Pearson.

26.3.3 Coeficiente de Correlação de Kendall

O coeficiente de **Kendall** (τ) também se baseia nos postos dos dados, sendo utilizado para medir a força da associação entre duas variáveis. É especialmente útil em situações com **pequenas amostras** ou quando há muitos **empates** nos valores dos dados (valores iguais). Assim como o Spearman, o Kendall não exige normalidade dos dados e é apropriado para relações monotônicas. Em geral, o tau de Kendall é visto como mais robusto em amostras pequenas ou com muitos empates.

26.3.4 Interpretação dos Coeficientes

O valor da correlação varia de -1 (correlação negativa perfeita) a +1 (correlação positiva perfeita), sendo 0 a ausência de correlação linear.

Faixa de valores	Interpretação
0,00 – 0,10	Desprezível
0,10 – 0,30	Fraca
0,30 – 0,50	Moderada
0,50 – 0,70	Forte
0,70 – 1,00	Muito forte

26.3.5 Exemplo no R

Vamos supor que temos os dados de 18 alunos: a quantidade de aulas frequentadas (de um total de 20) e suas notas finais na disciplina de Estatística (de 0 a 10).

```
# Vetor de presenças (número de aulas frequentadas)
presencas <- c(20, 18, 17, 19, 15, 16, 20, 18, 17, 19, 14, 15, 12, 16, 20, 13, 17, 18)

# Vetor de notas finais em Estatística
notas <- c(9.8, 9.0, 8.5, 9.5, 7.0, 7.5, 10.0, 8.7, 8.0, 9.2, 6.5, 7.2, 5.0, 7.8, 9.7, 6.0, 8.2, 8.8)

# Para calcular o r de Pearson
cor(presencas, notas, method = "pearson")

## [1] 0.992563

# Para calcular o rho de Spearman
cor(presencas, notas, method = "spearman")

## [1] 0.9922299

# Para calcular o tau de Kendall
cor(presencas, notas, method = "kendall")

## [1] 0.9599837

# Dica: dá para abreviar o nome de cada método
# Para calcular o r de Pearson
cor(presencas, notas, method = "p")

## [1] 0.992563

# Para calcular o rho de Spearman
cor(presencas, notas, method = "s")

## [1] 0.9922299

# Para calcular o tau de Kendall
cor(presencas, notas, method = "k")

## [1] 0.9599837
```

26.4 Testes de Correlação

26.4.1 Pearson

- $H_0: r = 0$ (não há correlação linear entre as variáveis “x” e “y”)
- $H_1: r \neq 0$ (existe correlação)

```
cor.test(presencas, notas, method = "pearson")

##
## Pearson's product-moment correlation
##
## data:  presencas and notas
## t = 32.615, df = 16, p-value = 4.597e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.9796700 0.9972906
## sample estimates:
##      cor
## 0.992563
```

O teste de correlação de Pearson realizado entre as variáveis **presencas** e **notas** apresentou os seguintes resultados:

- **t = 32.615:**
Este é o valor do teste t calculado, que indica uma diferença extremamente significativa entre a correlação observada e a hipótese nula (correlação igual a zero). Quanto maior o valor de t, maior a evidência contra a hipótese nula.
- **df = 16:**
Refere-se aos graus de liberdade do teste, calculados por $(n - 2)$, onde n é o número de pares de dados analisados. Neste caso, indica que havia 18 observações.
- **p-value = 4.597e-16:**
O valor-p extremamente baixo mostra que a probabilidade de obter uma correlação tão forte por acaso é praticamente nula. Portanto, a correlação é estatisticamente significativa.
- **alternative hypothesis: true correlation is not equal to 0:**
A hipótese alternativa testada é de que existe alguma correlação (positiva ou negativa) diferente de zero entre as variáveis.
- **95 percent confidence interval: 0.9796700 a 0.9972906:**
O intervalo de confiança indica que, com 95% de certeza, o valor real da correlação populacional entre **presencas** e **notas** está entre aproximadamente 0,98 e 0,997. Isso é considerado uma correlação extremamente forte.
- **sample estimates: cor = 0.992563:**
O coeficiente de correlação de Pearson (r) observado foi de 0,99, indicando uma relação positiva, muito forte e praticamente perfeita: quanto maior o número de presenças, maior tende a ser a nota.

Resumo:

Os resultados mostram uma associação positiva fortíssima e estatisticamente significativa entre presenças e notas, sugerindo que alunos que frequentam mais tendem a obter notas mais altas.

26.4.2 Spearman

- $H_0: r = 0$ (não há correlação entre as variáveis “x” e “y”)
- $H_1: r \neq 0$ (existe correlação)

```
cor.test(presencas, notas, method = "spearman")

##
## Spearman's rank correlation rho
```

```
##
## data: presencas and notas
## S = 7.5293, p-value = 6.52e-16
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##      rho
## 0.9922299
```

O teste de correlação de Spearman realizado entre as variáveis **presencas** e **notas** apresentou os seguintes resultados:

- **S = 7.5293:**
Este é o valor da estatística de teste S, usada no cálculo da correlação de Spearman. Ele reflete as diferenças nas posições (ranks) entre as duas variáveis analisadas.
- **p-value = 6.52e-16:**
O valor-p extremamente baixo indica que a probabilidade de observar uma correlação tão alta por acaso, caso não exista correlação real, é praticamente nula. Portanto, a correlação encontrada é estatisticamente significativa.
- **alternative hypothesis: true rho is not equal to 0:**
A hipótese alternativa do teste é de que o coeficiente de Spearman (ρ) é diferente de zero, ou seja, existe uma associação monotônica entre as variáveis.
- **sample estimates: rho = 0.9922299:**
O coeficiente de correlação de Spearman observado foi de 0,99, indicando uma relação positiva, extremamente forte, entre **presencas** e **notas**. Isso significa que, à medida que o número de presenças aumenta, as notas tendem a aumentar de forma consistente, mesmo que a relação não seja perfeitamente linear.

Resumo:

Os resultados demonstram uma associação positiva e muito forte entre presenças e notas, estatisticamente significativa. Isso sugere que alunos com mais presenças tendem a obter notas mais altas, mesmo considerando possíveis variações não lineares na relação entre as variáveis.

26.4.3 Kendall

- $H_0: \tau = 0$ (não há correlação entre as variáveis “x” e “y”)
- $H_1: \tau \neq 0$ (existe correlação)

```
cor.test(presencas, notas, method = "kendall")
```

```
##
## Kendall's rank correlation tau
##
## data: presencas and notas
## z = 5.3952, p-value = 6.844e-08
## alternative hypothesis: true tau is not equal to 0
## sample estimates:
##      tau
## 0.9599837
```

O teste de correlação de Kendall realizado entre as variáveis **presencas** e **notas** apresentou os seguintes resultados:

- **z = 5.3952:**
Este é o valor da estatística z calculado para o teste de Kendall. Valores de z elevados indicam forte evidência contra a hipótese nula de ausência de associação entre as variáveis.
- **p-value = 6.844e-08:**
O valor-p extremamente baixo indica que a probabilidade de obter uma correlação tão alta por acaso é praticamente nula. Portanto, a associação observada entre as variáveis é estatisticamente significativa.

- **alternative hypothesis: true tau is not equal to 0:**

A hipótese alternativa do teste é de que o coeficiente de Kendall (τ) é diferente de zero, ou seja, existe uma associação monotônica entre as variáveis.

- **sample estimates: tau = 0.9599837:**

O coeficiente de correlação de Kendall (τ) encontrado foi de 0,96, indicando uma associação positiva, muito forte, entre **presenças** e **notas**. Isso significa que, à medida que o número de presenças aumenta, as notas também tendem a aumentar de forma consistente, mesmo considerando possíveis empates (valores iguais) entre as observações.

Resumo:

Os resultados mostram uma associação positiva e extremamente forte entre presenças e notas, estatisticamente significativa. Isso sugere que alunos com mais presenças tendem a obter notas mais altas, mesmo considerando a ordem dos dados e possíveis empates nas avaliações.

26.5 Tamanho do Efeito (Effect Size)

Em estudos de correlação, o **tamanho do efeito** é representado pelo valor absoluto do coeficiente de correlação (por exemplo, Pearson, Spearman ou Kendall). Isso significa que consideramos apenas a intensidade da relação entre as variáveis, independentemente de ser positiva ou negativa.

Por exemplo, tanto um coeficiente de +0,65 quanto de -0,65 indicam um tamanho de efeito de 0,65. Quanto mais próximo de 1 (ou -1), mais forte é a correlação; quanto mais próximo de 0, mais fraca.

26.6 Cálculo do Tamanho da Amostra e Poder Estatístico

26.6.1 Exemplo com pwr

Calcular o tamanho da amostra necessário para detectar uma correlação de 0,4 com poder de 80% e $\alpha = 0,05$:

```
library(pwr)
pwr.r.test(r = 0.4, power = 0.8, sig.level = 0.05, alternative = "two.sided")

##
##      approximate correlation power calculation (arctangh transformation)
##
##              n = 45.91614
##              r = 0.4
##      sig.level = 0.05
##              power = 0.8
##      alternative = two.sided
```

26.6.2 Verificar o poder para uma amostra de tamanho 30:

```
pwr.r.test(n = 30, r = 0.4, sig.level = 0.05, alternative = "two.sided")

##
##      approximate correlation power calculation (arctangh transformation)
##
##              n = 30
##              r = 0.4
##      sig.level = 0.05
##              power = 0.6075135
##      alternative = two.sided
```

26.7 Outros recursos

Para explorar um pouco mais o estudo de correlação, vamos usar o banco de dados `iris`, que já vem instalado por padrão no R.

O dataset `iris` é um conjunto de dados clássico em estatística e aprendizado de máquina (*machine learning*). Ele contém 150 observações de flores de íris de três espécies diferentes: *setosa*, *versicolor* e *virginica*. As variáveis numéricas são:


- **Sepal.Length:** comprimento da sépala (em centímetros), a sépala é a parte externa da flor, que protege os botões florais.
- **Sepal.Width:** largura da sépala (em centímetros).
- **Petal.Length:** comprimento da pétala (em centímetros), as pétalas são as partes geralmente coloridas da flor.
- **Petal.Width:** largura da pétala (em centímetros).

Estas medidas são úteis para estudar relações entre características morfológicas das flores.

26.7.1 Visualização com `pairs()`

A função `pairs()` mostra uma matriz de gráficos de dispersão, útil para observar visualmente correlações entre todas as variáveis numéricas.

```
pairs(iris[, 1:4])
```



A função `pairs` no R gera uma matriz de gráficos de dispersão mostrando a relação entre todas as variáveis numéricas de um conjunto de dados. Cada gráfico da matriz compara duas variáveis diferentes:

- Cada linha e cada coluna representam uma variável.
- Os gráficos mostram como cada variável se relaciona com as outras: por exemplo, a relação entre `Sepal.Length` e `Petal.Length`.
- Quando os pontos formam uma linha inclinada, isso indica uma correlação (positiva ou negativa) entre as variáveis.
- Se os pontos estão espalhados, sem padrão, indica pouca ou nenhuma relação.
- A diagonal mostra o nome de cada variável.

Assim, ao olhar para a matriz, você consegue visualizar rapidamente quais variáveis têm relação entre si e qual é o tipo dessa relação (mais forte, mais fraca, positiva ou negativa).

26.7.2 Matriz de Correlação com `cor()`

A função `cor()` calcula a matriz de correlação entre variáveis numéricas. A seguir, uma matriz com correlação de Pearson:

```
# use o método adequado method = "pearson"; method = "spearman" ou method = "kendall"
cor(iris[, 1:4], method = "pearson")
```

```
##              Sepal.Length Sepal.Width Petal.Length Petal.Width
## Sepal.Length    1.0000000  -0.1175698    0.8717538    0.8179411
## Sepal.Width     -0.1175698    1.0000000   -0.4284401   -0.3661259
## Petal.Length     0.8717538  -0.4284401    1.0000000    0.9628654
## Petal.Width      0.8179411  -0.3661259    0.9628654    1.0000000
```

A matriz de correlação é uma tabela que mostra os coeficientes de correlação entre todas as combinações possíveis de variáveis numéricas em um conjunto de dados. Cada valor da matriz indica o grau de associação linear entre um par de variáveis. A diagonal principal sempre apresenta o valor 1, pois cada variável é perfeitamente correlacionada com ela mesma. Assim, a matriz de correlação permite identificar rapidamente quais variáveis estão mais relacionadas entre si, facilitando a análise exploratória dos dados. Observe que essa matriz é simétrica


26.7.3 Matriz Visual com `GGally::ggcorr()`

O `ggcorr()` do pacote `GGally` mostra graficamente os coeficientes de correlação, com intensidade e direção representadas por cor.

```
# Instale os pacotes se necessário:
# install.packages("GGally")
# install.packages("ggplot2")

# Matriz de correlação tipo heatmap com valores destacados
ggcorr(
  data = iris[, 1:4],
  method = c("everything", "pearson"), # calcula todas as correlações de Pearson
  label = TRUE,                        # mostra os coeficientes nas células
  label_round = 2,                    # arredonda os valores para 2 casas decimais
  label_size = 5,                     # tamanho do texto dos coeficientes
  hjust = 0.5,                        # centraliza os rótulos nas células
  layout.exp = 2,                     # expande o tamanho das células
  low = "#D73027",                    # cor para correlação negativa forte
  mid = "white",                       # cor para correlação nula
  high = "#3366CC"                    # cor para correlação positiva forte
) +
  ggtitle("Matriz de Correlação de Pearson - iris (Heatmap)") +
  theme_minimal(base_size = 14) + # visual minimalista e tamanho de fonte maior
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"), # centraliza e destaca o título
    axis.text.x = element_text(angle = 45, vjust = 1, hjust = 1) # gira rótulos do eixo x para melhor leitura
  )
```

Matriz de Correlação de Pearson – iris (Heatmap)




A função `ggpairs()` combina histogramas, correlações e gráficos de dispersão em uma visualização integrada.

Este comando cria uma matriz de gráficos que facilita visualizar a distribuição e a relação entre as variáveis numéricas do conjunto. É muito útil para identificar padrões, tendências, outliers e possíveis correlações antes de uma análise estatística mais aprofundada.


- Considerando todos os dados:

```
GGally::ggpairs(iris, columns = 1:4)
```



- Considerando as categorias de espécies (variável Species)

```
GGally::ggpairs(iris, columns = 1:4, aes(color = Species))
```



O que a figura mostra?

Esta figura é uma **matriz de gráficos de pares** (pairs) das variáveis numéricas do conjunto de dados, nesse caso, `Sepal.Length`, `Sepal.Width`, `Petal.Length` e `Petal.Width`.

- **Diagonal principal:** exibe a distribuição de cada variável individualmente, usando histogramas ou curvas de densidade. Quando os dados estão divididos por categoria (como diferentes espécies no exemplo do iris), cada cor representa uma categoria distinta, permitindo visualizar e comparar facilmente como os valores da variável se distribuem em cada grupo.
- **Abaixo da diagonal:** mostra gráficos de dispersão, permitindo observar visualmente as relações entre os pares de variáveis para cada espécie.
- **Acima da diagonal:** apresenta os **coeficientes de correlação** para cada par de variáveis:
 - O valor principal (exemplo: `Corr: 0.872***`) corresponde à correlação considerando todas as espécies juntas.
 - Abaixo, aparecem as correlações **por espécie**:
 - * setosa (vermelho)
 - * versicolor (verde)
 - * virginica (azul)
 - Os valores são coloridos conforme a espécie correspondente.
- **Sobre os asteriscos:** os asteriscos após os valores de correlação indicam o **nível de significância estatística** do coeficiente calculado, ou seja, quão provável é que a correlação observada seja diferente de zero apenas pelo acaso. A convenção usual é:
 - * : $p < 0,05$
 - ** : $p < 0,01$
 - *** : $p < 0,001$
 - Sem asteriscos: correlação **não** significativa

Chapter 27

Regressão

A **regressão** é uma técnica estatística usada para estudar a relação entre uma variável de interesse (chamada de variável dependente ou resposta) e uma ou mais variáveis que podem influenciá-la (chamadas de variáveis independentes ou preditoras). O objetivo principal é **prever** ou **explicar** o comportamento da variável resposta a partir das informações das variáveis preditoras.

Regressão Linear Simples:

É o tipo mais básico de regressão, analisando a relação entre duas variáveis: uma resposta (por exemplo, peso) e uma preditora (por exemplo, altura). A relação é representada por uma linha reta:

$$\text{Resposta} = a + b \text{ (Preditora)}$$

Exemplo: Prever o peso de uma pessoa a partir de sua altura. O modelo estima qual seria o peso esperado para cada altura.

Regressão Linear Múltipla:

Quando queremos analisar o efeito de duas ou mais variáveis preditoras sobre a variável resposta, usamos a regressão linear múltipla. A equação fica:

$$\text{Resposta} = a + b_1 \text{ (Preditora}_1\text{)} + b_2 \text{ (Preditora}_2\text{)} +$$

Exemplo: Prever o preço de uma casa considerando área, número de quartos e localização.

Regressão Logística:

É usada quando a resposta é categórica, por exemplo: sim/não, doente/sadio, aprovado/reprovado. Em vez de prever um número, ela estima a probabilidade de um determinado evento ocorrer. Exemplo: Prever a chance de um paciente ter uma certa doença com base em exames. O resultado é sempre um valor entre 0 e 1 (uma probabilidade).

Outros Modelos de Regressão:

Além dos modelos acima, existem outros tipos de regressão para diferentes situações, como:

- Regressão de Poisson: para contagem de eventos (exemplo: número de acidentes por mês); - Regressão de Prais-Winsten: utilizada em séries temporais, especialmente quando os dados têm dependência ao longo do tempo (como dados econômicos mensais); - Regressão polinomial: ajusta curvas em vez de retas, para relações não-lineares; - Regressão robusta, Ridge, Lasso: abordam problemas específicos como dados com valores extremos ou quando há muitas variáveis preditoras.

Em resumo, a regressão é uma ferramenta poderosa e versátil, útil em diferentes áreas como saúde, economia, educação e ciências sociais. Ela nos ajuda a compreender relações, prever resultados e tomar decisões baseadas em dados, mesmo sem precisar de conhecimentos avançados em matemática.

27.1 Regressão Linear Simples

A correlação responde à pergunta: “**Existe relação linear? Qual a força e o sentido dessa relação?**”

A **regressão linear simples** vai além: além de indicar se existe relação, ela fornece uma equação que **quantifica e permite prever** uma variável a partir da outra.

A equação tem a forma:

$$Y = a + bX$$

onde: - **Y**: variável resposta (dependente) - **X**: variável explicativa (independente) - **a**: intercepto (valor esperado de Y quando X = 0) - **b**: inclinação (quanto Y varia, em média, a cada unidade de X)

A regressão responde à pergunta: “**Como prever Y a partir de X?**”

É comum estudar primeiro a correlação, pois ela mostra se vale a pena tentar ajustar um modelo de regressão linear.

27.1.1 Regressão Linear Simples no R


Como exemplo, vamos estudar a relação entre a **frequência cardíaca** (x, em batimentos por minuto - bpm) e o **comprimento do intervalo QT** (y, em milissegundos) de um eletrocardiograma (ECG). O intervalo QT representa o tempo que o coração leva para se despolarizar e repolarizar, sendo um importante marcador clínico.

Vamos considerar a seguinte amostra:

```
# Frequência cardíaca (bpm)
x <- c(60,75,62,68,84,97,66,65,86,78,93,75,88)
# Intervalo QT (ms)
y <- c(403,363,381,367,341,317,401,384,342,377,329,377,349)
```

Vamos, primeiro, verificar o comportamento das variáveis pelo gráfico de dispersão:

```
plot(x, y,
      xlab = "Frequência Cardíaca (bpm)",
      ylab = "Intervalo QT (ms)",
      pch = 19, col = "blue")
grid()
```



O teste de correlação nos fornece:

```
# antes, verifique a normalidade das variáveis
cor.test(x, y) # Teste estatístico da correlação
```

```
##
## Pearson's product-moment correlation
##
## data: x and y
## t = -8.2944, df = 11, p-value = 4.625e-06
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.9787673 -0.7730054
## sample estimates:
## cor
## -0.9285203
```

- **Coefficiente de correlação (r):** -0,93
- **Valor de t:** -8,29
- **Graus de liberdade (df):** 11
- **Valor-p:** 0,0000046
- **Intervalo de confiança (95%):** de -0,98 a -0,77

O que isso significa?

- **Força e direção:** O coeficiente de correlação de Pearson ($r = -0,93$) indica uma **correlação negativa muito forte** entre as variáveis x e y. Isso significa que, à medida que uma variável aumenta, a outra tende a diminuir de forma bastante consistente.
- **Significância estatística:** O valor-p ($p < 0,001$) mostra que essa correlação é **estatisticamente significativa**. Ou seja, é extremamente improvável que essa relação forte e negativa tenha ocorrido por acaso.
- **Intervalo de confiança:** O intervalo de -0,98 a -0,77 indica que, com 95% de confiança, a verdadeira correlação na população está dentro desse intervalo — sempre indicando uma relação negativa forte.
- **Hipótese nula:** Como o valor-p é muito pequeno, rejeitamos a hipótese nula de que não existe correlação linear entre x e y.

Como há uma correlação linear forte e significativa, **faz sentido estudar um modelo de regressão linear** para quantificar e prever a relação entre essas variáveis.

Para ajustarmos um modelo onde o intervalo QT é explicado pela frequência cardíaca no R, usamos a função `lm()`, onde `lm` significa *linear model*.

```
regressao <- lm(y ~ x)
regressao
```

```
##
## Call:
## lm(formula = y ~ x)
##
## Coefficients:
## (Intercept)          x
##      520.668      -2.044
```

O modelo ajustado de regressão linear simples foi:

$$\text{Intervalo QT} = 520,67 - 2,04 (\text{E Frequência Cardíaca})$$

Interpretação dos coeficientes:

- **Intercepto (520,67):**
Este valor representa a estimativa do intervalo QT (em milissegundos) quando a frequência cardíaca (x) é zero. Embora uma frequência cardíaca de zero não faça sentido fisiológico, o intercepto é necessário para construir a reta de regressão e serve como referência matemática.
- **Inclinação (-2,04):**
Esse coeficiente indica que, para cada aumento de 1 batimento por minuto (bpm) na frequência cardíaca, o intervalo QT diminui, em média, cerca de 2,04 milissegundos.
Ou seja, existe uma relação negativa: quanto maior a frequência cardíaca, menor tende a ser o intervalo QT.

O resumo da regressão é obtido a partir da função `summary()`

```
summary(regressao)
```

```
##
## Call:
## lm(formula = y ~ x)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -14.689  -5.418  -2.900   8.188  15.750
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  520.6683    19.1158  27.238 1.90e-11 ***
## x           -2.0438     0.2464  -8.294 4.63e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.38 on 11 degrees of freedom
## Multiple R-squared:  0.8622, Adjusted R-squared:  0.8496
## F-statistic: 68.8 on 1 and 11 DF, p-value: 4.625e-06
```

- **Valor-p para ambos os coeficientes ($p < 0,001$):** Os dois coeficientes são significativos, ou seja, existe evidência estatística muito forte de que ambos são diferentes de zero.
- **R² (Multiple R-squared): 0,86:** Aproximadamente 86% da variação do intervalo QT é explicada pela frequência cardíaca. É um valor alto, indicando que o modelo ajusta bem os dados.
- **R² Ajustado (0,85):** Leva em conta o número de variáveis e tamanho da amostra, e também é alto.

- **Erro padrão residual (Residual standard error: 10,38):** Mede o desvio médio dos pontos em relação à reta ajustada (quanto menor, melhor).
- **Resíduos:** Representam a diferença entre os valores observados e os previstos pelo modelo. Os valores mínimos e máximos indicam a dispersão dos erros.
- **F-statistic: 68,8, p-value: 4,6e-06:** Teste global do modelo, confirma que a relação encontrada é altamente significativa.

O modelo de regressão linear simples mostra que existe uma **forte relação linear negativa** e estatisticamente significativa entre a frequência cardíaca e o intervalo QT: quanto maior a frequência cardíaca, menor tende a ser o intervalo QT. O modelo explica a maior parte da variação dos dados, sendo útil para previsões e interpretações clínicas dessa relação.

Os intervalos de confiança para os coeficientes da reta são dados por:

```
confint(regressao)
```

```
##                2.5 %      97.5 %
## (Intercept) 478.594702 562.741896
## x           -2.586164 -1.501475
```

- **Intercepto (a):**
O intervalo de confiança de 95% para o intercepto vai de **478,59** a **562,74**. Isso significa que, com 95% de confiança, o verdadeiro valor do intercepto está dentro desse intervalo. O intercepto representa o valor estimado do intervalo QT quando a frequência cardíaca é zero (valor teórico/matemático).
- **Inclinação (b):**
O intervalo de confiança de 95% para a inclinação vai de **-2,59** a **-1,50**. Como o intervalo é totalmente negativo, reforça que a relação entre frequência cardíaca e intervalo QT é negativa: a cada aumento de 1 bpm na frequência cardíaca, o intervalo QT diminui, em média, entre 1,50 e 2,59 ms.

Limitações e Cuidados na Regressão Linear

Apesar do modelo indicar uma associação significativa, é importante considerar algumas limitações e pontos de atenção:

- **Extrapolação:** O modelo é válido apenas para a faixa de dados observados. Prever valores de QT para frequências cardíacas muito fora do intervalo observado pode gerar resultados sem sentido.
- **Suposições do modelo:**
 - **Linearidade:** A relação entre as variáveis deve ser aproximadamente linear.
 - **Normalidade dos resíduos:** Os resíduos (erros) devem ser aproximadamente distribuídos normalmente.
 - **Homoscedasticidade:** A variância dos resíduos deve ser constante ao longo dos valores previstos.
 - **Independência:** As observações devem ser independentes entre si. Recomenda-se sempre checar essas suposições usando gráficos de resíduos e testes estatísticos.
- **Possíveis valores extremos (outliers):** Valores muito diferentes dos demais podem influenciar fortemente o ajuste, distorcendo os resultados.
- **Correlação não implica causalidade:** A regressão mostra associação, mas não garante que uma variável causa a outra.

27.1.2 O que deve ser checado ao ajustar uma regressão linear?

- **Gráfico de resíduos:** Para avaliar linearidade, homoscedasticidade e detectar outliers.
- **Histograma/QQ-plot dos resíduos:** Para verificar a normalidade dos resíduos.
- **Verificar influências:** Avaliar se algum ponto influencia demais o resultado (diagnóstico de outliers/influência).
- **Intervalos de confiança:** Analisar a precisão das estimativas dos parâmetros.
- **R² e R² ajustado:** Avaliar o quanto do comportamento da variável resposta é explicado pelo modelo.

27.2 Regressão Linear Múltipla

Depois de entender a regressão linear simples, é fácil expandir para a **regressão linear múltipla**, onde podemos incluir mais de uma variável preditora para explicar a variável resposta. No nosso exemplo, além da **frequência cardíaca (x)**, vamos acrescentar a **idade dos indivíduos (z)**, que também pode influenciar o intervalo QT do eletrocardiograma (y).

Vamos supor os seguintes valores de idade para os mesmos indivíduos:

```
# Frequência cardíaca (bpm)
x <- c(60,75,62,68,84,97,66,65,86,78,93,75,88)
# Intervalo QT (ms)
y <- c(403,363,381,367,341,317,401,384,342,377,329,377,349)
# Idade (anos) - exemplo hipotético
z <- c(25,40,30,22,53,60,28,27,50,35,59,41,55)
```

Vamos ajustar agora um modelo que considera tanto a frequência cardíaca quanto a idade como preditoras do intervalo QT:

- O modelo ajustado tem a forma:

$$QT = a + b_1 \text{ (E Frequência Cardíaca (x))} + b_2 \text{ (E Idade (z))}$$

```
regressao_multipla <- lm(y ~ x + z)
summary(regressao_multipla)

##
## Call:
## lm(formula = y ~ x + z)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -16.055  -5.737  -2.952   8.566  15.082
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  514.3929    37.2473  13.810 7.72e-08 ***
## x            -1.8827     0.8466  -2.224  0.0504 .
## z            -0.1505     0.7534  -0.200  0.8457
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.87 on 10 degrees of freedom
## Multiple R-squared:  0.8627, Adjusted R-squared:  0.8352
## F-statistic: 31.42 on 2 and 10 DF,  p-value: 4.88e-05
```

Modelo ajustado:

$$QT = 514,39 - 1,88 \text{ (E Frequência Cardíaca (x))} - 0,15 \text{ (E Idade (z))}$$

- **Intercepto (514,39):**
Valor estimado do QT quando frequência cardíaca e idade são zero (valor teórico, apenas referência matemática).
- **Frequência Cardíaca (x):**
O coeficiente é -1,88, ou seja, para cada aumento de 1 bpm, o QT diminui em média 1,88 ms, mantendo a idade constante.
O valor-p (0,0504) fica **acima** de 0,05: pelo critério adotado neste livro, **não** rejeitamos a hipótese nula de que esse coeficiente seja zero. É um resultado limítrofe, que ficou a um fio do nível de significância tradicional — mas “quase significativo” não é significativo (lembre-se dos memes do capítulo sobre o p-valor).

Repare no contraste com a regressão simples: lá, a mesma variável tinha $p < 0,001$. O que mudou foi que a idade entrou no modelo trazendo informação **redundante**: nestes dados, idade e frequência cardíaca são fortemente correlacionadas ($r = 0,95$; $p < 0,001$). Confira você mesmo(a):

```
cor.test(x, z)

##
##   Pearson's product-moment correlation
##
## data:  x and z
## t = 10.369, df = 11, p-value = 5.14e-07
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.8448526 0.9860019
## sample estimates:
##          cor
## 0.9524644
```

Quando dois preditores carregam praticamente a mesma informação, o modelo não consegue separar o efeito de um do efeito do outro. Isso infla o erro padrão dos coeficientes e derruba a significância de ambos — é o que chamamos de **multicolinearidade**. É um bom lembrete de que acrescentar preditores nem sempre melhora o modelo.

- **Idade (z):**

O coeficiente é -0,15, ou seja, para cada aumento de 1 ano de idade, o QT diminui, em média, 0,15 ms, mantendo a frequência cardíaca constante.

No entanto, o valor-p (0,8457) mostra que essa associação **não é estatisticamente significativa** — ou seja, não há evidência de que a idade tenha efeito relevante sobre o QT neste conjunto de dados.

Qualidade do ajuste

- **R² (0,86):**

Aproximadamente 86% da variação do QT é explicada pelo modelo com as duas variáveis preditoras, indicando bom ajuste.

- **R² ajustado (0,83):**

Leva em conta o número de variáveis, também indicando bom ajuste.

- **Erro padrão residual (10,87):**

Média dos desvios dos pontos em relação à reta ajustada, semelhante ao modelo simples.

Análise dos resíduos

- A distribuição dos resíduos sugere que o modelo está adequado, mas sempre é recomendado visualizar os gráficos de resíduos para avaliar possíveis violações das suposições.

Teste F

- **F-statistic: 31,42, p-value: 4,88e-05:**

O modelo como um todo é altamente significativo, ou seja, pelo menos uma das variáveis preditoras está relacionada ao QT.

Conclusão

- No modelo de **regressão múltipla**, nenhum dos dois preditores atinge o nível de 5% isoladamente: a frequência cardíaca fica no limite ($p = 0,050$) e a idade está bem longe dele ($p = 0,846$).
- O teste F, porém, mostra que o modelo **como um todo** é altamente significativo ($p < 0,001$), e o R² praticamente não mudou em relação ao modelo simples (0,8627 contra 0,8622).
- Juntas, essas três observações apontam para a mesma conclusão: a idade **não acrescentou nada** ao modelo, apenas diluiu o efeito da frequência cardíaca. Neste caso, a regressão simples é a melhor escolha.
- O ajuste da regressão múltipla no R é simples e a interpretação amplia a compreensão das relações entre várias variáveis e a resposta.

- **Importante:** Sempre verifique as suposições do modelo e a significância de cada preditor.

27.3 No R é fácil

A sintaxe para ajustar a regressão múltipla é muito parecida com a da simples, basta acrescentar as variáveis ao modelo:


```
lm(y ~ x + z, data = dados)
```


Se quiser incluir ainda mais variáveis, basta adicioná-las na fórmula, separadas por +.


Visualização dos resíduos

É importante, como sempre, checar os resíduos para garantir que as suposições do modelo continuam válidas:

```
plot(regressao_multipla)
```







Resíduos vs Valores Ajustados

- **Objetivo:** Avaliar linearidade e homocedasticidade (variância constante dos resíduos).
- **Interpretação:** Os resíduos estão distribuídos de forma aproximadamente aleatória ao redor de zero, sem padrões claros. Isso sugere que a relação linear é adequada e que a variância dos resíduos é razoavelmente constante. Não há grandes evidências de problemas de ajuste, ainda que um ou outro ponto se afaste mais do centro (possíveis outliers).

Q-Q Plot dos Resíduos

- **Objetivo:** Verificar se os resíduos seguem uma distribuição normal (suposição importante para testes de hipóteses na regressão).
- **Interpretação:** Os pontos seguem bem a linha reta, indicando que a normalidade dos resíduos é atendida na maior parte dos casos. Pequenos desvios nas extremidades são toleráveis, especialmente com amostras pequenas, como neste exemplo.

Scale-Location (Homocedasticidade)

- **Objetivo:** Avaliar se a variância dos resíduos é constante para todos os valores ajustados (homocedasticidade).
- **Interpretação:** Os pontos estão relativamente dispersos de forma homogênea ao longo do eixo dos valores ajustados, sem formar um funil ou padrão crescente/decrecente marcante. Isso reforça que a suposição de homocedasticidade está sendo atendida.

Resíduos Padronizados vs Leverage

- **Objetivo:** Identificar pontos com alto potencial de influência no modelo (outliers ou observações influentes).
- **Interpretação:** A maioria dos pontos está dentro dos limites aceitáveis de leverage e resíduos. Apenas um ou dois pontos apresentam valores de leverage mais altos, mas sem exceder drasticamente os limites de distância de Cook. Isso sugere que não há observações extremamente influentes comprometendo o modelo.

Os diagnósticos gráficos indicam que: - **As suposições do modelo de regressão múltipla estão razoavelmente bem atendidas:** linearidade, normalidade dos resíduos, homocedasticidade e ausência de pontos influentes extremos. - **O modelo é adequado para os dados analisados**, com apenas leves

indícios de possíveis outliers, mas sem comprometer as conclusões.

27.4 Exercício

O exercício “nutrientes em cereais matinais” foi retirado do livro Estatística Básica de Larson & Farber.

A *U.S. Food and Drug Administration* (FDA) exige a rotulagem nutricional para a maioria dos alimentos. Sob os regulamentos da FDA, os produtores são obrigados a listar as quantidades de certos nutrientes em seus alimentos, tais como: calorias, açúcar, gordura e carboidratos. Essa informação nutricional é exibida em uma tabela na embalagem do alimento.

A Tabela mostra o teor nutricional para uma xícara de 21 cereais matinais diferentes.

C = calorias

S = açúcar em gramas

F = gordura em gramas

R = carboidratos em gramas

C	S	F	R
100	12	0.5	25
130	11	1.5	29
110	10	1.0	29
130	15	2.0	31
130	13	1.5	29
120	3	0.5	26
100	2	0.0	24
120	0	0.0	29
150	16	1.5	31
110	4	0.0	25
110	12	1.0	23
160	15	1.5	35
150	12	2.0	36
150	15	1.5	29
110	15	0.0	29
190	13	1.5	45
100	3	0.0	23
120	4	0.5	23
120	11	1.5	28
120	11	1.0	29
130	5	0.5	29

1. Use o R para obter um diagrama de dispersão dos seguintes pares (x, y) no conjunto de dados.

- (a) (Calorias, açúcar.)
- (b) (Calorias, gordura.)
- (c) (Calorias, carboidratos.)
- (d) (Açúcar, gordura.)
- (e) (Açúcar, carboidratos.)
- (f) (Gordura, carboidratos.)

2. Dos diagramas de dispersão no Exercício 1, quais pares de variáveis parecem ter uma correlação linear forte?

3. Use o R para encontrar o coeficiente de correlação para cada par de variáveis no Exercício 1. Qual tem a correlação linear mais forte?
4. Use tecnologia para encontrar a equação de uma reta de regressão para os seguintes pares de variáveis.
 - (a) (Calorias, açúcar.)
 - (b) (Calorias, carboidratos.)
5. Use os resultados do Exercício 4 para prever o seguinte:
 - (a) O teor de açúcar de uma xícara de cereal que tem 120 calorias.
 - (b) O teor de carboidrato de uma xícara de cereal que tem 120 calorias.
6. Use tecnologia para encontrar as equações de regressão múltipla dos seguintes modelos:
 - (a) $C = b + m_1S + m_2F + m_3R$
 - (b) $C = b + m_1S + m_2R$
7. Use as equações do Exercício 6 para prever as calorias em 1 xícara de cereal que tem 7 gramas de açúcar; 0,5 grama de gordura e 31 gramas de carboidratos.

Chapter 28

Associação entre variáveis

Testes de associação são usados para verificar se existe uma relação estatisticamente significativa entre duas variáveis categóricas. A escolha do teste depende do tipo de variável e do tamanho da amostra.

A aplicação desses testes é fundamental em diversas áreas do conhecimento.

28.1 Tipos de Variáveis Envolvidas

Os testes de associação são aplicados principalmente a **variáveis qualitativas nominais**, como:

- Sexo (Masculino, Feminino)
- Presença de Doença (Sim, Não)

28.2 Tabela de Contingência

Uma **tabela de contingência** é uma ferramenta estatística utilizada para organizar e analisar a relação entre duas (ou mais) variáveis categóricas. Ela apresenta a distribuição conjunta das frequências observadas de cada combinação possível dos níveis das variáveis, facilitando a identificação de possíveis associações entre elas.

Exemplo:

Considere uma pesquisa em que se investiga a associação entre sexo e presença de uma determinada doença em uma amostra de pessoas:

	Doença: Sim	Doença: Não	Total
Masculino	8	7	15
Feminino	5	10	15
Total	13	17	30

Cada célula da tabela mostra o número de pessoas de cada sexo que têm ou não têm a doença, permitindo analisar se existe associação entre essas variáveis.

28.2.1 Cálculo das Frequências Esperadas

As **frequências esperadas** são valores teóricos que indicam quantas ocorrências seriam esperadas em cada célula de uma tabela de contingência caso não houvesse associação entre as variáveis (ou seja, se fossem independentes). Elas são fundamentais para a realização do teste qui-quadrado de independência.

Como calcular?

Para cada célula da tabela de contingência (frequências observadas), usamos a seguinte conta:

$$\text{Frequência Esperada} = \frac{\text{Total da Linha} \times \text{Total da Coluna}}{\text{Total Geral}}$$

- O “Total da Linha” é o total de pessoas daquela linha (por exemplo, todos os homens).
- O “Total da Coluna” é o total de pessoas daquela coluna (por exemplo, todos que têm a doença).
- O “Total Geral” é o total de pessoas da tabela toda.

Da tabela de contingência do exemplo anterior, podemos efetuar os cálculos

1. Masculino, Doença: Sim

$$\frac{15 \times 13}{30} = \frac{195}{30} = 6,5$$

2. Masculino, Doença: Não

$$\frac{15 \times 17}{30} = \frac{255}{30} = 8,5$$

3. Feminino, Doença: Sim

$$\frac{15 \times 13}{30} = 6,5$$

4. Feminino, Doença: Não

$$\frac{15 \times 17}{30} = 8,5$$

Então, nesse caso a tabela de frequências esperadas é dada por:

	Doença: Sim	Doença: Não	Total da linha
Masculino	6,5	8,5	15
Feminino	6,5	8,5	15
Total da coluna	13	17	30

A tabela acima mostra as frequências que seriam esperadas em cada célula caso não existisse associação entre sexo e presença de doença.

A essência dos testes de associação é comparar a tabela de frequências observadas (com os dados reais coletados) com a tabela de frequências esperadas (calculada considerando que não exista relação entre as variáveis, ou seja, que sejam independentes). A tabela observada mostra quantas vezes cada combinação de categorias realmente aconteceu, enquanto a tabela esperada mostra quantas vezes cada combinação seria esperada ao acaso. O teste avalia se as diferenças entre o que foi observado e o que seria esperado são grandes o suficiente para indicar uma associação entre as variáveis. Portanto, a comparação entre essas duas tabelas está no centro da análise para determinar se existe ou não uma relação significativa entre as variáveis estudadas.

Na prática, todos esses cálculos acontecem nos bastidores, pois utilizamos ferramentas computacionais que realizam automaticamente tanto o cálculo das frequências esperadas quanto a comparação com os valores observados. Assim, normalmente não precisamos calcular manualmente cada valor esperado ou montar todas as tabelas. No entanto, é fundamental compreender o conceito central dos testes de associação: eles servem para comparar o que foi realmente observado com o que seria esperado caso não houvesse relação entre as variáveis, ajudando a identificar se existe ou não uma associação significativa entre elas.

28.3 Principais Testes de Associação

É importante destacar que existem diversos métodos estatísticos para analisar a associação entre variáveis categóricas, dependendo do tipo de dados e da estrutura da tabela de contingência.

Além dos tradicionais teste qui-quadrado e teste exato de Fisher, há outros métodos que podem ser aplicados conforme a situação:

- O **teste G** (ou teste da razão de verossimilhança) é uma alternativa ao qui-quadrado, baseado em outra abordagem matemática, mas com objetivo semelhante.
- O **teste de McNemar** é indicado para tabelas 2x2 com dados pareados, como em estudos antes e depois.
- O **teste de Mantel-Haenszel** avalia a associação entre variáveis, controlando possíveis fatores de confusão por meio da estratificação, sendo muito usado em estudos epidemiológicos.
- O **teste de tendência linear de Cochran-Armitage** é recomendado quando as categorias possuem uma ordem natural e se deseja avaliar a existência de tendência linear entre elas.
- Existem ainda o **teste de concordância Kappa de Cohen**, que mede o grau de concordância entre avaliadores, e o **teste exato de Barnard**, alternativa ao teste de Fisher em tabelas 2x2.

A escolha do teste adequado depende do tamanho da amostra, da distribuição dos dados, do tipo de variável (nominal ou ordinal), da estrutura dos dados (independentes ou pareados) e do objetivo da análise.

28.3.1 Exemplos

Exemplo na Medicina:

Investigar se há associação entre o sexo do paciente (masculino/feminino) e a presença de hipertensão (sim/não).

- **Variáveis:** Sexo (masculino, feminino) e hipertensão (sim, não)
- **Aplicação:** Monta-se uma tabela de contingência 2x2 e aplica-se o teste de associação para verificar se a proporção de hipertensos difere entre os sexos.

Exemplos na Psicologia

Verificar se existe associação entre tipo de terapia utilizada (cognitivo-comportamental, psicanalítica, humanista) e desfecho do tratamento (melhorou/não melhorou) em pacientes.

- **Variáveis:** Tipo de terapia (três categorias) e desfecho (melhorou, não melhorou)
- **Aplicação:** Monta-se uma tabela de contingência 3x2 e aplica-se o teste de associação para analisar se o tipo de terapia está associado ao desfecho.

Exemplo na Educação Física

Analisar se há associação entre a participação em atividades extracurriculares (sim/não) e o nível de aptidão física (baixo/médio/alto) em estudantes do ensino médio.

- **Variáveis:** Participação em atividades (sim, não) e aptidão física (baixo, médio, alto)
- **Aplicação:** Cria-se uma tabela de contingência 2x3 e utiliza-se o teste de associação para verificar se a aptidão física difere conforme a participação em atividades extracurriculares.

28.3.2 Teste Qui-Quadrado

O teste **qui-quadrado** ⁽²⁾ é um dos métodos mais utilizados para avaliar se existe associação entre duas variáveis categóricas. Ele funciona comparando as frequências observadas nas células de uma tabela de contingência com as frequências que seriam esperadas caso não houvesse relação entre as variáveis.

- **Hipótese nula (H_0):** Não existe associação entre as variáveis “x” e “y”, ou seja, elas são independentes.
- **Hipótese alternativa (H_1):** Existe associação entre as variáveis.

Principais requisitos:

- A amostra deve ser aleatória.
- Pelo menos 80% das células da tabela devem ter frequência esperada igual ou superior a 5.
- Nenhuma célula deve ter frequência esperada igual a zero.

Observação: Nenhuma célula deve ter frequência esperada igual a zero porque, no teste qui-quadrado, a fórmula envolve dividir pela frequência esperada. Se algum valor esperado for zero, não é possível fazer a divisão, pois divisão por zero é indefinida. Além disso, uma frequência esperada igual a zero indica que, teoricamente, aquela combinação de categorias não deveria

ocorrer nunca, o que torna os cálculos e os resultados do teste estatístico inválidos ou sem sentido. Por isso, é importante garantir que todas as células tenham valores esperados maiores que zero para que o teste seja matematicamente correto e confiável.

O teste qui-quadrado pode ser aplicado em tabelas maiores que 2x2.

28.3.3 Teste Exato de Fisher

O **teste exato de Fisher** é recomendado quando os tamanhos das amostras são pequenos ou quando as frequências esperadas em alguma célula da tabela são menores que 5, situação em que o teste qui-quadrado pode não ser confiável.

- **Hipótese nula (H_0):** Não existe associação entre as variáveis “x” e “y”, ou seja, elas são independentes.
- **Hipótese alternativa (H_1):** Existe associação entre as variáveis.
- É mais conservador do que o qui-quadrado, pois calcula a probabilidade exata de ocorrência das frequências observadas.
- Tradicionalmente, é utilizado para tabelas 2x2 (dois grupos e duas categorias), mas pode ser estendido a tabelas maiores com recursos computacionais.
- Não depende das condições de frequência esperada mínima.

28.3.4 Exemplo no R

Vamos analisar se há associação entre sexo (Masculino/Feminino) e presença de doença (Sim/Não) com os seguintes dados, da tabela de contingência que foi mencionada anteriormente:

	Doença: Sim	Doença: Não
Masculino	8	7
Feminino	5	10

Essa tabela pode ser repassada diretamente para o R:

```
# Crie a matriz de dados
tabela <- matrix(c(8, 7,      # observe o uso de matrix() e c()
                  5, 10),    # observe os parênteses
                nrow = 2,    # numero de linhas
                byrow = TRUE) # você está informando por linhas (by row)

# é opcional, mas ficará mais claro que se você nomear
# as linhas (row) e colunas (col) da sua tabela
colnames(tabela) <- c("Doença: Sim", "Doença: Não")
rownames(tabela) <- c("Masculino", "Feminino")

# Veja como ficou a tabela
tabela
```

```
##          Doença: Sim Doença: Não
## Masculino          8           7
## Feminino           5          10
```

Para fazer o teste Qui-quadrado no R usamos `chisq.test()`:

```
# Aplicando o teste qui-quadrado
resultado <- chisq.test(tabela)

# Veja o resultado
resultado
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabela
## X-squared = 0.54299, df = 1, p-value = 0.4612
```

O resultado apresentado refere-se ao teste qui-quadrado de Pearson com a correção de continuidade de Yates, usada para tabelas 2x2:

A **correção de continuidade de Yates** é um ajuste aplicado ao teste qui-quadrado em tabelas 2x2 para evitar superestimação da significância estatística, especialmente em amostras pequenas. Ela consiste em diminuir a diferença entre os valores observados e esperados antes de calcular o qui-quadrado, tornando o teste mais conservador.

- **X-squared:** Valor do qui-quadrado calculado $\chi^2 = 0,543$.
- **df:** Graus de liberdade (1), determinado pelo número de linhas e colunas da tabela. O cálculo é feito pela fórmula:
 $df = (\text{número de linhas} - 1) \text{ e } (\text{número de colunas} - 1)$.
 No exemplo, temos 2 linhas e 2 colunas: $(2-1) \text{ e } (2-1) = 1$.
- **p-value:** Valor de p (0,4612)

Como o valor de p é 0,4612 (maior do que o nível de significância de 0,05), **não há evidências suficientes para rejeitar a hipótese nula**. Portanto, não foi encontrada associação estatisticamente significativa entre sexo e presença de doença nessa amostra.

E, caso queira visualizar as tabelas de valores observados e esperados basta fazer o seguinte:

```
# Exibir os valores observados
resultado$observed
```

```
##          Doença: Sim Doença: Não
## Masculino          8          7
## Feminino           5         10
```

```
# Exibir os valores esperados
resultado$expected
```

```
##          Doença: Sim Doença: Não
## Masculino        6.5         8.5
## Feminino         6.5         8.5
```

Observação: Se alguma frequência esperada for menor que 5, o R emitirá um alerta. Nesses casos, considere usar o teste exato de Fisher:

```
fisher.test(tabela)
```

Por exemplo, se substituirmos o 7 por 1, teremos

```
##          Doença: Sim Doença: Não
## Masculino          8          1
## Feminino           5         10

## Warning in chisq.test(tabela2): Aproximação do qui-quadrado pode estar
## incorreta

##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabela2
## X-squared = 4.9343, df = 1, p-value = 0.02633

##
## Fisher's Exact Test for Count Data
```

```
##
## data:  tabela2
## p-value = 0.01306
## alternative hypothesis: true odds ratio is not equal to 1
## 95 percent confidence interval:
##      1.30156 774.69430
## sample estimates:
## odds ratio
##      14.06912
```

- **p-value = 0.01306:** O valor de p é menor que 0,05, indicando que existe uma associação estatisticamente significativa entre as duas variáveis analisadas. Isso significa que a chance de observarmos essa diferença (ou uma diferença maior) apenas por acaso é de aproximadamente 1,3%.
- **Odds ratio = 14.07:** A razão de chances estimada é 14 vezes maior em um grupo do que no outro, sugerindo uma associação forte entre as categorias das variáveis.
- **Intervalo de confiança (1,30 a 774,69):** O intervalo de confiança de 95% mostra que a razão de chances verdadeira, na população, pode variar de cerca de 1,3 até 774,7. Como esse intervalo não inclui o valor 1, reforça-se a evidência de associação.

28.3.5 Observação sobre tabelas de contingência em artigos científicos

Quando lemos um artigo que apresenta uma **tabela de contingência** (por exemplo, uma tabela cruzando sexo e presença de doença), estamos vendo exatamente a amostra utilizada pelo autor, com a distribuição real dos indivíduos nos diferentes grupos. Isso é diferente do que ocorre em testes de comparação de médias (como t-teste) ou correlação, onde geralmente temos acesso apenas a medidas-resumo (como média, desvio-padrão, coeficiente de correlação), e não aos dados individuais.

Nesse sentido, **ter a tabela de contingência é praticamente o mesmo que ter os dados brutos** dos autores, pois conhecemos exatamente a quantidade de participantes em cada combinação de categorias. Isso possibilita que qualquer leitor possa refazer os cálculos dos testes estatísticos (como o qui-quadrado ou Fisher) e, inclusive, explorar outras análises categóricas de interesse.

Em resumo, a tabela de contingência oferece um grau de transparência e reprodutibilidade muito maior do que apenas apresentar medidas-resumo, pois expõe toda a estrutura dos dados da amostra analisada.

28.4 Tamanho do Efeito: Medidas de Associação

Ao realizar testes de independência como o Qui-Quadrado ou o teste exato de Fisher para tabelas de contingência, é importante não apenas analisar o p-valor, mas também quantificar o tamanho do efeito, ou seja, a força da associação entre as variáveis categóricas.

A seguir são mostradas as principais medidas de tamanho de efeito.

28.4.1 V de Cramér

- **Descrição:** mede a intensidade da associação entre duas variáveis categóricas. Varia de 0 (nenhuma associação) a 1 (associação perfeita).
- **Uso:** Indicado para tabelas de contingência de qualquer dimensão.

Fórmula:

$$V = \frac{\sqrt{\chi^2}}{\sqrt{n(k-1)}}$$

- χ^2 = valor do teste Qui-Quadrado
- n = total de observações
- k = menor número entre linhas ou colunas

No R:

```
library(rcompanion)
cramerV(tabela)
```

```
## Cramer V
## 0.2018
```

ou

```
library(DescTools)
CramerV(tabela)
```

```
## [1] 0.2018018
```

Se você tentar refazer a conta na mão, atenção a um detalhe: o χ^2 que entra na fórmula do V é o valor **sem** a correção de continuidade de Yates. O `chisq.test()` aplica Yates por padrão em tabelas 2x2 e devolveu 0,543 — mas $0,543/30 = 0,13$, e não 0,20.

Para obter o χ^2 que as funções acima realmente usam, peça a versão sem correção:

```
chisq.test(tabela, correct = FALSE)$statistic
```

```
## X-squared
## 1.221719
```

Agora a conta fecha: $1,2217/30 = 0,2018$, exatamente o V de Cramér devolvido pelo R.

28.4.2 Phi de Pearson ()

- **Descrição:** Medida de associação para tabelas 2x2. Varia de 0 a 1.
- **Uso:** Exclusivo para tabelas 2x2.

Fórmula:

$$= \frac{\chi^2}{n}$$

No R:

```
library(DescTools)
Phi(tabela)
```

```
## [1] 0.2018018
```

Interpretação dos valores:

- **V de Cramér:**
 - Pequeno: $\sim 0,1$
 - Moderado: $\sim 0,3$
 - Forte: $\sim 0,5$ ou mais
- **Phi:** Interpretação semelhante ao V de Cramér para 2x2.

No exemplo, o valor obtido para o **V de Cramér** ou **Phi** foi de **0,20**. De acordo com os critérios usuais para essa medida, valores em torno de 0,1 indicam associação pequena, valores próximos de 0,3 associação moderada e valores a partir de 0,5 associação forte entre as variáveis analisadas.

Além disso, como o teste estatístico realizado (por exemplo, Qui-Quadrado ou Fisher) indicou que **não há associação significativa** entre as variáveis ($p > 0,05$), o resultado do V de Cramér reforça essa conclusão. Um valor de 0,20 sugere uma associação fraca, e como não há significância estatística, não se pode afirmar que exista uma relação relevante entre as variáveis na população estudada.

28.4.3 Odds Ratio (Razão de Chances)

- **Descrição:** O Odds Ratio (OR) mede a força da associação entre dois eventos em tabelas 2x2, comparando as chances (odds) de um evento ocorrer em dois grupos diferentes. Ele indica se a ocorrência do evento em um grupo é mais, menos ou igualmente provável em relação ao outro grupo.
- **Uso:** Teste de Fisher e tabelas 2x2.

Considere a estrutura da tabela 2x2:

	Evento Presente	Evento Ausente
Grupo 1	a	b
Grupo 2	c	d

Então odds ratio (OR), pode ser facilmente calculado:

$$OR = \frac{a \oslash d}{b \oslash c}$$

Onde:

- **a** = número de casos com o evento presente no Grupo 1
- **b** = número de casos com o evento ausente no Grupo 1
- **c** = número de casos com o evento presente no Grupo 2
- **d** = número de casos com o evento ausente no Grupo 2

A interpretação do OR é a seguinte:

- **OR = 1:**
Não há diferença entre os grupos. O evento tem a mesma chance de acontecer no Grupo 1 e no Grupo 2.
Exemplo: Se o OR for 1, os dois grupos têm risco igual para o evento.
- **OR > 1:**
O evento é mais provável no **Grupo 1** do que no Grupo 2.
Exemplo: Se o OR for 2, o Grupo 1 tem o dobro de chance do evento comparado ao Grupo 2.
- **OR < 1:**
O evento é menos provável no **Grupo 1** do que no Grupo 2.
Exemplo: Se o OR for 0,5, o Grupo 1 tem metade da chance do evento comparado ao Grupo 2.

No R:

```
fisher.test(tabela)$estimate
```

```
## odds ratio
##      2.22194
```

Por que 2,22 e não 2,29? A fórmula $OR = (a \oslash d) / (b \oslash c)$ aplicada a esta tabela dá $(8 \oslash 10) / (7 \oslash 5) = 2,286$. Já a `fisher.test()` devolve um estimador ligeiramente diferente — a estimativa de máxima verossimilhança condicional —, que aqui vale 2,222. Os dois respondem à mesma pergunta e levam à mesma conclusão; a diferença aparece sobretudo em amostras pequenas. Se quiser a razão de produtos cruzados exata, calcule-a diretamente: $(8*10)/(7*5)$.

O odds ratio (OR) calculado pela `fisher.test()` foi de **2,22**.

- O OR compara as chances de ocorrência da doença entre os grupos “Masculino” e “Feminino”.
- **OR = 2,22** indica que as chances de um indivíduo do sexo masculino ter a doença são aproximadamente **2,2 vezes maiores** do que as chances de um indivíduo do sexo feminino.

- Em outras palavras, a doença é mais provável entre os homens do que entre as mulheres neste conjunto de dados.

Ou usando o pacote `epitools`:

```
# install.packages("epitools")
library(epitools)
oddsratio(tabela)

## $data
##          Doença: Sim Doença: Não Total
## Masculino          8          7    15
## Feminino           5         10    15
## Total             13         17    30
##
## $measure
##                NA
## odds ratio with 95% C.I. estimate lower upper
##      Masculino 1.000000         NA      NA
##      Feminino  2.203004 0.498955 10.60706
##
## $p.value
##                NA
## two-sided midp.exact fisher.exact chi.square
##      Masculino      NA      NA      NA
##      Feminino 0.3007786 0.4621374 0.2690235
##
## $correction
## [1] FALSE
##
## attr("method")
## [1] "median-unbiased estimate & mid-p exact CI"
```

- O odds ratio (OR) indica que as chances de “Doença: Sim” são cerca de 2,2 vezes maiores no grupo **Masculino** em relação ao grupo **Feminino**.
- O intervalo de confiança (IC) de 95% para o OR do grupo Feminino é de 0,50 a 10,61, o que inclui o valor 1. Isso sugere que esta diferença **não é estatisticamente significativa**.
- Valores de p

Grupo	midp.exact	fisher.exact	chi.square
Feminino	0,3008	0,4621	0,2690

- Todos os valores de p são **maiores do que 0,05**, indicando que não há associação estatisticamente significativa entre sexo e presença de doença nesta amostra.
- O uso da função `oddsratio()` do pacote `epitools` mostrou um OR de 2,2 para o grupo masculino, mas essa diferença (entre os grupos feminino e masculino) não é estatisticamente significativa. Isso significa que, com base nesses dados, não se pode concluir que há uma associação real entre sexo e presença de doença.

28.5 Cálculo do Poder Estatístico

O poder estatístico pode ser estimado usando o pacote `pwr`, útil para calcular tamanho de efeito ou tamanho de amostra necessário.

```
# Exemplo para efeito 0,2, alfa = 0.05 e N = 30 (OBSERVE o N em MAIÚSCULO, tamanho da amostra)
pwr.chisq.test(w = 0.2, df = 1, N = 30, sig.level = 0.05)
```

```
##
##      Chi squared power calculation
##
##          w = 0.2
##          N = 30
##          df = 1
##      sig.level = 0.05
##          power = 0.1947752
##
## NOTE: N is the number of observations
```

- **w (tamanho do efeito):**

- Representa o tamanho do efeito. Em tabelas **2x2**, w é igual ao V de Cramér (e ao Phi).
- Em tabelas maiores, a relação é $w = V \oslash k \wedge 1$, onde k é o menor número entre linhas e colunas. Por exemplo, numa tabela 3x2 com $V = 0,2$, teríamos $w = 0,2 \oslash 1 = 0,2$; já numa 3x3, $w = 0,2 \oslash 2 = 0,28$.

- **df (graus de liberdade):**

- Indica o número de graus de liberdade do teste.
- Em uma tabela de contingência, é calculado como:
(número de linhas – 1) $\oslash$ (número de colunas – 1)
- Exemplo: Para uma tabela 2x2, $df = (2-1) \oslash (2-1) = 1$

Com uma amostra de 30 indivíduos, tentando detectar um efeito pequeno ($w = 0,2$) em um teste do qui-quadrado com 1 grau de liberdade e nível de significância de 5%, o poder do teste é de apenas cerca de **19,5%**.

Isso significa que, se realmente existir uma associação do tamanho especificado entre as variáveis, o teste só terá cerca de 19,5% de chance de detectar essa associação (ou seja, rejeitar a hipótese nula corretamente).

Em geral, recomenda-se um poder estatístico de pelo menos 80% (0,8) para que o teste tenha boa chance de detectar uma associação real. Portanto, **com essa configuração, o teste está subdimensionado (pouco poder)** para detectar efeitos pequenos.

Chapter 29

Ciência Aberta

Ao longo do livro, todos os bancos que usamos vieram de fontes abertas: o SINASC do DATASUS, o Pokemon e a tabela nutricional do McDonald's, publicados por quem os produziu para que qualquer pessoa pudesse usar. Isso não é coincidência nem conveniência. É um movimento com nome: **ciência aberta**.

E ele tem consequência prática direta para você, que está começando a pesquisar: é ciência aberta que torna possível fazer um bom trabalho sem ter orçamento para coletar dados próprios.

29.1 O que é ciência aberta

A ideia central é simples: o conhecimento produzido com dinheiro público deve estar disponível para qualquer pessoa. Na prática, isso se desdobra em quatro frentes.

Acesso aberto é o artigo poder ser lido sem assinatura. Muita revista científica cobra caro pelo acesso, e sem vínculo com uma universidade rica você fica de fora. As revistas de acesso aberto derrubam essa barreira.

Dados abertos é o banco de dados por trás do artigo estar disponível. Isso permite que outra pessoa confira os resultados, e permite que alguém faça uma pergunta nova com os mesmos dados — que é exatamente o que fizemos neste livro.

Código aberto é o programa usado na análise poder ser inspecionado. O R é software livre: qualquer um pode ler o código de qualquer função, verificar o que ela faz e corrigi-la. Você não precisa acreditar que a `t.test()` está certa; pode conferir.

Reprodutibilidade é conseguir refazer a análise e chegar ao mesmo resultado. É por isso que usamos `set.seed()` em toda simulação deste livro: sem a semente, cada execução daria números diferentes, e você não teria como confirmar que o que está impresso aqui é o que o código realmente produz.

29.2 Por que isso importa para o seu trabalho

Coletar os próprios dados é uma habilidade central da pesquisa, e é o que muitos de vocês vão fazer no TCC: definir a população, calcular a amostra, submeter ao Comitê de Ética, aplicar o instrumento, acompanhar a coleta. Nada disso é dispensável, e este livro inteiro foi escrito para preparar você para essas etapas.

Os dados abertos são **outro caminho**, com forças próprias, e não um atalho para escapar da coleta.

A principal delas é a **escala**. Nenhum estudante consegue, sozinho, acompanhar todos os nascimentos de uma cidade em um ano. Foi exatamente isso que fizemos: o banco de Uberaba tem 3.602 registros reais, e nenhum deles precisou ser coletado por nós. Com esse tamanho, dá para investigar diferenças pequenas e comparar subgrupos — coisas que uma amostra de trinta questionários não permite.

A segunda é o **tempo**. Bancos como o SINASC existem desde os anos 1990, então você pode olhar dez anos de série histórica e perguntar como algo mudou, o que uma coleta feita agora jamais responderia.

A terceira é a de **eventos raros**. Se o desfecho que interessa acontece em um caso a cada mil, uma coleta de porte estudantil não vai encontrá-lo; um registro nacional, sim.

E há uma quarta, que costuma passar despercebida: usar dados que já existem **não expõe novas pessoas** a questionário, entrevista ou procedimento. Reaproveitar um dado bem coletado é, em si, uma escolha eticamente boa.

Não é à toa que boa parte da produção em epidemiologia é feita com dados secundários. É um caminho legítimo, e muitas vezes o único possível para a pergunta que você quer fazer.

A contrapartida é real: com dado secundário, você trabalha com as variáveis que alguém já decidiu coletar, para uma finalidade que não era a sua. Se a sua pergunta depende de uma informação que não está lá, nenhuma análise vai resolver — e aí a coleta própria deixa de ser opção e passa a ser necessidade.

Usar dado aberto não dispensa cuidado ético nem citação. O banco tem autoria, tem uma finalidade original e tem limitações. Cite a fonte, leia a documentação e não force o dado a responder uma pergunta que ele não pode responder. E confirme com seu orientador se o seu projeto precisa passar pelo Comitê de Ética: o uso de dados públicos anonimizados costuma ser dispensado, mas essa avaliação não é sua.

29.3 Onde encontrar dados abertos

29.3.1 No Brasil

Fonte	O que tem	Endereço
DATASUS	Nascimentos, óbitos, internações, notificações de agravos	https://datasus.saude.gov.br/transferecia-de-arquivos
IBGE / SIDRA	Censo, pesquisas domiciliares, indicadores sociais	https://sidra.ibge.gov.br
Portal Brasileiro de Dados Abertos	Dados de todos os órgãos do governo federal	https://dados.gov.br
Base dos Dados	Bases públicas já tratadas e padronizadas	https://basedosdados.org
SciELO Data	Dados depositados por autores de artigos da SciELO	https://data.scielo.org

O DATASUS merece destaque para quem é da área da saúde, e por isso tem um capítulo só dele logo a seguir.

29.3.2 Repositórios internacionais

Repositório	Perfil	Endereço
Zenodo	Generalista, mantido pelo CERN; dá DOI a qualquer depósito	https://zenodo.org
Figshare	Generalista, muito usado para material suplementar de artigos	https://figshare.com
OSF	Projetos inteiros: dados, código, registro e pré-print no mesmo lugar	https://osf.io
Harvard Dataverse	Grande acervo, forte em ciências sociais	https://dataverse.harvard.edu
PhysioNet	Sinais fisiológicos e dados clínicos	https://physionet.org

Repositório	Perfil	Endereço
re3data	Não guarda dados: é um catálogo de repositórios, para você achar o certo	https://www.re3data.org

29.4 Onde encontrar artigos abertos

A **SciELO** (<https://scielo.org>) reúne a produção científica da América Latina, em acesso aberto e em português. Deve ser sua primeira parada.

O **DOAJ** (<https://doaj.org>), *Directory of Open Access Journals*, cataloga revistas de acesso aberto do mundo todo e serve para checar se uma revista é confiável antes de submeter.

O **PubMed Central** (<https://pmc.ncbi.nlm.nih.gov>) é o acervo aberto da área biomédica.

E o **Portal de Periódicos da CAPES** (<https://www.periodicos.capes.gov.br>) dá acesso, pela sua conta institucional, a revistas que de outra forma seriam pagas. Vale aprender a usar: é um recurso que você tem por ser estudante de universidade pública e que costuma passar despercebido.

29.4.1 Pré-prints

Um **pré-print** é o artigo publicado pelos autores antes da revisão por pares. Sai rápido, às vezes um ano antes da versão final, mas **ainda não foi avaliado por outros pesquisadores** — trate com cautela e diga na sua citação que é um pré-print.

Os principais são o **SciELO Preprints** (<https://preprints.scielo.org>), em português, o **medRxiv** (<https://www.medrxiv.org>) para saúde e o **PsyArXiv** (<https://psyarxiv.com>) para psicologia.

29.5 Registro de estudos

Antes de começar uma pesquisa, é boa prática registrá-la publicamente, dizendo o que você vai medir e como vai analisar. Isso impede uma prática comum e problemática: testar várias hipóteses e depois relatar só a que deu significativa.

No Brasil, o registro de ensaios clínicos é feito no **ReBEC** (<https://ensaiosclinicos.gov.br>). Internacionalmente, no **ClinicalTrials.gov** (<https://clinicaltrials.gov>). Para estudos que não são ensaios clínicos, o **OSF** permite registrar o plano de análise.

29.6 Como tornar a sua pesquisa aberta

Você também pode contribuir, e isso pesa a favor do seu trabalho.

Deposite os seus dados em um repositório que dê DOI, como o Zenodo ou o OSF, e cite esse DOI no artigo. Se os dados forem sensíveis, deposite ao menos o dicionário de variáveis e o código.

Publique o seu código. O script que gerou os seus resultados é parte do método. Este livro faz isso: os scripts que produziram os bancos usados aqui estão publicados junto com ele.

Escolha uma licença. Sem licença explícita, ninguém sabe o que pode fazer com o seu material. As licenças **Creative Commons** (<https://creativecommons.org/licenses/>) resolvem isso em uma linha.

Cite os dados que usar como você citaria um artigo, com autor, ano, título, repositório e DOI. Dado é produção intelectual, e quem o disponibilizou merece o crédito.

Repare que este livro é, ele mesmo, um exercício de ciência aberta: está em acesso aberto, foi escrito com software livre, o código de todas as análises está à vista em cada capítulo, e os bancos usados estão disponíveis para download.

Chapter 30

Dados do DATASUS

Este capítulo é dirigido principalmente a quem é da área da **saúde**, mas vale a leitura para todo mundo: ele mostra como se chega a um banco de dados nacional, real e gratuito, sem coletar nada.

O **DATASUS** é o departamento de informática do SUS, e ele publica os microdados de vários sistemas de informação em saúde. “Microdado” quer dizer que cada linha é **um caso** — um nascimento, um óbito, uma internação — e não um total já resumido. É isso que permite fazer as próprias análises em vez de depender das tabelas que alguém já montou.

30.1 Os principais sistemas

Sigla	O que registra	Uma pergunta que ele responde
SINASC	Nascidos vivos	O peso ao nascer varia com a escolaridade da mãe?
SIM	Óbitos	Qual a taxa de mortalidade por causa externa entre jovens?
SIH	Internações hospitalares do SUS	Quanto tempo dura, em média, uma internação por AVC?
SIA	Procedimentos ambulatoriais	Quantas consultas especializadas são feitas por região?
SINAN	Doenças de notificação compulsória	Como a dengue se distribui ao longo do ano?
CNES	Estabelecimentos de saúde	Quantos leitos de UTI existem por município?

Todos são de acesso público e cobrem o país inteiro, com séries que em alguns casos começam nos anos 1990.

30.2 O pacote microdatasus

Os arquivos do DATASUS vêm em um formato antigo e compactado (`.dbc`), que não abre direto no R. O pacote **microdatasus**, criado por pesquisadores brasileiros, resolve isso: ele baixa, descompacta e ainda traduz os códigos numéricos para rótulos legíveis.

```
install.packages("microdatasus")
library(microdatasus)
```

O pacote foi desenvolvido por Raphael Saldanha, Ronaldo Bastos e Christovam Barcellos, e descrito em artigo nos *Cadernos de Saúde Pública* (2019). Se você usá-lo no seu trabalho, **cite o artigo** — é assim que quem constrói ferramenta gratuita para a comunidade recebe crédito. A referência está no fim do livro, e o próprio R mostra a forma correta com `citation("microdatasus")`.

O uso tem sempre dois passos. Primeiro `fetch_datasus()` baixa os dados brutos:

```
bruto <- fetch_datasus(
  year_start = 2022,
  year_end   = 2022,
  uf         = "MG",
  information_system = "SINASC"
)
```

Depois, uma função `process_*()` correspondente ao sistema traduz os códigos:

```
rotulado <- process_sinasc(bruto)
```

Sem esse segundo passo, o sexo do recém-nascido vem como 1 e 2, e o tipo de parto como 1 e 2, em vez de “Masculino”/“Feminino” e “Vaginal”/“Cesáreo”.

Existe uma função `process_` para cada sistema: `process_sinasc()`, `process_sim()`, `process_sih()`, `process_sia()`, `process_cnes()` e uma para cada agravo do SINAN, como `process_sinan_dengue()`.

30.3 Duas armadilhas que valem ouro

Estas duas foram descobertas montando o banco de nascimentos que usamos no livro, e nenhuma delas está escrita de forma óbvia na documentação.

30.3.1 O código de “ignorado”

O DATASUS não deixa campos em branco: ele preenche o desconhecido com códigos como 9999, 99 ou 9. Se você calcular uma média sem filtrar isso, o resultado sai completamente errado — imagine um peso ao nascer de 9.999 gramas entrando na conta.

Por isso, antes de qualquer análise, restrinja cada variável a valores plausíveis:

```
peso_g <- ifelse(peso_g %in% 250:7000, peso_g, NA)
```

Tudo que estiver fora da faixa vira NA, e aí você trata como aprendemos no capítulo de importação, com `na.rm = TRUE`.

30.3.2 O `process_sinasc()` zera o peso

Esta é específica e traiçoeira: a função `process_sinasc()` devolve a coluna PESO inteiramente vazia. O dado está perfeito no banco **bruto**, mas se perde no processamento.

A solução é ler o peso do bruto e o resto do rotulado:

```
peso_g <- as.numeric(bruto$PESO)      # do banco bruto
sexo   <- rotulado$SEXO                # do banco rotulado
```

A lição vale além deste caso: depois de qualquer processamento, **confira se as suas variáveis continuam lá**. Um `summary()` ou um `colSums(is.na(seu_banco))` mostram na hora se alguma coluna virou só NA. Foi assim que este problema apareceu.

30.4 O banco de nascimentos deste livro

O `nascimentos.csv` que usamos nos exemplos foi montado exatamente desse jeito: 3.602 nascimentos registrados em Uberaba em 2022, filtrados a partir dos 235.063 de Minas Gerais.

O script completo e comentado está aqui: **dados-nascimentos.R**. Ele é curto, e você pode adaptá-lo trocando duas linhas:

```
UF           <- "MG"
MUNICIPIO    <- "Uberaba"  # NULL para manter o estado inteiro
```

Trocando para o seu estado e o seu município, você tem em minutos um banco da sua realidade local — o que costuma render trabalhos muito mais interessantes que analisar dados de outro lugar.

A filtragem por município usa a coluna `munResNome`, que o `process_sinasc()` acrescenta com o nome do município de residência da mãe.

30.5 Um exemplo do começo ao fim

Vamos percorrer uma análise inteira, do jeito que você faria em um trabalho de verdade. A pergunta é simples e tem importância de saúde pública:

Bebês de mães adolescentes nascem com peso menor?

É uma hipótese que parece óbvia, e é justamente por isso que vale testá-la.

30.5.1 Passo 1: trazer os dados

```
library(readr)
library(dplyr)

nascimentos <- read_csv("https://ana-mat-br.github.io/dados/nascimentos.csv")

# quantos registros temos?
nrow(nascimentos)

## [1] 3602
```

30.5.2 Passo 2: criar o grupo que vamos comparar

O banco traz a idade da mãe em anos, mas a nossa pergunta é sobre dois grupos. Precisamos, então, criar uma variável qualitativa a partir de uma quantitativa. A função `ifelse()` faz isso: testa uma condição e devolve um valor se ela for verdadeira e outro se for falsa.

```
nascimentos$grupo <- ifelse(nascimentos$idade_mae < 20,
                             "Adolescente",
                             "20 anos ou mais")

table(nascimentos$grupo)

##
## 20 anos ou mais      Adolescente
##           3240           362
```

São 362 mães adolescentes e 3.240 com 20 anos ou mais. Repare que os grupos têm tamanhos bem diferentes: isso é comum com dados reais e não impede a comparação.

30.5.3 Passo 3: olhar antes de testar


Nunca aplique um teste sem antes olhar os dados. Comece pelas medidas resumo, separadas por grupo:

```
aggregate(peso_g ~ grupo, data = nascimentos,
           FUN = function(x) c(n = length(x),
                                media = round(mean(x), 1),
                                dp = round(sd(x), 1),
                                mediana = median(x)))

##           grupo peso_g.n peso_g.media peso_g.dp peso_g.mediana
## 1 20 anos ou mais  3240.0      3098.2     578.0      3165.0
## 2   Adolescente   362.0      3074.5     531.2      3080.0
```

E depois pelo boxplot, que mostra a distribuição inteira:

```
boxplot(peso_g ~ grupo, data = nascimentos,
        xlab = "", ylab = "Peso ao nascer (g)",
        col = c("lightblue", "lightpink"))
```



As duas caixas são muito parecidas. A diferença entre as médias é de apenas 24 gramas. Guarde essa impressão: o teste vai confirmá-la.

30.5.4 Passo 4: escolher o teste

Seguindo o fluxograma do capítulo de comparação entre dois grupos: são **dois grupos, não pareados** (cada bebê está em um grupo só) e a variável de resposta é **quantitativa**. Falta decidir entre o teste t e o de Wilcoxon, e para isso verificamos a normalidade **dentro de cada grupo** — é sobre cada grupo, e não sobre a variável inteira, que a suposição se aplica.


Comece pelo **gráfico QQ**, que é o mais informativo. Vamos fazer um para cada grupo, lado a lado:

```
# separa os dois grupos
adolescente <- nascimentos$peso_g[nascimentos$grupo == "Adolescente"]
adultas     <- nascimentos$peso_g[nascimentos$grupo == "20 anos ou mais"]

# dois gráficos na mesma linha
par(mfrow = c(1, 2))

qqnorm(adolescente, main = "Mães adolescentes")
qqline(adolescente, col = "red", lwd = 2)

qqnorm(adultas, main = "Mães com 20 anos ou mais")
qqline(adultas, col = "red", lwd = 2)
```



```
par(mfrow = c(1, 1)) # volta a um gráfico por vez
```

Nos dois grupos o padrão se repete: o miolo dos pontos acompanha bem a linha, mas a **ponta de baixo despenca**. Aquela curva para fora, no canto inferior esquerdo, são os bebês prematuros e de muito baixo peso, valores bem mais extremos do que uma distribuição normal produziria. Do lado de cima não há nada equivalente, e é justamente isso que caracteriza uma **assimetria à esquerda**.

Agora o teste, para cada grupo:

```
library(nortest)
```

```
ad.test(adolescente)
```

```
##
## Anderson-Darling normality test
##
## data:  adolescente
## A = 1.7845, p-value = 0.0001425
```

```
ad.test(adultas)
```

```
##
## Anderson-Darling normality test
##
## data:  adultas
## A = 51.681, p-value < 2.2e-16
```

Os dois valores de p são pequenos, confirmando o que o gráfico já mostrava: nenhum dos grupos tem distribuição normal.

Por que olhar o gráfico se o teste já responde? Porque o teste diz apenas *sim* ou *não*, enquanto o gráfico mostra **onde** e **quanto** a distribuição se afasta da normal. Aqui ele revelou que o desvio está em uma cauda só — e é essa informação que vai explicar, daqui a dois passos, por que os dois testes discordam.

Com amostras deste tamanho, o teste t costuma continuar confiável mesmo assim. Mas em vez de confiar em uma regra de bolso, vamos fazer o que resolve a dúvida de vez: **rodar os dois testes e comparar**.

30.5.5 Passo 5: fazer os dois testes

```
t.test(peso_g ~ grupo, data = nascimentos)
```

```
##
## Welch Two Sample t-test
##
## data:  peso_g by grupo
## t = 0.7957, df = 461.9, p-value = 0.4266
## alternative hypothesis: true difference in means between group 20 anos ou mais and group Adolescente is
## 95 percent confidence interval:
## -34.74361  82.02469
## sample estimates:
## mean in group 20 anos ou mais      mean in group Adolescente
##                3098.160                3074.519
wilcox.test(peso_g ~ grupo, data = nascimentos)
```

```
##
## Wilcoxon rank sum test with continuity correction
##
## data:  peso_g by grupo
## W = 624130, p-value = 0.0446
## alternative hypothesis: true location shift is not equal to 0
```

E aqui acontece uma coisa que não estava no roteiro: **os dois testes discordam**. O teste t dá $p = 0,43$, e o de Wilcoxon dá $p = 0,045$.

Isso não é erro de nenhum dos dois. É a coisa mais instrutiva deste capítulo, e vale entender por quê.

30.5.6 Passo 6: por que eles discordam

Os dois testes respondem a perguntas diferentes. O teste t compara **médias**. O de Wilcoxon compara **postos**, ou seja, é sensível a um deslocamento da distribuição como um todo. Quando os dados são simétricos, os dois dão praticamente o mesmo resultado. Quando são assimétricos, podem divergir — e foi o que ocorreu.

Olhe as duas medidas de centro lado a lado:

```
aggregate(peso_g ~ grupo, data = nascimentos,
           FUN = function(x) c(media = round(mean(x), 1),
                                mediana = median(x)))
```

	grupo	peso_g.media	peso_g.mediana
## 1	20 anos ou mais	3098.2	3165.0
## 2	Adolescente	3074.5	3080.0

A diferença entre as **médias** é de 24 gramas. A diferença entre as **medianas** é de 85 gramas, quase quatro vezes maior. Como isso é possível?

```
# proporção de bebês com mais de 4 kg em cada grupo
prop.table(table(nascimentos$grupo, nascimentos$peso_g > 4000), margin = 1)
```

		FALSE	TRUE
##	20 anos ou mais	0.97407407	0.02592593
##	Adolescente	0.95856354	0.04143646

Está aí a explicação: as mães adolescentes têm **proporcionalmente mais bebês acima de 4 quilos** (4,1% contra 2,6%). Esses poucos bebês muito pesados puxam a **média** do grupo para cima e escondem o fato de que o miolo da distribuição está deslocado para baixo. A mediana não se deixa levar por eles, e por isso enxerga a diferença.

A lição: quando a variável é assimétrica, média e mediana contam histórias diferentes, e escolher só uma delas pode mudar a sua conclusão. Rodar os dois testes leva dez segundos e evita esse tipo de armadilha. Se eles concordarem, ótimo. Se discordarem, você acabou de descobrir algo sobre a forma dos seus dados.

30.5.7 Passo 7: então, qual é a conclusão?

Nenhuma das duas, sozinha. É preciso olhar o **tamanho** da diferença, e não só o valor de p .

```
# o Wilcoxon também estima a diferença, não só o valor de p
wilcox.test(peso_g ~ grupo, data = nascimentos, conf.int = TRUE)
```

```
##
## Wilcoxon rank sum test with continuity correction
##
## data: peso_g by grupo
## W = 624130, p-value = 0.0446
## alternative hypothesis: true location shift is not equal to 0
## 95 percent confidence interval:
##  7.264444e-05 1.050001e+02
## sample estimates:
## difference in location
##                54.99998
```

O deslocamento estimado é de **55 gramas**, com intervalo de confiança que vai de **0 a 105 gramas**. Repare que o limite inferior encosta no zero: é por isso que o valor de p ficou em 0,045, logo abaixo do corte, e não muito abaixo dele.

Junte as peças. Há um sinal de que bebês de mães adolescentes são um pouco mais leves, mas ele é **fraco** (p no limite, intervalo encostando no zero) e **pequeno** (55 gramas, quando um recém-nascido pesa em média mais de três quilos). Cinquenta e cinco gramas não mudam a conduta clínica de ninguém.

Como reportar:

O peso ao nascer de filhos de mães adolescentes ($n = 362$; mediana 3.080 g) foi comparado ao de filhos de mães com 20 anos ou mais ($n = 3.240$; mediana 3.165 g). O teste t não indicou diferença entre as médias (3.074 g contra 3.098 g; $p = 0,43$), enquanto o teste de Wilcoxon indicou diferença limítrofe ($p = 0,045$), com deslocamento estimado de 55 g (IC95%: 0 a 105 g). A divergência decorre da assimetria da distribuição: o grupo de adolescentes apresentou maior proporção de recém-nascidos acima de 4.000 g (4,1% contra 2,6%), o que eleva sua média. A magnitude estimada não sugere relevância clínica.

Repare no que essa redação faz: ela relata os **dois** testes, explica a divergência em vez de escondê-la e conclui pelo tamanho do efeito. Escolher só o teste que deu significativo e omitir o outro tem nome — é uma forma de *p-hacking*, e é exatamente o que o registro prévio de estudos, visto no capítulo de ciência aberta, existe para impedir.

30.5.8 Passo 8: a pergunta que os dados respondem com clareza

O resultado acima é honesto, mas é fraco e ambíguo. Ele não encerra o assunto: ele muda a pergunta.

Se a diferença no peso ao nascer é, na melhor das hipóteses, pequena, será que a **assistência recebida durante a gravidez** difere? O banco traz o número de consultas de pré-natal, então dá para verificar.

```
aggregate(consultas_pn ~ grupo, data = nascimentos,
  FUN = function(x) c(n = length(x),
    media = round(mean(x), 1),
    mediana = median(x)))
```

```
##          grupo consultas_pn.n consultas_pn.media consultas_pn.mediana
## 1 20 anos ou mais      3124.0           8.1           8.0
## 2   Adolescente      343.0           7.3           7.0
```

Aqui a variável é uma **contagem**, e fortemente assimétrica, então o teste adequado é o de Wilcoxon:

```
wilcox.test(consultas_pn ~ grupo, data = nascimentos)
```

```
##
```

```
## Wilcoxon rank sum test with continuity correction
##
## data: consultas_pn by grupo
## W = 630694, p-value = 5.33e-08
## alternative hypothesis: true location shift is not equal to 0
```

Agora sim: **p menor que 0,001**. Mães adolescentes fazem menos consultas de pré-natal, com mediana de 7 contra 8.

Como reportar:

Mães adolescentes realizaram menor número de consultas de pré-natal (mediana 7) do que mães com 20 anos ou mais (mediana 8); teste de Wilcoxon, $p < 0,001$.

30.5.9 O que este exemplo ensina

Repare no percurso. Partimos de uma hipótese que parecia evidente e os dados não deram uma resposta limpa: um teste disse que não havia diferença, o outro disse que havia, e no limite. Em vez de escolher o resultado mais conveniente, fomos entender **por que** discordavam — e a explicação (a assimetria da distribuição, com mais bebês acima de 4 kg entre as adolescentes) ensinou mais sobre os dados do que qualquer um dos dois valores de p sozinho.

Aí olhamos o tamanho da diferença, concluímos que 55 gramas não têm relevância clínica, e mudamos a pergunta. E na pergunta seguinte, sobre o acesso ao pré-natal, o dado respondeu com clareza.

São três hábitos que valem para qualquer análise:

- **olhe antes de testar**, porque o boxplot já sugeria que as distribuições eram parecidas;
- **rode os dois testes quando a variável for assimétrica**, porque média e mediana podem discordar;
- **conclua pelo tamanho do efeito**, e não pelo valor de p , porque foi o tamanho que resolveu o impasse.

E tudo isso foi feito com um banco público e gratuito, baixado em minutos, usando só os testes que você aprendeu ao longo do livro.

30.6 Cuidados ao usar dados do DATASUS

São dados secundários. Foram coletados para outra finalidade, a de vigilância em saúde, e não para a sua pergunta. Isso limita o que dá para concluir: você trabalha com as variáveis que existem, não com as que gostaria de ter.

É censo, não amostra. O SINASC registra todos os nascimentos, não uma amostra deles. Isso é uma vantagem, porque dispensa peso amostral, mas muda a interpretação: se você analisa todos os nascimentos de Uberaba em 2022, não está estimando nada — está descrevendo a população inteira daquele ano.

Há subnotificação e erro de preenchimento. A qualidade varia entre municípios e ao longo dos anos. Compare os seus totais com os publicados oficialmente antes de confiar neles.

Não há identificação nominal, mas ainda são dados de saúde. Trate com o mesmo cuidado que trataria uma coleta própria, e verifique junto ao seu orientador se o seu projeto precisa passar pelo Comitê de Ética — o uso de dados públicos anonimizados costuma ser dispensado, mas a decisão não é sua.

Cite a fonte. Uma forma usual é:

BRASIL. Ministério da Saúde. Sistema de Informações sobre Nascidos Vivos (SINASC). Brasília: DATASUS. Disponível em: <https://datasus.saude.gov.br>. Acesso em: [data].

30.7 Ideias para começar

Algumas perguntas que o SINASC responde e que dão bons trabalhos:

- O peso ao nascer difere entre partos vaginais e cesáreos, na sua cidade?
- A proporção de cesáreas mudou ao longo dos últimos dez anos?

- Mães adolescentes fazem menos consultas de pré-natal?
- A prematuridade se distribui igualmente entre os níveis de escolaridade materna?

Todas elas podem ser respondidas com os testes que você aprendeu neste livro — teste t, Wilcoxon, qui-quadrado, correlação e regressão — sobre um banco que você monta em cinco minutos.

Livros e textos gerais

- **Cohen, J. (1988).** Statistical Power Analysis for the Behavioral Sciences (2nd ed.). Lawrence Erlbaum Associates.
- **Field, A. (2013).** Discovering Statistics Using IBM SPSS Statistics (4th ed.). Sage.
- **Larson, R., & Farber, B. (2013).** Estatística Aplicada (5ª ed.). Pearson. (*fonte do exercício do capítulo de Regressão*)
- **Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023).** R para Ciência de Dados (2ª ed.). <https://pt.r4ds.hadley.nz/>

Tamanho do efeito

- **Cliff, N. (1993).** Dominance statistics: Ordinal analyses to answer ordinal questions. *Psychological Bulletin*, 114(3), 494-509. <https://doi.org/10.1037/0033-2909.114.3.494>
- **Cramér, H. (1946).** Mathematical Methods of Statistics. Princeton University Press.
- **Romano, J., Kromrey, J. D., Coraggio, J., & Skowronek, J. (2006).** Appropriate statistics for ordinal level data: Should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys? *Annual Meeting of the Florida Association of Institutional Research*, Jacksonville, FL, USA.

Cálculo amostral e poder em testes não paramétricos

- **Lehmann, E. L. (2006).** Nonparametrics: Statistical Methods Based on Ranks (Revised ed.). Springer.
- **Noether, G. E. (1987).** Sample size determination for some common nonparametric tests. *Journal of the American Statistical Association*, 82(398), 645-647. <https://doi.org/10.1080/01621459.1987.10478478>

Testes de normalidade, assimetria e curtose

- **Anderson, T. W., & Darling, D. A. (1954).** A test of goodness of fit. *Journal of the American Statistical Association*, 49(268), 765-769. <https://doi.org/10.1080/01621459.1954.10501232>
- **Anscombe, F. J., & Glynn, W. J. (1983).** Distribution of the kurtosis statistic b2 for normal samples. *Biometrika*, 70(1), 227-234. <https://doi.org/10.1093/biomet/70.1.227>
- **D'Agostino, R. B. (1970).** Transformation to normality of the null distribution of g1. *Biometrika*, 57(3), 679-681. <https://doi.org/10.1093/biomet/57.3.679>
- **Lilliefors, H. W. (1967).** On the Kolmogorov-Smirnov test for normality with mean and variance unknown. *Journal of the American Statistical Association*, 62(318), 399-402. <https://doi.org/10.1080/01621459.1967.10482916>
- **Shapiro, S. S., & Wilk, M. B. (1965).** An analysis of variance test for normality (complete samples). *Biometrika*, 52(3-4), 591-611. <https://doi.org/10.1093/biomet/52.3-4.591>

Comparação entre grupos e ANOVA

- **Dunn, O. J. (1964).** Multiple comparisons using rank sums. *Technometrics*, 6(3), 241-252. <https://doi.org/10.1080/00401706.1964.10490181>
- **Greenhouse, S. W., & Geisser, S. (1959).** On methods in the analysis of profile data. *Psychometrika*, 24(2), 95-112. <https://doi.org/10.1007/BF02289823>

Gráficos e instrumentos

- **De Rose Jr., D. (1998).** Lista de sintomas de estresse pré-competitivo infanto-juvenil: elaboração e validação de um instrumento. *Revista Paulista de Educação Física*, 12(2), 126-133.
- **Sturges, H. A. (1926).** The choice of a class interval. *Journal of the American Statistical Association*, 21(153), 65-66. <https://doi.org/10.1080/01621459.1926.10502161>

Ciência aberta e dados abertos

- **Saldanha, R., Bastos, R., & Barcellos, C. (2019).** Microdatasus: pacote para download e pré-processamento de microdados do Departamento de Informática do SUS (DATASUS). *Cadernos de Saúde Pública*, 35(9), 1-9. <https://doi.org/10.1590/0102-311x00032419>
- **UNESCO (2021).** Recomendação da UNESCO sobre Ciência Aberta. Paris: UNESCO. <https://www.unesco.org/en/open-science>
- **Wilkinson, M. D., et al. (2016).** The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, 3, 160018. <https://doi.org/10.1038/sdata.2016.18>
- **BRASIL. Ministério da Saúde.** Sistema de Informações sobre Nascidos Vivos (SINASC). Brasília: DATASUS. <https://datasus.saude.gov.br>

Software

- **R Core Team (2025).** R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing, Vienna, Austria. <https://www.R-project.org/>
- **Xie, Y. (2016).** bookdown: Authoring Books and Technical Documents with R Markdown. Chapman and Hall/CRC. <https://bookdown.org/yihui/bookdown/>