Estatística + R

Ana Paula Fernandes

Atualizado em: 22/05/2023

Sumário

1 Bem-vindos! 5

2 Introdução 7

2.1 Atividade 8

3 Definições iniciais 9

4 Tamanho da amostra 11

4.1 Atividade 11

5 Ambiente computacional 13

5.1 Plano A: Instalação R e RStudio 14

5.2 Plano B: R e RStudio online 14

6 Trabalhando no RStudio 19

7 Primeiros exercícios no R 23

7.1 Exemplo 1 23

7.2 Exemplo 2 24

7.3 Exemplo 3 24

8 Tipos de variáveis 27

8.1 Atividade 27

9 Estatística descritiva 29

9.1 Medidas de tendência central (ou posição) 29

9.2 Medidas de dispersão (ou variabilidade) 29

9.3 Medida relativa de variabilidade 29

9.4 Funções do R 29

10 Importando banco de dados **31**

10.1 Importando um banco csv 31

10.2 Importando um banco xls 33

10.3 Exemplo 1 34

10.4 Exemplo 2 34

10.5 Exemplo 3 34

11 Instalando pacotes **35**

11.1 Exemplo 1 36

11.2 Exemplo 2 36

11.3 Exemplo 3 36

11.4 Exemplo 4 37

11.5 Atividade 37

Capítulo 1

Bem-vindos!

Esse livro *online* tem como propósito principal ser um guia para as aulas de estatística, referente as disciplinas de **Bioestatística** para os curso de Medicina e Educação Física e **Estatística Aplicada** para o curso de Psicologia da Universidade Federal do Triângulo Mineiro (UFTM) http://www.uftm.edu.br. E como objetivo secundário, ser uma referência de consulta para todos os discentes que passaram por essas disciplinas, bem como, para todos que estão interessados em realizar análises de dados por meio da linguagem R e o ambiente de desenvolvimento RStudio.

Sugestões, correções ou qualquer outra forma de interação são sempre bem-vindas! Então, por favor, não hesite em me escrever anapaula.fernandes@uftm.edu.br.

E vamos lá!

Capítulo 2

Introdução

Ao longo de algum tempo ministrando aulas de estatísticas conclui que estudar estatística com auxílio de recursos computacionais é bem mais eficaz, quero dizer, é mais fácil entender os conceitos téoricos, lidar com recusos visuais (gráficos) e, de fato, transformar o contéudo estudado na disciplina em uma ferramenta para pesquisas científicas, quando se trata de analisar dados.

Ministrando aulas para os cursos da área de saúde, esporte e psicologia sempre ouvi dos discentes que estatística é matemática, e sempre digo que estatística é estatística! É normal alguns discentes não assimilarem, em princípio, a importância da disciplina na grade do seu curso, e realmente, alguns acham até que é assunto que deveria ficar restrito aos curso das exatas. Assim, a primeira tarefa é sempre desconstruir essa ideia.

A estatística é **MULTIDICIPLINAR**, ela está em tudo na verdade... e para dizer uma coisa "bem chique" a estatística é a base da Inteligência Artificial. Advinha quem está por trás dos famosos algortimos das redes sociais? Ou das sugestões de filmes que aparecem no seu *streamming* favorito? Ou no ranque de busca realzada no *Google*? Ou no *Chat* GTP?

E sendo um pouco mais "acadêmica", dentro do nosso propósito:

Qualquer competição ou treinamento esportivo está recheado de estatística, como medir o desempenho de um time ou atleta? Veja esse exemplo aqui:

> **Velocidade e resistência de velocidade de sprint em atletas de Futebol amador** http://www.rbff.com.br/index.php/rbff/article/view/866

Na medicina, estudos epidemiologicos, e claro, da medicina baseada em evidências, tem o suporte da estatística. Veja esse exemplo aqui:

> **Qualidade de Vida Relacionada à Saúde e Satisfação com o Tratamento Hospitalar de Adultos com Câncer: Estudo Observacional** https://rbc.inca.gov.br/index.php/revista/article/view/3554

Na psicologia a estatística é a ferramenta utilizada na psicometria. Veja esse exemplo:

> **Escala de Comportamentos Antissociais: construção e estudos psicométricos** https://periodicos.pucpr.br/psicologiaargumento/article/view/27071

Basta realizar uma busca com os termos estatística e um campo do seu curso que você se interessa, que você encontrará um artigo científico. E se você não encontrar, comece a escreve sobre o tema!

Quando olhamos os artigos acima, podemos ver que todos eles tem resultados **descritivos** e **inferenciais**.

2.1 Atividade

3. Busque um artigo do campo de seu interesse que utiliza a estatística.

- Qual é o principal objetivo da pesquisa?
- Como a pesquisa foi realizada?
- Observe o que é descrito por meio de tabelas ou gráficos.
- Faça uma lista de termos que são relacionados à estatística.

Periódicos da área da Ciência dos Esportes

- RBFF - Revista Brasileira de Futsal e Futebol http://www.rbff.com.br
- RBME - Revista Brasileira de Medicina do Esporte https://www.scielo.br/j/rbme
- RBPE - Revista Brasileira de Psicologia do Esporte http://pepsic.bvsalud.org

Periódicos da área de Medicina

- RBC - Revista Brasileira de Cancerologia https://rbc.inca.gov.br/index.php/revista
- RBCMS - Revista Brasileira de Ciências Médicas e da Saúde http://www.rbcms.com.br
- Revista da Associação Brasileira de Saúde Coletiva https://cienciaesaudecoletiva.com.br

Periódicos da área de Piscologia

- Psicologia argumento https://periodicos.pucpr.br/psicologiaargumento
- Estudos de psicologia (Campinas) https://www.scielo.br/j/estpsi/
- Psicologia em foco https://revistas.fw.uri.br/index.php/psicologiaemfoco

Ou busque na ferramenta Mendeley <www.mendeley.com>

Capítulo 3

Definições iniciais

A estatística é divida em duas partes

- Estatística **DESCRITIVA**: é o ramo da estatística que envolve a organização, o resumo e a representação dos dados.
- Estatística **INFERENCIAL**: é o ramo da estatística que envolve o uso de uma amostra para chegar a conclusões sobre uma população.

Essas duas partes são conectadas pela téoria de probabilidade, especificamente pelas distribuições de probabilidade.

População x Amostra

- **POPULAÇÃO**: é a coleção de todos os resultados, respostas, medições ou contagens que são de interesse.
- **AMOSTRA**: é um subconjunto ou parte de uma população.

Capítulo 4

Tamanho da amostra

O cálculo do tamanho da amostra é um procedimento simples, porém ele depende de vários conceitos da parte da estatística inferencial, e também dos objetivos das análises que serão feitas na pesquisa.

Existem várias calculadoras de tamanho de amostra, basta procurar no *Google* por calculadora amostral, ou em inglês, por *sample size calculator*.

Um ótimo exemplo de calculadora amostral *online*: http://estatistica.bauru.usp.br/calculoamostral/, essa calculadora foi desenvolvida pelo pessoal da Faculdade de Odontologia da USP - Bauru, na opção cálculos podemos ver que essa ferramenta disponibiliza 15 opções de cálculo amostral! Então, já podemos perceber que:

> A estimativa do tamanho de amostra adequado para uma pesquisa depende do objetivo da pesquisa!

O **G*Power **é um *software* gratuito, desenvolvido pela Universidade de Düsseldorf, onde podemos claramente verificar que o tamanho da amostra depende principalmente dos objetivos da pesquisa, quais análises inferenciais serão feitas, isto é, quais testes estatísticos (testes de hipóteses) serão realizados. Veremos o conceito de** Poder do Teste**, por isso o *software* leva esse nome.

Além disso, como nosso objetivo é usar o R, uma boa referência de cálculo amostral no R é o seguinte documento produzido por pesquisadores da DaCCoTA (Univesidade da Dakota do Norte) https://med.und.edu/research/daccota/_files/pdfs/berdc_resource_pdfs/sample_size_r_module.pdf

4.1 Atividade

2. Responda a partir do artigo buscado na atividade 1.

- O autores mencionaram sobre o cálculo do tamanho da amostra?
- A população da pesquisa foi bem delineada (bem definida)?
- Os autores mencionaram se a pesquisa foi submetida ao Comitê de Ética.
- Qual a importância de submeter a pesquisa ao Comitê de Ética?

Importante

> Conheça o Comitê de Ética em Pesquisa (CEP) da UFTM

https://www.uftm.edu.br/comitesecomissoes/cep

Capítulo 5

Ambiente computacional

Existem vários softwares que são dedicados a análise estatística que vão do maravilhoso SPSS (da IMB) às planilhas eletrônicas (como o Excel). Para citar alguns algumas dessas ferramentas:

Softwares pagos

- SPSS https://www.ibm.com/br-pt/spss
- Stata https://www.stata-brasil.com/software/stata.html
- SAS https://www.sas.com/pt_br
- JMP https://www.jmp.com/
- Prisma https://software.com.br/p/prism
- Minitab https://osbsoftware.com.br/produto/minitab-statistical-software
- Excel (Microsoft)

Softwares livre

- Jamovi https://www.jamovi.org
- OpenStat https://openstat.info

Liguagens computacionais

- R https://www.r-project.org
- Python https://www.python.org/

Concentraremos nossas forças na utlização do R, que é uma linguagem computacional que foi desenvolvida especificamente para análise estatística. Saiba um pouco mais: https://www.cienciaedados.com/por-que-escolher-r/

Assim, vamos preparar o ambiente computacional para realizarmos nossas análises.

E para ficar claro:

- **R é uma linguagem computacional** (não se preocupe, não vamos programar!)
- **RStudio é um software** onde executaremos códigos R, é o pessoal da computação denomina de ambiente de desenvolvimento (IDE).[1]

[1] Integrated Development Environment - Ambiente de Desenvolvimento Integrado

5.1 Plano A: Instalação R e RStudio

No laboratório de informática da UFTM o R e a IDE RStudio estão instaladas nos computadores que utilizamos nas nossas aulas práticas, no entanto, nem sempre há tempo de desenvolver todas as atividades em sala de aula, assim, fica a sugestão para que o estudante faça a instação do R e da IDE RStudio em seus computadores.

O RStudio é propriedade da empresa Posit (desde outubro de 2022), em seu site são dadas as instruções:

1. Instale o R https://cran.rstudio.com
2. Instale o RStudio Desktop https://posit.co/download/rstudio-desktop

   Ou, veja diretamente no site https://posit.co/download/rstudio-desktop

É importante baixar e instalar as versões do R e RStudio que sejam compatíveis com seu computador.

Essa etapa de preparação do ambiente computacional é de suma importância para o andamento da disciplina, para que as atividades sejam executadas, mas pode ser que você enfrente algum tipo dificuldade na instalação, então faça o quanto antes!

Se der tudo certo, ao clicar no ícone do RStudio, uma tela parecida como será apresentada:

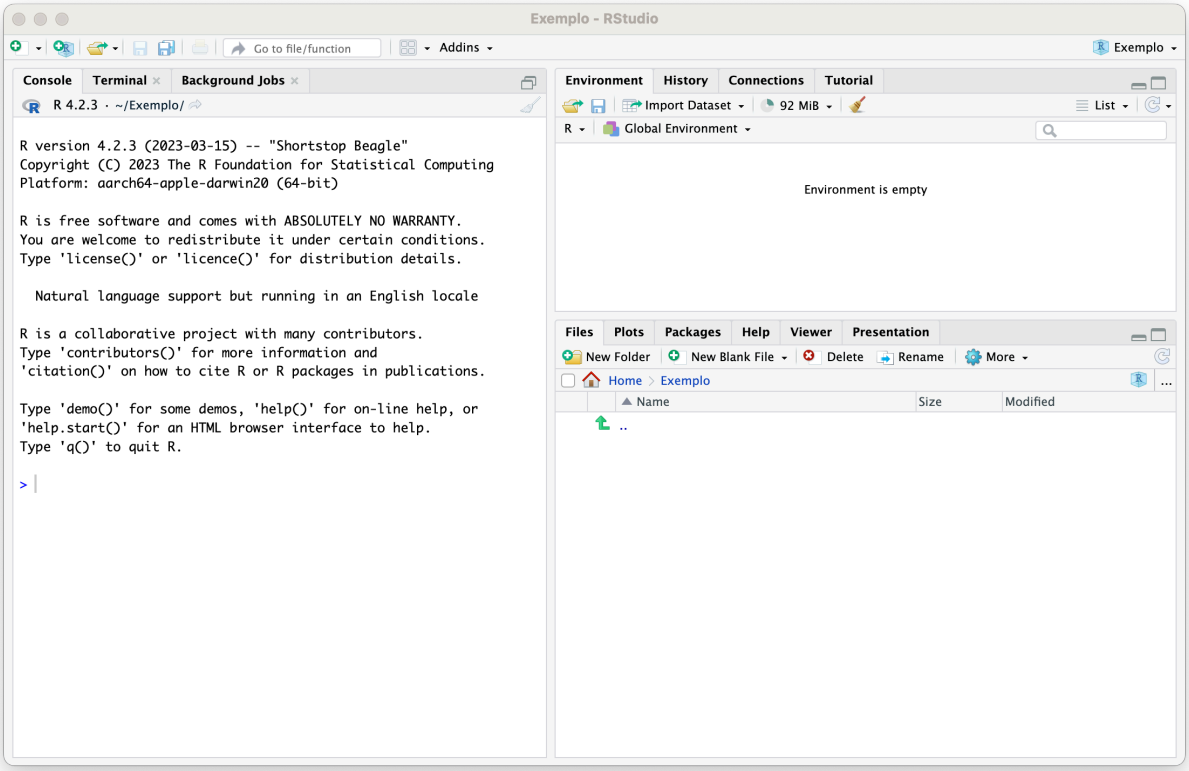

Figura 5.1: Figura: Tela inicial do RStudio

Se nada der certo, temos o plano B.

5.2 Plano B: R e RStudio online

O plano B é tão bom, tão bom que poderia ser considerado plano A, no entanto, é preciso estar conectado à Intenet, o RStudo será excutado online na nuvem da Posit.

Se você tem uma boa conexão de Internet, fica a sugestão para usar o plano B.

1. Acesse https://posit.cloud
2. Faça o login (eu acesso com meu usuário do Google)
3. A seguinte tela será apresentada

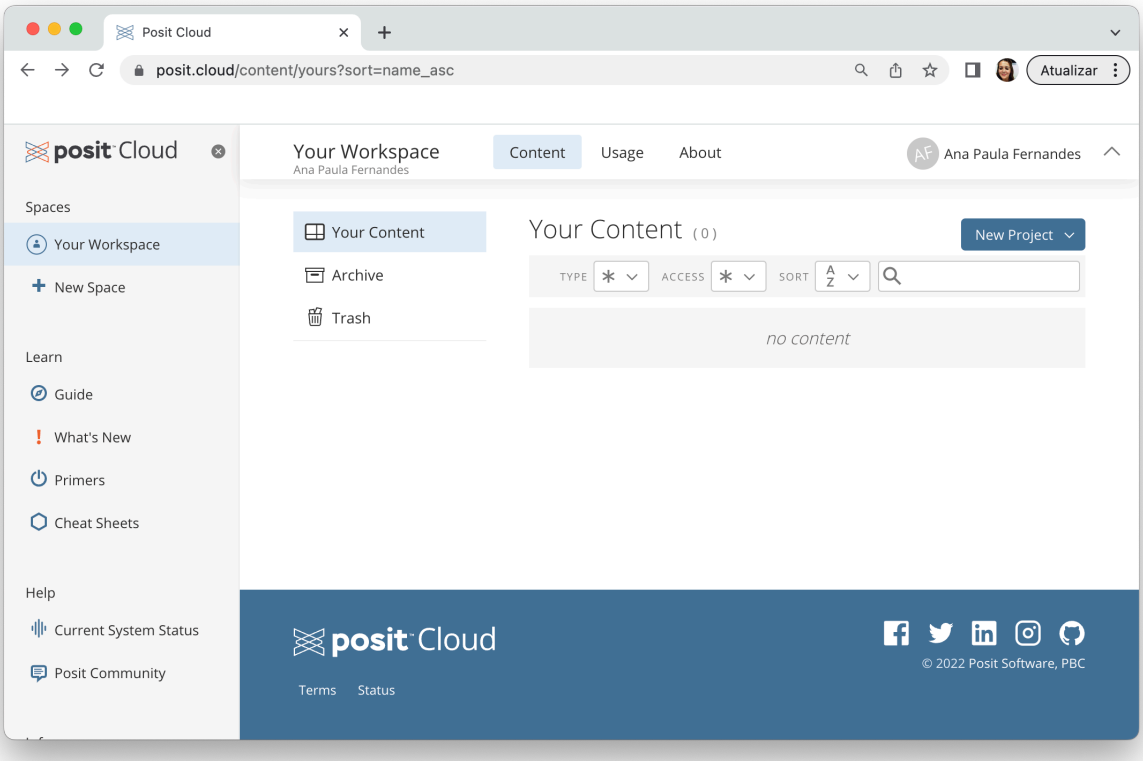

Figura 5.2: Tela inicial na nuvem da Posit

4. Crie um projeto RStudio, selecionando a opção New Project, e em seguida, escolhendo New RStudio Project.

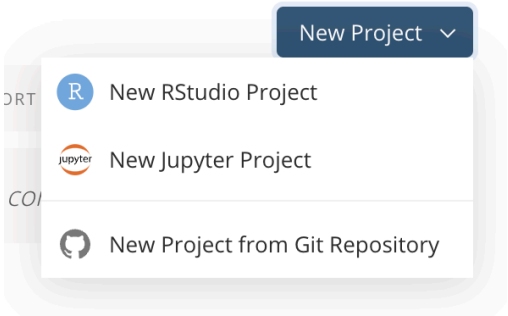

Figura 5.3: Botão de criação de um novo projeto

Se deu tudo certo, você verá a seguinte tela:

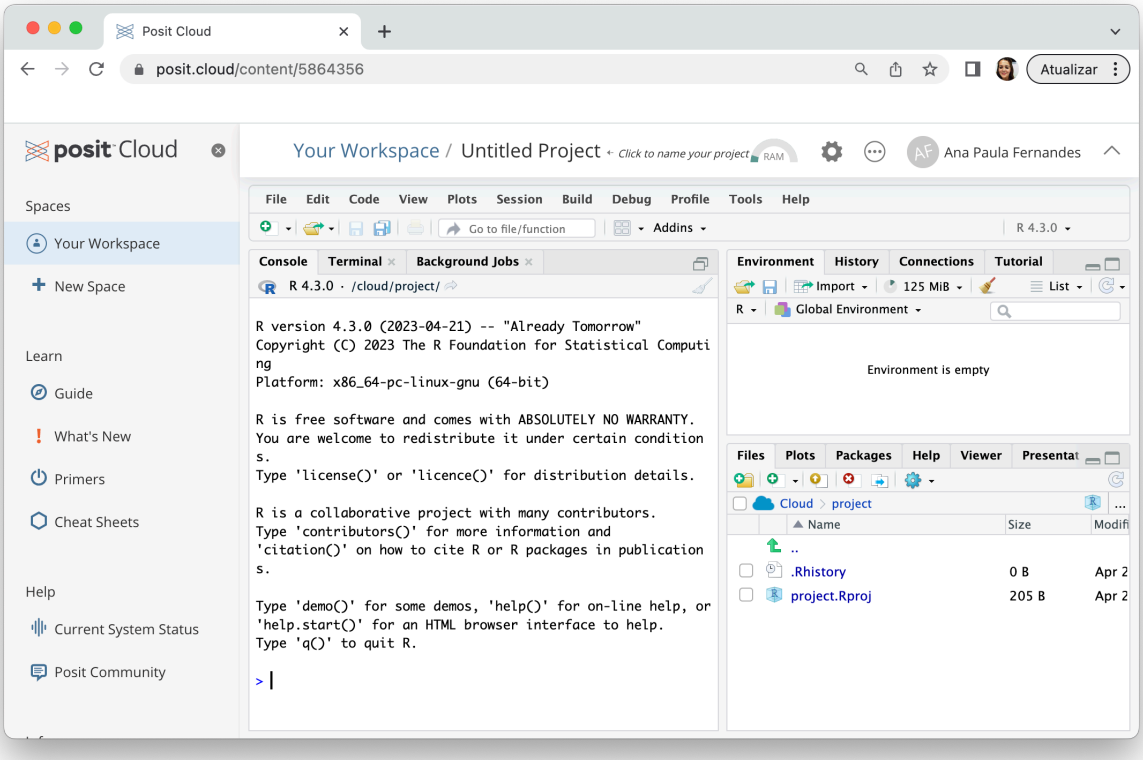

Figura 5.4: Tela inicial do RStudio online na nuvem da Posit

O melhor de usar a nuvem da Posit é que tudo armazenado por lá, isso quer dizer que suas análises ficam gravadas em um lugar seguro.

Capítulo 6

Trabalhando no RStudio

Seja na versão instalada no seu computador (plano A) ou na nuvem (plano B), conheça melhor as áreas do RStudio:

1. **Console:** local onde serão apresentadas as respostas para códigos execudados;
2. **Ambiente de memória (Environment):** é o cerébro do R, onde ficam registrados os objetos que ele reconhece.
3. A área de **Arquivos (Files), Gráficos (Plots), Pacotes (Packages), Ajuda (Help), Visualização (Viewer) e Apresentação (Presentation)**: mostram respectivamente, os arquivos do diretório onde estão seus arquivos no computador, os gráficos, os pacotes, ajuda, janela de visualização e apresentação.

A figura abaixo identifica cada uma dessas áreas:

Digitaremos os códigos da linguagem R, em um arquivo que chamamos de **script**, para abrir um arquivo do tipo script R, faça:

1. Acesse a opção **File** no menu principal do RStudio;
2. Escolha a opção **New File**
3. E depois a opção **R Script**

Assim, na tela da IDE RStudio aparecerá uma nova área, que é a área do arquivo script, como mostra a figura.

Observe que o arquivo está sem um nome **Untitled1** (sem titulo), salve o arquivo atribuindo-o um nome adequado. Para isso, no menu principal, escolha *File*, depois *Save*.

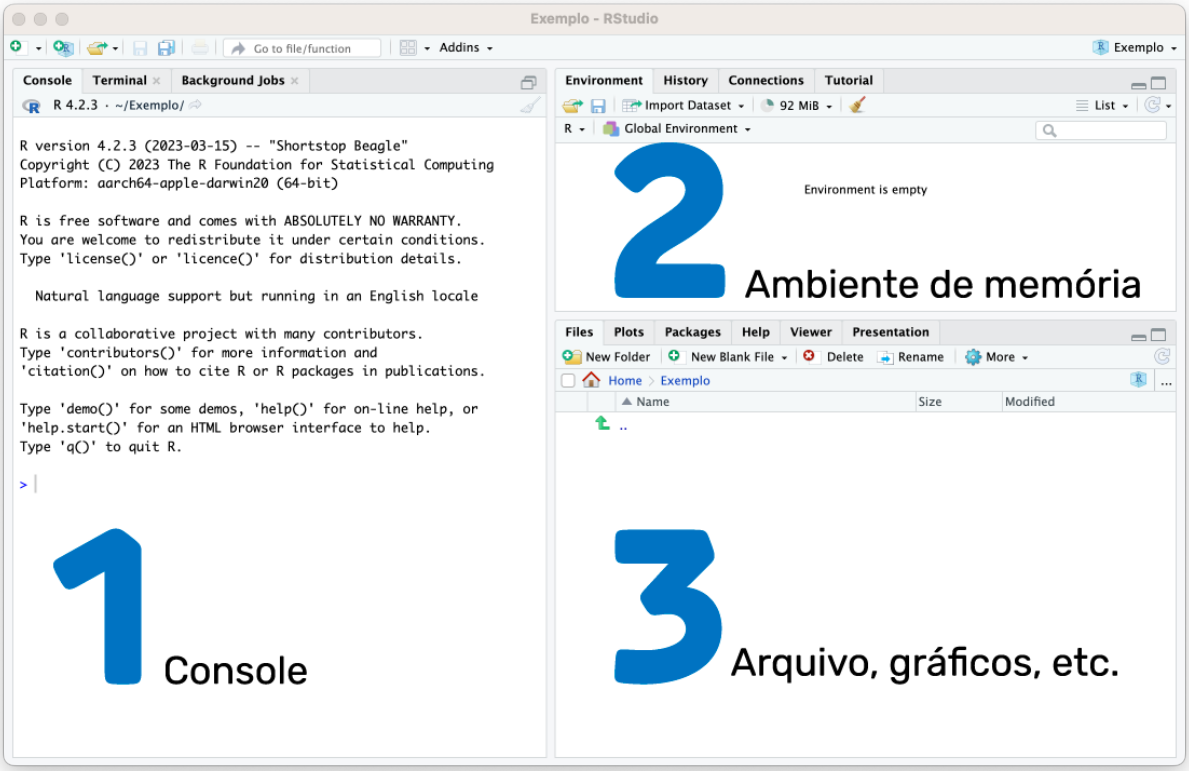

Figura 6.1: Figura: Identificação das áreas do RStudio

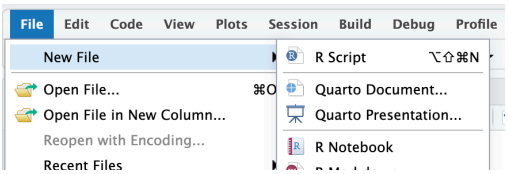

Figura 6.2: Figura: Como abrir um novo arquivo de script R

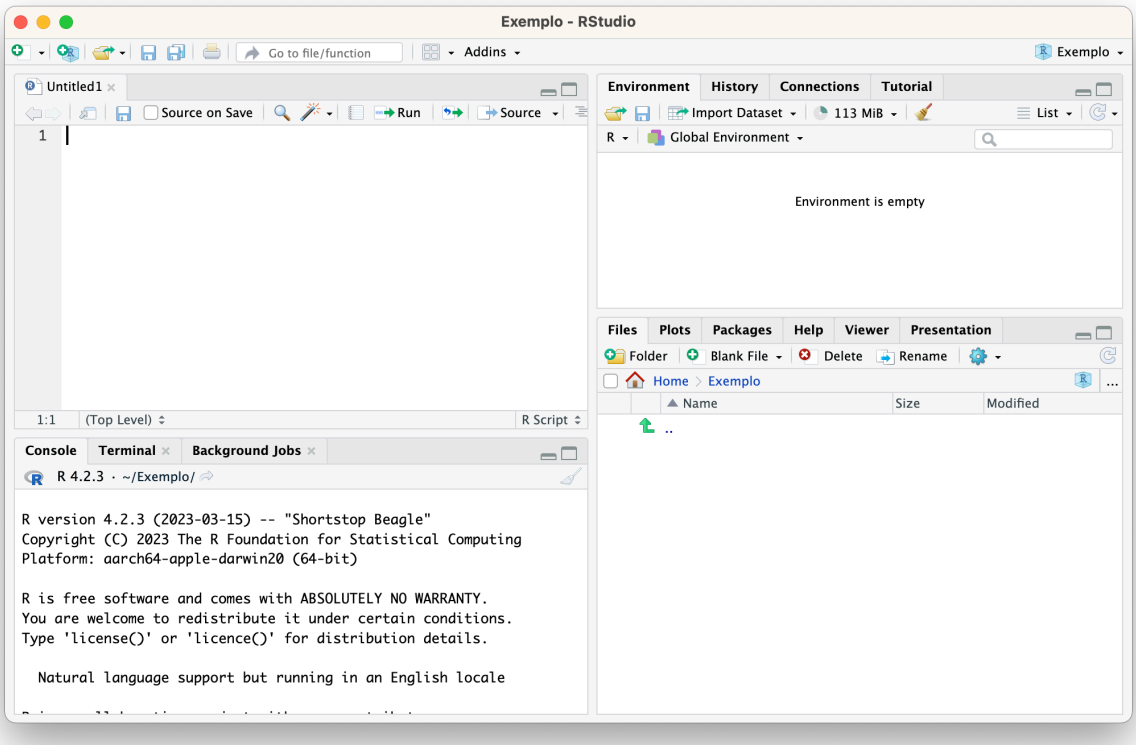

Figura 6.3: Figura: Como abrir um novo arquivo de script R

Capítulo 7

Primeiros exercícios no R

Nos capítulos 5 e 6 vimos sobre o ambiente computacional (computador ou nuvem) e identificamos as 4 áreas da tela da interface do RStudio: **console**, **ambiente de memória**, **arquivos, gráficos, etc.** e **script**, assim estamos prontos para escrever alguns códigos e executá-los a partir da área de script.

> **Atenção:** TODOS os cógigos serão digitados no arquivo de script, seguindo uma sequência lógica de passos, ou seja, escreveremos um roteiro (*script*), como se fosse uma receita de bolo, isso é o que o pessoal da computação chama de algoritmo.

7.1 Exemplo 1

- Observe o código escrito na linha 1 do arquivo de script e o botão **Run** (primeira seta verde):

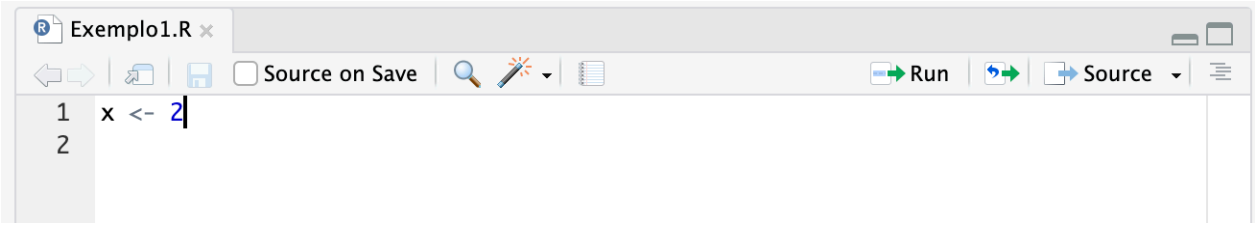

Figura 7.1: Figura: Primeiro exemplo de cógigo R

- O sequência de caracteres **<-** é o símbolo de atribuição no R.

  Pressionando as teclas ALT e - (menos) simultaneamente cria no script o sinal de atribuição.

- O código significa que criamos um objeto chamado **x** e atribuimos a esse objeto o valor 2.
- No entanto, o R ainda não sabe que o valor de x é igual a 2!
- Para registrar essa informação na memória do R, devemos executar essa linha.

  Para executar uma linha posicione o cursor na linha, e clique no botão **Run**

  Observe sempre o ambiente de memória (bem como o console) quando executar uma linha.

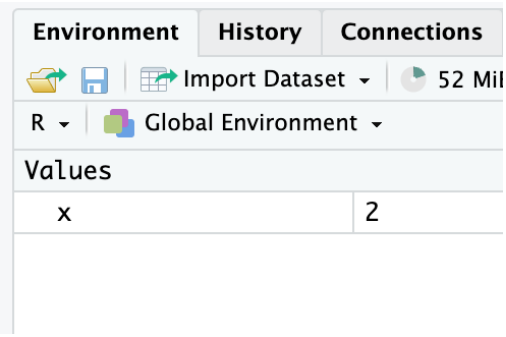

Figura 7.2: Figura: O objeto x é registrado na memória do R, armazenando o valor igual a 2

7.2 Exemplo 2

Execute o seguinte cógigo no R.

```
idades <- c( 23, 18, 17, 25, 21, 19, 22, 24, 19, 19 )
```

- Esse código significa que foi criado um objeto chamado idade que armazena 10 valores: 23, 18, 17, 25, 21, 19, 22, 24, 19, 19, diferentemente do exemplo 1 em que x armazenava somente o valor 2.
- Isso foi possível pois usamos a função **c( )**.
- observe que os valores foram colocado dentro dos parênteses da função **c( )**

  Com função **c( )** podemos **combinar** vários valores em um objeto, esse objeto recebe o nome de vetor ou lista.

7.3 Exemplo 3

Observe nesse código as funções:

- **max( )**
- **min( )**
- **range( )**
- **mean( )**
- **sd( )**

```
# criando o vetor idades
idades <- c( 23, 18, 17, 25, 21, 19, 22, 24, 19, 19 )

# maior valor
# função max( )
max(idades)

# menor valor
# função min( )
min(idades)
```

```
# faixa de valores
# função range( )
range(idades)

# média (mean)
# função mean( )
mean(idades)

# desvio padrão (standard deviation)
# função sd()
sd(idades)
```

Copie o código e cole no seu arquivo script, selecione todo conteúdo (CRTL+A) e execute todo o cógigo de uma única vez.

- Observe que as respostas apareceram no **console**, conforme mostrado na figura abaixo:

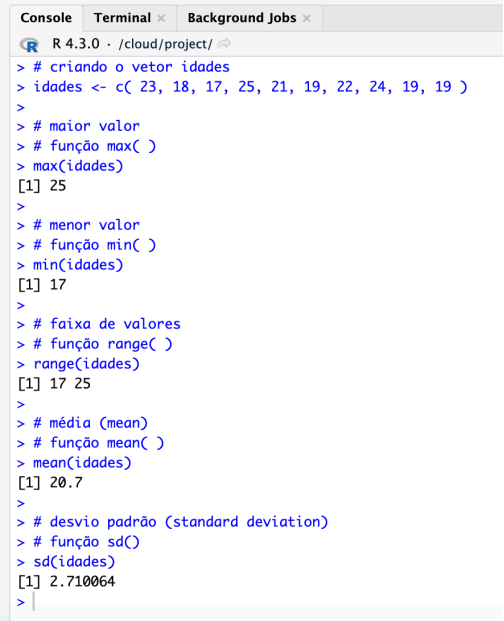

Figura 7.3: Figura: Como abrir um novo arquivo de script R

O símbolo # é o símbolo de comentário, isso significa que podemos escrever qualquer texto diferente do que o R sabe interpretar, e mesmo executando o código nenhum erro acontece!

IMPORTANTE: é uma boa prática comentar os trechos de códigos para deixar documentado qual é o objetivo do código.

Capítulo 8

Tipos de variáveis

A natureza das variáveis (ou dados) são

- **Quantitativa** - expressa quantidade
  - Discreta - assume valores inteiros (contagem)
  - Contínua - assume qualquer valor de um dado intervalo (mensuração)
- **Qualitativa** - expressa qualidade (categorias, rótulos)
  - Nominal - categorias que não podem ser ordenadas
  - Ordinal - categorias que podem ser ordenadas, existe uma graduação entre as categorias.

(vou acrescentar referências!)

O procedimento estatístico que iremos realizar depende da natureza da variável que estamos analizado, por exemplo:

- Na estatística descritiva:
  - as variáveis qualitativas são representadas por sua frequência absoluta ou percentual;
  - as variáveis quantitativas são representadas por medidas resumo, como por exemplo, média e desvio padrão.
- Na estatística inferencial:
  - O teste Qui-quadrado é o teste de hipótese que tem como objetivo verificar se existe ou não associação entre as categorias de duas variáveis, como estamos falando de categorias, esse teste é aplicado a variáveis de natureza qualitativa.
  - O teste de correlação de Pearson, mede a força da correlação linear entre duas variáveis, é aplicado à variáveis quantitativas.

8.1 Atividade

1. Veja o artigo *Estado nutricional, tempo de internação e mortalidade em pacientes submetidos à cirurgia cardíaca em um hospital na cidade de Maceió* https://www.rasbran.com.br/rasbran/article/view/1724/443 publicado na RASBRAN, Revista da Associação Brasileira de Nutrição em 2023 (https://www.rasbran.com.br/).

- A **Tabela 1 - Características clínicas dos pacientes submetidos à cirurgia cardíaca**, é uma tabela descritiva da amostra que foi analisada na pesquisa. Classique as variáveis (características) em qualitativa e quantitativa e observe atentamente como elas foram resumidas.

- A **Tabela 2 - Associação entre estado nutricional, sexo, idade e tempo de internação hospitalar entre os pacientes submetidos à cirurgia cardíaca** e **Tabela 3 - Associação entre evolução clínica, sexo, idade, tempo de internação hospitalar e estado nutricional entre os pacientes submetidos à cirurgia cardíaca** são tabelas que mostram o resultado de um teste de hipótese (estatística inferencial). Qual teste foi aplicado? Qual o objetivo deste teste?

Capítulo 9

Estatística descritiva

Medidas resumo

9.1 Medidas de tendência central (ou posição)

- Média
- Mediana e quartis
- Moda

9.2 Medidas de dispersão (ou variabilidade)

- Aplitude (maior - menor)
- Variância
- Desvio padrão
- Distância interquartil

9.3 Medida relativa de variabilidade

- Coeficiente de variação - quociente DP/media

9.4 Funções do R

Supondo que o objeto **x <- c(valor 1, valor 2, . . . , valor n)** está na memória do R.

Medida resumo	Função básica do R
média	mean(x)
mediana	median(x)
primeiro quartil	quantile(x,0.25)
terceiro quartil	quantile(x,0.75)
moda	table(x)
menor valor	min(x)

Medida resumo	Função básica do R
maior valor	max(x)
amplitude	range(x)
variância	var(x)
desvio padrão	sd(x)
amplitude interquartil	IQR(x)
coeficiente de variação	sd(x)/mean(x)

- *use sort(table(x)), use a função sort() para ordenar as ocorrências da menor para a maior, a maior ocorrência é a moda!
- use a função **summary(x)** para obter, menor valor, média, mediana, primeiro e terceiro quartil e maior valor.
- Calcular é fácil, o **importante é interpretar** as medidas resumo!

Capítulo 10

Importando banco de dados

Na prática, os dados que vamos analisar estarão armazenado em um **banco de dados**, um arquivo de banco de dados pode ser de diferentes tipos, por exemplo:

- Arquivo do tipo Excel (xls ou xlsx)
- Arquivo de texto separado por vírgulas (csv - *comma-separated values*)

  Existem várias fontes de dados abertas, onde podemos baixar um banco de dados para realizar analises estatísticas, aqui estão algumas delas:

- DataSus: https://datasus.saude.gov.br/transferencia-de-arquivos
- OMS: https://www.who.int/data/collections
- Kaggle: https://www.kaggle.com/datasets

  No link (google drive) existem alguns bancos que podemos usar para compreender como importar um banco de dados para o ambiente do RStudio: https://drive.google.com/drive/folders/1gyORbBEuKBstfSKULA58TLhawOXaY-st

10.1 Importando um banco csv

1. Faça *download* do banco de dados **mcdonald.csv** (fonte original: https://www.kaggle.com/datasets/mcdonalds/nutrition-facts)
2. Na área de ambinete de memória, localize **Import Dataset**, ao clicar nessa opção você terá o seguinte:

- Como queremos importar um arquivo csv, a melhor opção é a segunda **From Text (readr)**
- ***readr*** é uma pacote do R que faz a leitura de arquivo csv (se o pacote ainda não estiver instalado no seu computador, o R fará a instalação, se você concordar!)

3. Clicando na opção **From Text (readr)**, no botão **browser** indidique onde (no seu computador) está localizado o arquivo a ser importado. A seguinte tela será apresentada:

- No quadro **Data Preview**, temos uma "prévia" com os nomes da variáveis, seus tipos computacionais e os primeiros valores que estão armazenados no banco de dados.

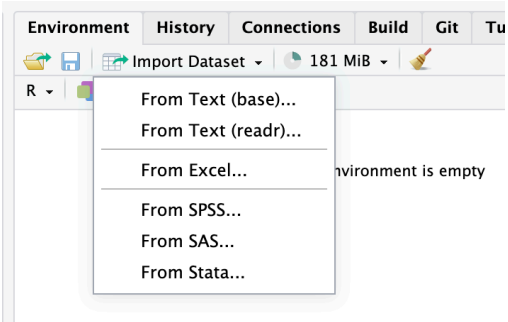

Figura 10.1: Figura: Importando banco de dados

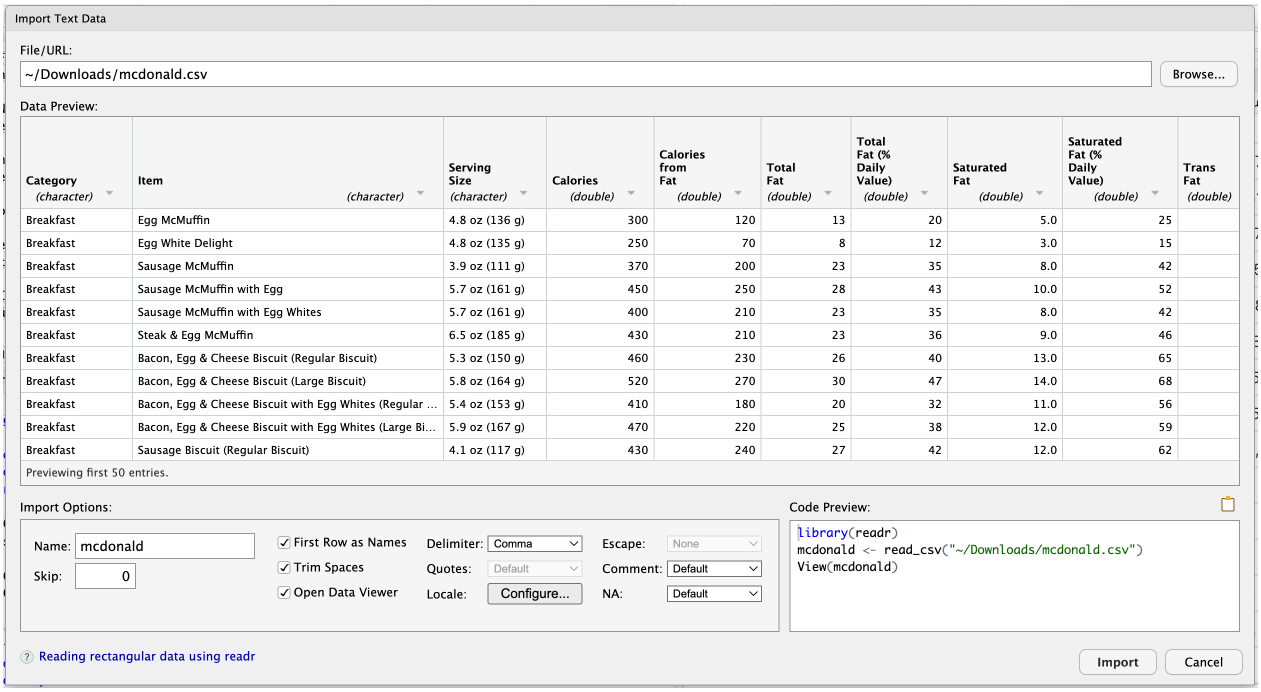

Category (character)	Item (character)	Serving Size (character)	Calories (double)	Calories from Fat (double)	Total Fat (double)	Total Fat (% Daily Value) (double)	Saturated Fat (double)	Saturated Fat (% Daily Value) (double)	Trans Fat (double)
Breakfast	Egg McMuffin	4.8 oz (136 g)	300	120	13	20	5.0	25	
Breakfast	Egg White Delight	4.8 oz (135 g)	250	70	8	12	3.0	15	
Breakfast	Sausage McMuffin	3.9 oz (111 g)	370	200	23	35	8.0	42	
Breakfast	Sausage McMuffin with Egg	5.7 oz (161 g)	450	250	28	43	10.0	52	
Breakfast	Sausage McMuffin with Egg Whites	5.7 oz (161 g)	400	210	23	35	8.0	42	
Breakfast	Steak & Egg McMuffin	6.5 oz (185 g)	430	210	23	36	9.0	46	
Breakfast	Bacon, Egg & Cheese Biscuit (Regular Biscuit)	5.3 oz (150 g)	460	230	26	40	13.0	65	
Breakfast	Bacon, Egg & Cheese Biscuit (Large Biscuit)	5.8 oz (164 g)	520	270	30	47	14.0	68	
Breakfast	Bacon, Egg & Cheese Biscuit with Egg Whites (Regular ...	5.4 oz (153 g)	410	180	20	32	11.0	56	
Breakfast	Bacon, Egg & Cheese Biscuit with Egg Whites (Large Bi...	5.9 oz (167 g)	470	220	25	38	12.0	59	
Breakfast	Sausage Biscuit (Regular Biscuit)	4.1 oz (117 g)	430	240	27	42	12.0	62	

Figura 10.2: Figura: Prévia dos dados

- No quadro **Import Options** temos as opções de importação, fique atento ao **Name** do seu banco de dados, geralmente usamos nomes sem espaços ou caracteres especiais (', ~ ou ç), é até permitido usar alguns desses caracteres especiais, mas evite.
- Ainda no quadro **Import Options**, observe que a opção **Open Data Viewer** está marcada, isso significa que ao importar o banco de dados, o arquivo de banco de dados será aberto pelo RStudio. Caso esteja trabalhando com bancos com muitos dados (como os bancos do dataSUS), talvez seja melhor desmarcar essa opção para não sobrecarregar o processamento do seu computador.
- O quadro **Code Preview** mostra como é a importação (leitura) do banco de dados via código. É interessante copiar esse trecho de código para o arquivo de script.

4. Clique no botão **Import** e observe que no ambiente de memória será criado o objeto do tipo **Data** com o nome do banco de dados que foi importado.

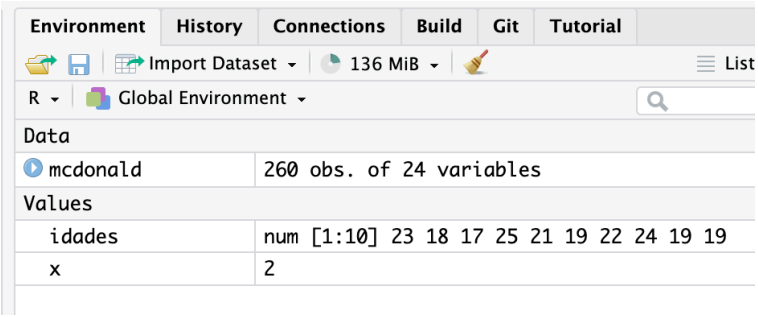

Figura 10.3: Figura: Import dataset

- Observe que esse objeto do tipo **Data** é diferente dos objetos do tipo **Values** que vimos nos exemplos iniciais.
- Ao clicar no ícone ao lado do nome do objeto, temos acesso ao nomes e tipos computacionais das variáveis, e ao clicar sobre nome do objeto, o banco será aberto!

10.2 Importando um banco xls

Na área de ambiente de memória, localize **Import Dataset**, ao clicar sobre essa opção, escolha **From Excel...**

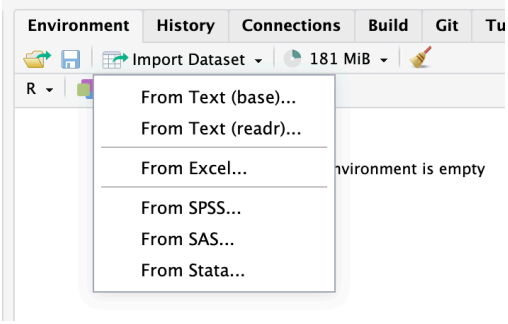

Figura 10.4: Figura: Importando banco de dados

- Se for a primeira vez que você estiver importando um arquivo Excel, pode ser necessária a instalação do pacote que fornece a biblioteca que tem a função de leitura de arquivo xls (**readxl**)! O RStudio mostrará um aviso parecido com este:

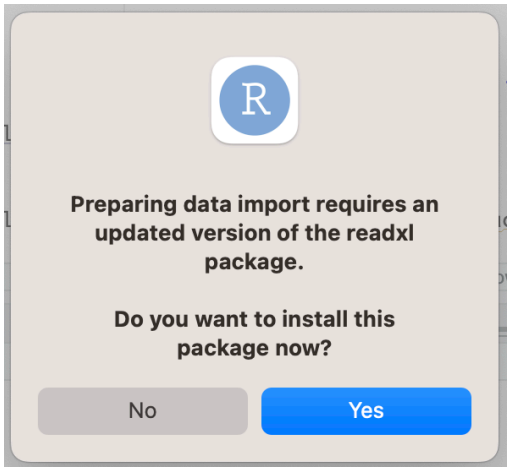

Figura 10.5: Figura: Aviso para instalação de pacote

10.3 Exemplo 1

Como obter a média da variável **Calories** que é uma coluna do objeto **mcdonald**, que por sua vez, é um objeto do tipo **Data**?

```
# Usamos o operador $
# Para calcular a média precisamos informar para função:
# mean( NOME DO BANCO $ NOME DA COLUNA ):
mean(mcdonald$Calories)
```

10.4 Exemplo 2

Como armazenar os valores de uma variável (coluna), em um objeto do tipo **Values** e depois calcular a média?

```
# Uso o operador <-
# Criamos o objeto
caloria <- mcdonald$Calories
# Agora podemos usar o objeto que criamos, por exemplo para calcular a média e o desvio padrão
mean(caloria)
sd(caloria)
```

10.5 Exemplo 3

O que acontece se usamos a função **summary()** para o objeto **mcdonald**, sem usar o operador, isto é sem indicar uma variável?

```
# No console será mostrado o resumo de todas as variáveis do banco!
summary(mcdonald)
```

> Essa forma de obter os resultados não é a melhor forma, vamos **instalar um pacote** para obter os resultados em uma tabela bem formatada que podemos copiar e colar diretamente para um editor de texto.

Capítulo 11

Instalando pacotes

Quando instalamos nosso ambiente computacional R e RStudio, instalamos uma versão básica, onde apenas os recursos básicos do R estão diponíveis, o pacote básico (**base**) do R.

Os pacotes (**packages**) do R são compostos por uma biblioteca (**library**) que é um conjunto de funções. Por exemplo, do pacote **base** usamos as funções min(), max(), mean(), median(), table(), var(), sd(), summary(), etc.

Para ver a lista de funções que compõem a bilbioteca do pacote base, execute o código:

```
library(help = "base")
```

Os pacotes são análogos aos aplicativos que instalamos nos nossos celulares, são módulos que agregam funcionalidades específicas. Ao longo das nossas atividades usaremos alguns desses pacotes.

Como nesse momento estamos interessados em otimizar o trabalho para realizar uma análise descritiva dos dados, então vamos instalar um pacote chamado **gtsummary** (https://www.danieldsjoberg.com/gtsummary/).

> O pacote **gtsummary** nos fornecerá uma tabela resumo de todo banco de dados, otimizando bastante nosso trabalho de resumir o banco de dados.

- IMPORTANTE 1: instalamos um pacote apenas uma vez (como um aplicativo no celular... a gente só refaz a instalação se o app *bugar*!)
- IMPORTANTE 2: todas vez precisamos carregar o pacote com as funções que queremos usar por meio da função **library()**

Veja o código:

```
# comando para instalar o pacote gtsummary
install.packages("gtsummary")

# comando para carregar a biblioteca de funções do gtsummary
library(gtsummary)

# a função que vamos usar para gerar uma tabela que resume os dados é
# tbl_summary
tbl_summary(mcdonald)
```

- Ao executar **tbl_summary(mcdonald)** a tabela de resultados será mostrada na área de arquivos, gráficos, pacotes... na aba **Viewer**, no quadrante abaixo do ambiente de memória.

- Essa tabela pode ser copiada e colada para o editor de texto que você utiliza para escrever seus trabalhos, claro essa tabela pode ser melhorada!
- Observe no rodapé da tabela a seguinte legenda **n (%); Median (IQR)**, isso significa que para
  - **variáveis qualitativas:** n é a contagem (frequência absoluta) e entre parenteses (%) é mostrado a porcentagem de cada categoria.
  - **variveis quantitativas:** Median é a mediana e entre parenteses (IQR - de InterQuantile Range) estão o primeiro e terceiro quartil respectivamente.

11.1 Exemplo 1

Como mostrar o resultado com a média e desvio padrão?

```
# acrescente nos argumentos da função tbl_summary() a opção:
# statistic = list(all_continuous() ~ "{mean} ({sd})"
tbl_summary(
            mcdonald,
            statistic = list(all_continuous() ~ "{mean} ({sd})")
            )
```

11.2 Exemplo 2

Como selecionar somente algumas variáveis do banco de dados?

```
# Precisamos do pacote tidyverse, tire o símbolo de # se precisar instalar!
# install.packages("tidyverse")

# ative tidyverse
library(tidyverse)

# vamos usar a função select() do pacote tidyverse
dadosSelecionados <- select (mcdonald, Cholesterol, Sodium, Carbohydrates)

# faça uma tabela para o objeto dadosSelecionados
tbl_summary(dadosSelecionados)
```

11.3 Exemplo 3

Algumas vezes é mais fácil excluir algumas variáveis, por exemplo queremos todas, menos **Item** e **Serving Size**

```
# vamos usar a função select() do pacote tidyverse e colocar o sinal de menos (-)
# antes dos nomes das variáveis que queremos excluir
# IMPORTANTE: Serving Size é um nome de variável com espaço
# então devemos referênciá-la entre aspas: `Serving Size`
dadosSelecionados2 <- select (mcdonald, -Item, -`Serving Size`)

# faça uma tabela para o objeto dadosSelecionados2
tbl_summary(dadosSelecionados2)
```

11.4 Exemplo 4

Como selecinar um conjunto de variáveis que estão em sequência, por exemplo, de **Carbohydrates** a **Cholesterol (% Daily Value)**

```
# vamos usar a função select() do pacote tidyverse e colocar o sinal de dois pontos (:)
# entre a primeira variável e a última da sequência
# IMPORTANTE: Cholesterol (% Daily Value) é um nome de variável com espaço
# então devemos referênciá-la entre aspas: `Cholesterol (% Daily Value)`
dadosSelecionados3 <- select (mcdonald, Carbohydrates:`Cholesterol (% Daily Value)`)

# faça uma tabela para o objeto dadosSelecionados
tbl_summary(dadosSelecionados3)
```

Saiba mais sobre o Tidyverse https://www.tidyverse.org/packages/

11.5 Atividade

Escolha outro banco de dados (você pode até criar um banco fictício!), faça uma tabela descritiva dos dados e escreva sobre os dados (um ou dois parágrafos), afinal, o nosso trabalho não é só obter a tabela, é dissertar sobre ela!